

Q 系列 Q1

觀念篇：單細胞 RNA 定序 在看什麼、怎麼運作、怎麼讀圖

以一塊腫瘤組織為例，30 分鐘把三件事講清楚：組織裡有什麼、資料從哪來、流程在做什麼。

約 30 分鐘 | 前置：無 | 範例：膠質母細胞瘤（GBM） | 深入：A 系列




[https://github.com/
Charlene717/scRNA-seq-
tutorial-Qseries](https://github.com/Charlene717/scRNA-seq-tutorial-Qseries)

一個場景

**一位 58 歲的病人，MRI 上一顆 4 公分的腦瘤。
手術切下來的那塊組織，裡面到底有什麼？**

病理科說：膠質母細胞瘤，第四級。這個名字告訴你診斷，但沒有告訴你這塊組織的內容。

腫瘤不是一團惡性細胞，是一個生態系



一塊腫瘤組織切片（示意）

腫瘤不是一團惡性細胞，是一個生態系

- 惡性細胞：同一顆腫瘤裡就有多種狀態
- 免疫細胞：巨噬細胞／小膠質、T 細胞
- 基質細胞：纖維母細胞、周細胞
- 血管內皮
- 被浸潤的正常組織（GBM：寡樹突細胞、神經元）

各類群的比例因癌別、部位、甚至同一顆腫瘤的取樣位置而差異極大，沒有一組通用數字——這正是要靠單細胞去量、Bulk 讀不出來的資訊

惡性細胞只佔一部分，而且自己就有好幾種狀態；其餘是免疫、基質、血管，與被浸潤的正常腦組織

這一集的起點

**治療失敗、復發、抗藥性，
答案常常藏在「哪一種細胞、處在哪一種狀態」。**

要回答這種問題，你需要一種能一顆一顆看細胞的技術。這一集講清楚為什麼，以及它給你的資料長什麼樣。

本集目標


- 1 說出腫瘤研究裡四個「Bulk 一定回答不了、單細胞才回答得了」的問題，以及 n 為什麼是病人不是細胞
- 2 解釋 10x 平台怎麼把一管細胞變成一個矩陣，矩陣裡除了細胞還混了什麼
- 3 畫出九步流程、說出腫瘤資料的兩個特有現象（惡性細胞按病人分群、用 CNV 判定惡性），並正確讀一張 UMAP

01

傳統方法看到什麼、漏掉什麼


先理解 Bulk RNA-seq 的限制，單細胞的價值才會清楚

Bulk RNA-seq：把整塊組織打碎，量一個平均



腫瘤 A

惡性 75%




腫瘤 B


惡性 35%、免疫 50%



整塊打碎定序



整塊打碎定序



Bulk：分不出高低



惡性



免疫



基質

Bulk 數字分不出高低，組成卻完全不同


基因 X 在惡性細胞裡高、在免疫細胞裡也高。
Bulk 把兩者加總，看不出訊號來自誰，
也看不出比例

腫瘤研究裡這叫「純度」問題：
每一份 Bulk 都被基質與免疫細胞稀釋，
而且稀釋比例未知

兩顆組成完全不同的腫瘤，Bulk 數字可以接近到分不出高低。腫瘤研究稱之為「純度」問題


四個 Bulk 回答不了的腫瘤問題

① 訊號來自誰？




EGFR 上升——是每顆惡性細胞變了，還是惡性細胞變多了？
兩種算出來的 Bulk 值一樣，
分不出來

② 少數細胞在做什麼？




耗竭 T 細胞、
癌症幹細胞可能只佔 1-2%，
在 Bulk 平均裡稀釋到看不見；
單細胞裡它們會自己聚成一群

③ 惡性細胞有幾種狀態？



GBM 的惡性細胞同時存在四種
狀態，而且會互相轉換。
Bulk 只給你一個平均位置

④ 誰在跟誰講話？



配體與受體在 Bulk 裡都測
得到，但看不出是哪一群發出、
哪一群接收。
細胞通訊需要細胞層級的座標

訊號來自誰、少數細胞在做什麼、惡性細胞有幾種狀態、誰在跟誰講話。四個都是臨床上真正重要的問題

什麼時候其實不需要單細胞

判準只有一個：你的問題需不需要「知道每一顆細胞是誰」。不需要 → 別用單細胞

不用 | 問「整體變了沒」



治療前後的整體變化、預後分型、幾百人的世代。答案是一個組織層級的數字—— Bulk 更便宜、更穩、功效更高

不用 | 型別已知，只想數比例



要數的型別已知、也有對應的 marker：流式、免疫組化、Bulk 反卷積（Q3）都答得了，而且做得動幾百個樣本

非用不可 | 型別未知或狀態連續



沒有 marker 可數的稀有群、還沒被命名的型別、惡性細胞之間連續的狀態、誰對誰送訊號——答案就是每顆細胞的身分，取平均就沒了

02

從一塊組織到一個矩陣

技術只需要記住三個詞： GEM、Barcode、UMI

手術台到定序儀： 四步



解離

酵素把組織拆成單顆細胞懸浮液。腫瘤組織硬、壞死多，這一步很暴力，會留下痕跡



分裝

微流道把每顆細胞跟一顆珠子包進油滴（GEM）



建庫

每顆細胞的 mRNA 帶上珠子的 Barcode，再一起做成一個定序庫



定序與計數

Cell Ranger 依 Barcode 分回細胞、依 UMI 去重，產生矩陣

平台不只一種： 3'、 5'、全長、細胞核


這三集用兩種： Q2 是 10x 3'， Q3 是 Smart-seq2。差異決定了 QC 與 CNV 的參數

平台	讀到什麼	細胞數 / 深度	適合	要注意
10x 3' (Q2)	mRNA 3' 端 + UMI	5-10k 顆 2-5 萬 reads	組成、型別、狀態 預設選擇	doublet、環境 RNA
10x 5' + V(D)J	5' 端 + TCR / BCR 序列	同上	免疫治療、T / B 細胞 克隆	腫瘤細胞本身沒有 額外資訊
Smart-seq2 (Q3)	全長 transcript， 無 UMI	數百-數千顆 約 100 萬 reads	CNV、剪接、突變 珍貴的少量細胞	貴、慢 read 數 ≠ 分子數
snRNA-seq (細胞核)	核內 RNA，多為未 剪接	同 10x	冷凍檢體、腦 解離會壞的組織	mt 基因近乎 0 免疫細胞較少

GEM：一顆細胞、一顆珠子、一滴油


凝膠珠（表面帶數百萬條 Barcode 引子）

細胞懸浮液 + 逆轉錄酵素



珠子與細胞是隨機配對的：多數液滴是空的，少數會包到兩顆細胞（doublet）

一顆 GEM 裡



珠子

裂解中的細胞


1 顆細胞 + 1 顆珠子 + 裂解液

細胞在珠子旁邊裂解，
所有 mRNA 的 poly(A) 尾都抓上
同一顆珠子的引子——這顆珠子的
Barcode 就成了這顆細胞的身分證

珠子與細胞是隨機配對的：多數液滴是空的，少數會包到兩顆細胞。這兩件事之後都會變成 QC 的工作

Barcode 記「哪顆細胞」， UMI 記「哪個分子」

珠子上的每一條引子



為什麼需要 UMI

定序到 3 條
一樣的 read：

AGTCCA
AGTCCA
AGTCCA

UMI 相同→同一個分子
被 PCR 複製，只算 1

AGTCCA
TTGACG


UMI 不同→兩個
分子，算 2

所以矩陣裡的數字是「分子數 (UMI count)」，
不是 read 數。它比 Bulk 的 read count 少很多，也更誠實

矩陣裡的數字是分子數，不是 read 數。這是單細胞計數資料和 Bulk 最根本的差別

定序輸出：基因 × 細胞的計數矩陣

Cell Ranger 交給你的：一個「基因 × 細胞」的計數矩陣



GBM 5k 範例：約 3.6 萬個基因 × 5,604 顆細胞；每格是 UMI 分子數，> 90% 的格子是 0

每一欄一顆細胞、每一列一個基因；九成以上的格子是 0，這是技術的本質，不是資料壞掉

三個檔案

Barcodes.tsv

每欄一顆細胞的 Barcode

features.tsv


每列一個基因

matrix.mtx

只存非零的格子（稀疏格式）

九成是 0：零有兩種，結論永遠建立在一群細胞上

矩陣九成是 0：這是技術的本質，也是分析的出發點



一個 0 有兩種可能

1 真的沒表現

例：T 細胞裡的 SOX2。這種 0 是訊號，是我們要的

2 有表現但沒抓到 (dropout)

每顆細胞只抓到 10–30% 的 mRNA；
低表現基因常常漏掉。這種 0 是雜訊，
靠「一群細胞一起看」補回來

所以：不要對單顆細胞的單一基因下結論；
結論永遠建立在「一群細胞」的分布上


零的比例主要由表現量決定，是技術期望，不是資料壞掉。所以看單顆細胞的單一基因沒有意義——這是後面所有分析都「一群一群看」的理由

矩陣裡不是每一欄都是細胞





垂死／破損細胞

腫瘤解離很暴力：壞死區、
酵素消化，
粒線體 RNA 比例衝高。
腫瘤樣本的 percent.mt 常常
是雙峰




空滴（ ambient RNA）

壞死釋出的游離 RNA 特別多。
空滴會帶著惡性細胞的基因，
看起來像「低品質的惡性細胞」



doublet

惡性細胞+巨噬細胞黏在一起，
會被誤讀成「表現免疫基因的
腫瘤細胞」
——文獻裡真的出現過



解離壓力反應



FOS、JUN、
HSPA1A 衝高的細胞散在各型別
裡。不是壞細胞，
但它們的「活化」是假的



腫瘤樣本這四種東西特別多。它們都有 Barcode，看起來就像細胞——所以流程第一步是 QC

實驗設計的三個數字：病人數、細胞數、深度

實驗設計的三個數字：病人數、每個樣本的細胞數、每顆細胞的深度



病人數決定統計功效 (Q3) ；細胞數決定看不看得到稀有群；深度過了膝點就該把錢花在更多病人上

決定順序是：先病人數（功效），再細胞數（最稀有的群），最後深度（過膝點就浪費）。預算固定時，多一位病人幾乎永遠比多一萬顆細胞值

03


流程在做什麼

記住每一步解決的問題，就記住了流程；最後一頁是整條流程都適用的那條紅線

九步，每一步一個問題

標準流程九步：每一步解決一個問題

藍色深底 = 對腫瘤資料特別關鍵的步驟；紅色卡 = 腫瘤資料的特殊之處



標準流程到 DE 為止。之後的路（惡性判定、細胞通訊、軌跡、反卷積）每一條都需要對的資料——Q3 會給你選路的表

這是 Q2 會用一份真實 GBM 資料逐行跑一遍的路線。紅色卡是腫瘤資料的特殊之處

九步之後：下游分析的六條路

標準流程走完之後：六條下游的路

九步的終點是一份「每顆細胞都有名字」的物件。從這裡開始，問題決定路，資料決定走不走得通



六條路不是選單，是六個不同的問題。每一條的紅字是它的前提——前提不成立時，正確的做法是說清楚，不是把圖畫出來

分析發生在 PC 空間，UMAP 只是投影


PC 空間（10-30 維，看不到）

- 分群：KNN 圖與社群偵測
- 細胞間距離、鄰居
- 整合（Harmony 校正的就是這裡）
- 軌跡、擬時序

RunUMAP

投影

UMAP（2 維，看得到）



只用來看：哪些細胞彼此相似。
距離、面積、形狀都不是證據

分群、距離、整合、軌跡都在左邊做；右邊只是畫給眼睛看。這句記住了，一半的誤讀不會發生

這條流程的紅線：統計單位是病人，不是細胞

設計一：1 位病人，3 萬顆細胞



30,000

$n = 1$

統計上的重複單位

設計二：6 位病人，各 5 千顆



5,000



5,000



5,000



5,000



5,000



5,000

$n = 6$

可以做病人間的推論

同一位病人的三萬顆細胞共享基因體、年齡、用藥與解離條件——它們不是獨立觀察值

一位病人三萬顆細胞，統計上仍是 $n = 1$ 。把細胞當樣本做檢定，得到的是自由度灌水後的假顯著——Q3 會實測這件事的規模


04

範例的特殊之處：腫瘤資料的兩個現象

每種組織都有自己的特殊之處；腫瘤的這兩件事最容易踩錯

現象一：惡性細胞按病人分群，正常細胞跨病人混合

腫瘤資料最重要的現象：惡性細胞按病人分群，正常細胞跨病人混合




原因：每位病人的腫瘤有自己的 CNV 與突變組合。這不是批次效應，整合時要小心不要把它「修掉」 (Q3)

每位病人的腫瘤有自己的 CNV 與突變組合。這不是批次效應——整合時千萬不要把它修掉 (Q3)

現象二：能定惡性的標記讀不到，讀得到的定不了惡性

惡性細胞的身分證是基因體：用表現量的「染色體級趨勢」推回 CNV



一個基因的表現量說不了什麼；但同一條染色體上一百個基因「一起」偏高或偏低，只有一種解釋：
這段 DNA 的拷貝數變了。這就是 inferCNV 的原理，也是腫瘤資料裡分辨惡性與正常最可靠的依據（Q3 實作）

IDH1 R132H、H3K27M 這類突變標記確實能定惡性，但它們是點突變，3' 定序讀不到。表現量讀得到的 SOX2、EGFR 只說得出譜系——所以退而求其次看整段染色體一起偏移

四個主要類群：三個好分，一個不好分

註釋腫瘤資料的第一刀永遠是這四塊

三群：免疫 · 血管 · 寡樹突

命名到這裡就結束

- 免疫 — PTPRC
- 血管 — PECAM1、VWF
- 寡樹突 — MBP、PLP1（inferCNV 的參考組）

第四群：膠質／惡性

命名完還有一關要過


- 膠質 — SOX2、OLIG2、PTPRZ1、EGFR
- 惡性另需 CNV + 跨病人專屬性
- 先判定，再談狀態（MES/AC/OPC/NPC）

05

看懂單細胞的圖

多數人一生只需要這個技能

UMAP 能告訴我們的，與不能告訴我們的



能告訴你

- ✓ 哪些細胞彼此相似（局部鄰居可信）
- ✓ 大致有幾群、哪些群相連
- ✓ 某個基因亮在哪一群（FeaturePlot）


不能告訴你

- ✗ 兩群離多遠 $\neq$ 親緣多遠（換 seed 就換位置）
- ✗ 群的面積 $\neq$ 細胞數（用 `table()` 數）
- ✗ 拉長的形狀 $\neq$ 分化軌跡
- ✗ 惡性細胞分四島 $\neq$ 四種亞型（那是四位病人）

最後一條是腫瘤專屬的誤讀：惡性細胞的四座島不是四種亞型，是四位病人

同一份資料，只換隨機種子

同一份腫瘤資料、同一行程式碼，只換隨機種子




群的位置與形狀全變了；每顆細胞的 cluster 標籤一個都沒變——因為分群在 PC 空間做，不在這張圖上

群的位置與形狀全變、標籤一個都沒變。「群 A 靠近群 B 暗示親緣」這種句子沒有證據力

dotplot：兩個維度要分開讀

dotplot：一張圖回答「哪一群表現什麼」——腫瘤微環境的 marker 面板



兩個維度分開讀



大小 = 多少比例的細胞有表現

顏色 = 平均表現量

沿對角線一塊塊亮起來，就是好的註釋。PTPRC 同時亮在三種免疫細胞：它是「免疫類群」的譜系標誌，不是型別 marker

點的大小是「多少比例的細胞表現」，顏色是「表現多高」。沿對角線一塊塊亮起來就是好的註釋


FeaturePlot：有顏色不一定是表現

FeaturePlot：同樣是「有顏色」，三種情況三種意思

乾淨的 marker：PTPRC

環境 RNA：MBP

低偵測基因：IL2



只在免疫細胞亮，
其他幾乎全灰——可以當譜系標誌

寡樹突細胞很亮，但所有細胞都有一點——
裂解細胞放出的 mRNA 漂進每一顆液滴

零星幾顆亮，沒有群的形狀——不能
用單顆細胞下結論

乾淨的譜系標誌只亮一塊；環境 RNA 讓每顆都有一點；低偵測基因零星幾點。看這種圖先問：亮的地方有沒有「群的形狀」

四種最普遍的誤讀

你看到	你以為	其實
兩群離得遠	親緣很遠	UMAP 不保留全域距離；換 seed 就換位置
某群面積很大	細胞很多	面積反映密度與參數；用 table() 數
群拉成一條長帶	分化軌跡	可能是週期、深度梯度、doublet 橋
惡性細胞分成四島	四種惡性亞型	四位病人；亞型要在病人內用狀態分數看

讀一篇單細胞論文的 Figure 1：先問五件事

五個答案都在方法段與補充圖裡；找不到，就把結論打折

問題	為什麼重要	去哪裡找
幾位病人？每組幾位？	n 是病人； $n < 3$ 的組間比較只是描述	Table 1、方法「樣本」段
細胞怎麼 QC、去 doublet？	沒做 doublet 的資料，「雙表現」型別多半是假的	方法「QC」段、補充圖 1
整合了什麼、修掉了什麼？	按病人整合會把惡性細胞的真實差異抹平（Q3）	方法「整合」段、整合前後的 UMAP
惡性怎麼判定？	只靠 marker 的「腫瘤細胞」不可信；要有 CNV 或突變	inferCNV / copyKAT 熱圖
DE 的單位是細胞還是病人？	cell-level 檢定給出上千個假陽性（Q3）	方法「差異表達」段：有無 pseudobulk

06

常見錯誤

三個觀念層級的錯誤——程式不會報錯，結論會錯

錯誤一：把細胞數當樣本數

雷是什麼

一位病人的腫瘤 vs 一位病人的正常腦，三萬顆細胞做檢定，找到三千個「疾病基因」。



為什麼會踩

每顆細胞看起來都是一個獨立觀察值。

踩了會怎樣

同一位病人的細胞彼此相關， n 其實是 1。這些基因大半在下一位病人身上不成立。

錯誤二：把解離壓力當成腫瘤生物學

雷是什麼

發現一群 FOS、JUN、HSPA1A 高表現的惡性細胞，寫成「壓力反應亞群」。



為什麼會踩

marker 乾淨、富集分析顯著、跟文獻上某個「MES 樣狀態」很像。

踩了會怎樣

那是酵素解離時的立即早期反應，散在所有型別裡。腫瘤組織解離時間長，這個假象特別強。

錯誤三：以 marker 判定惡性

雷是什麼

「這群表現 EGFR 和 SOX2 ，所以是腫瘤細胞。」



為什麼會踩

這些基因在教科書裡確實是 GBM 的標誌。

踩了會怎樣

反應性星狀細胞、OPC 也表現它們。惡性的證據是 CNV ； 沒有 CNV 佐證的「腫瘤細胞」審稿人不會接受。

這門技術看不到什麼：五個要先講清楚的限制

限制不是缺點，是解讀的邊界。討論段主動寫出來，比被審稿人指出來好

限制	具體是什麼	對結論的影響
位置資訊沒了	解離的那一刻，每顆細胞就離開了它原本待的地方	「在血管旁」「在壞死區邊緣」講不出來；要空間轉錄體才問得了
只讀得到 RNA	蛋白質、修飾、代謝物都不在這個矩陣裡	mRNA 高不等於蛋白高；「路徑活化」需要另一種證據
讀到的是解離後的狀態	酵素、時間、溫度都會改變表現；FOS／JUN／HSP 那群就是這樣來的	「壓力亞群」多半是操作痕跡，不是腫瘤生物學（見錯誤二）
3′ 定序只讀末端	10x 3′ 每個分子只定序到 3′ 端約 90 個鹼基	點突變、剪接、融合基因幾乎讀不到——惡性判定才要退回 CNV
只有一個時間點	每顆細胞只被量一次，量完就沒了	「A 變成 B」是推論不是觀察；軌跡給的是排序，不是時間

單細胞轉錄體之後還有什麼

這三集讀到的只有 RNA。知道還有哪些量法，才知道自己缺的是什麼

多模態



RNA + 蛋白 / 染色質。CITE-seq 同時量表面蛋白（免疫細胞更準）；10x Multiome 同時量 ATAC（調控與譜系）。分析骨架與本課相同

空間轉錄體



Visium、Xenium、MERFISH
保留位置：誰在血管旁、誰在壞死區、核心與邊緣的界線在哪。常用單細胞資料當參考來反卷積

譜系與基因體



TCR / BCR 定序追克隆；
scDNA-seq 或 mitochondrial variants 追亞株。腫瘤演化研究常把它們跟表現資料配對

一句話總結

**腫瘤是生態系，單細胞把它拆開；
分析在 PC 空間，UMAP 只是投影；
惡性看基因體，病人是統計單位。**

三句話。Q2 的每一行程式碼、Q3 的每一個決定，都建立在這三句上。

自測 1

Bulk RNA-seq 顯示腫瘤 A 的 CD8A 比腫瘤 B 高三倍。最保守的解讀？

A A 的 T 細胞更有攻擊性

B A 的 CD8 T 細胞比例可能較高，或每顆表現較高—— Bulk 分不開

C A 對免疫治療反應較好

答 B。組成改變 vs 內在改變在 Bulk 裡長得一樣。A 與 C 都是過度詮釋，要單細胞資料（加上多位病人）才能往那個方向推。

自測 2

四位病人的 GBM 資料，UMAP 上惡性細胞分成四座島、巨噬細胞混成一群。這代表？

- A 有嚴重批次效應，要整合
- B 惡性細胞有四種亞型
- C 正常現象：惡性細胞帶病人特異的 CNV，正常細胞沒有

答 C。巨噬細胞混合得很好，證明技術批次不大；惡性細胞分島來自基因體差異。硬整合會把真實的病人差異抹掉。

自測 3

要證明某群細胞是惡性的，最有力的證據是？

A 高表現 EGFR、SOX2

B 整段染色體（如 chr7 增加、chr10 缺失）的表現一起偏移

C 在 UMAP 上離免疫細胞很遠

答 B。marker 只能說譜系，UMAP 距離沒有證據力；CNV 是基因體層級的證據，也是 inferCNV 的原理。

下一集

Q2：單一樣本標準流程——從原始矩陣到細胞註釋

觀念有了，換手指。下一集用 10x 公開的 GBM 5k（5,604 顆細胞）從讀檔一路做到註釋，附三支練習腳本，每一段程式碼都可以直接複製。

