

Q1 Q 系列

觀念篇：單細胞 RNA 定序

在看什麼、怎麼運作、怎麼讀圖

以一塊腫瘤組織為例，30 分鐘建立三個心智模型：組織裡有什麼、資料從哪來、流程在做什麼。


約 30 分鐘 | 前置：無 | 範例：膠質母細胞瘤 (GBM) | 深入：A 系列

一個場景

**一位 58 歲的病人，MRI 上一顆 4 公分的腦瘤。
手術切下來的那塊組織，裡面到底有什麼？**

病理科說：膠質母細胞瘤，第四級。這個名字告訴你診斷，但沒有告訴你這塊組織的內容。

腫瘤不是一團惡性細胞，是一個生態系



一塊腫瘤組織切片（示意）

腫瘤不是一團惡性細胞，是一個生態系

- 惡性細胞：同一顆腫瘤裡就有多種狀態 80%
- 免疫細胞：巨噬細胞／小膠質、T細胞 40%
- 基質細胞：纖維母細胞、周細胞 5-15%
- 血管內皮 1-5%
- 被浸潤的正常組織（GBM：寡樹突細胞、神經元） 5-30%

比例因癌別、部位與取樣位置差異極大——這正是 bulk 讀不出來的資訊

惡性細胞只佔一部分，而且自己就有好幾種狀態；其餘是免疫、基質、血管，與被浸潤的正常腦組織

這一集的起點

**治療失敗、復發、抗藥性，
答案常常藏在「哪一種細胞、處在哪一種狀態」。**

要回答這種問題，你需要一種能一顆一顆看細胞的技術。這一集講清楚為什麼，以及它給你的資料長什麼樣。

30 分鐘後你會...


- 1 說出腫瘤研究裡三個「bulk 一定回答不了、單細胞才回答得了」的問題，以及 n 為什麼是病人不是細胞
- 2 解釋 10x 平台怎麼把一管細胞變成一個矩陣，矩陣裡除了細胞還混了什麼
- 3 畫出九步流程、說出腫瘤資料的兩個特有現象（惡性細胞按病人分群、用 CNV 判定惡性），並正確讀一張 UMAP

01

傳統方法看到什麼、漏掉什麼

先理解 bulk RNA-seq 的限制，單細胞的價值才會清楚


bulk RNA-seq：把整塊組織打碎，量一個平均



兩顆組成完全不同的腫瘤，可以給出一模一樣的 bulk 數字。腫瘤研究稱之為「純度」問題


三個 bulk 回答不了的腫瘤問題

① 訊號來自誰？




腫瘤裡 EGFR 上升——是惡性細胞的表現變了，還是惡性細胞的比例變了？
bulk 分不開，單細胞一顆一顆看得到

② 少數細胞在做什麼？



耗竭的 T 細胞、癌症幹細胞可能只佔 1-2%。在 bulk 平均裡被稀釋到看不見；在單細胞裡它們自己聚成一群

③ 惡性細胞有幾種狀態？



GBM 的惡性細胞同時存在四種狀態（MES/AC/OPC/NPC 樣），而且會互相轉換。
bulk 只給你一個平均位置

訊號來自誰、少數細胞在做什麼、惡性細胞有幾種狀態。每一個都是臨床上真正重要的問題

同一個現象，兩個名字

組成改變



免疫細胞被徵召進來，比例變了；每顆惡性細胞沒變

內在改變



比例沒變，但每顆惡性細胞的表現程式變了

bulk 分不開



兩者在 bulk 裡都是「基因 X 上升」；治療策略卻完全不同

最重要的一句話：n 是病人，不是細胞

設計一：1 位病人，3 萬顆細胞



30,000

n = 1

統計上的重複單位

設計二：6 位病人，各 5 千顆



5,000



5,000



5,000



5,000



5,000



5,000

n = 6

可以做病人間的推論

同一位病人的三萬顆細胞共享基因體、年齡、用藥與解離條件——它們不是獨立觀察值

一位病人三萬顆細胞，統計上仍是 $n = 1$ 。設計實驗時就要決定要收幾位病人——Q3 會看到違反這件事的後果

什麼時候其實不需要單細胞

單細胞貴、雜、統計功效低；先問清楚問題，再選工具

整體有沒有變？



治療前後的整體表現、預後分子分型
、幾百位病人的世代——bulk 更便宜、更穩、功效更高

問「比例變了多少」而且型別已知



流式細胞儀、免疫組織化學、bulk 反卷積（Q3 提到）就能回答；單細胞只是更貴的計數器

問「誰、什麼狀態、跟誰互動」



罕見群、未知型別、惡性細胞的狀態、細胞間通訊——這才是非單細胞不可的問題

02

從一塊組織到一個矩陣

技術只需要記住三個詞：GEM、barcode、UMI

手術台到定序儀：四步



解離

酵素把組織拆成單顆細胞懸浮液。腫瘤組織硬、壞死多，這一步很暴力，會留下痕跡



分裝

微流道把每顆細胞跟一顆珠子包進油滴 (GEM)



建庫

每顆細胞的 mRNA 帶上珠子的 barcode，再一起做成一個定序庫



定序與計數

Cell Ranger 把 reads 依 barcode 分回細胞、依 UMI 去重、產生矩陣

平台不只一種：3'、5'、全長、細胞核


這三集用兩種：Q2 是 10x 3'，Q3 是 Smart-seq2。差異決定了 QC 與 CNV 的參數

平台	讀到什麼	細胞數 / 深度	適合	要注意
10x 3' (Q2)	mRNA 3' 端 + UMI	5-10k 顆 2-5 萬 reads	組成、型別、狀態 預設選擇	doublet、ambient RNA
10x 5' + V(D)J	5' 端 + TCR / BCR 序列	同上	免疫治療、T / B 細胞克隆	腫瘤細胞本身沒有額外資訊
Smart-seq2 (Q3)	全長 transcript，無 UMI	數百-數千顆 約 100 萬 reads	CNV、剪接、突變 珍貴的少量細胞	貴、慢 read 數 ≠ 分子數
snRNA-seq (細胞核)	核內 RNA，多為未剪接	同 10x	冷凍檢體、腦 解離會壞的組織	mt 基因近乎 0 免疫細胞較少

GEM：一顆細胞、一顆珠子、一滴油


凝膠珠（表面帶數百萬條 barcode 引子）

細胞懸浮液 + 逆轉錄酵素



珠子與細胞是隨機配對的：多數液滴是空的，少數會包到兩顆細胞（doublet）

一顆 GEM 裡




1 顆細胞 + 1 顆珠子 + 裂解液

細胞在珠子旁邊裂解，
所有 mRNA 的 poly(A) 尾都抓上
同一顆珠子的引子——這顆珠子的
barcode 就成了這顆細胞的身分證

珠子與細胞是隨機配對的：多數液滴是空的，少數會包到兩顆細胞。這兩件事之後都會變成 QC 的工作

barcode 記「哪顆細胞」，UMI 記「哪個分子」

珠子上的每一條引子



為什麼需要 UMI

定序到 3 條
一樣的 read：

AGTCCA
AGTCCA
AGTCCA

UMI 相同→同一個分子
被 PCR 複製，只算 1

AGTCCA
TTGACG


UMI 不同→兩個
分子，算 2

所以矩陣裡的數字是「分子數 (UMI count)」，
不是 read 數。它比 bulk 的 read count 少很多，也更誠實

矩陣裡的數字是分子數，不是 read 數。這是單細胞計數資料和 bulk 最根本的差別

你最後拿到的東西

Cell Ranger 交給你的：一個「基因 × 細胞」的計數矩陣



GBM 5k 範例：約 3.6 萬個基因 × 5,604 顆細胞；每格是 UMI 分子數，> 90% 的格子是 0

每一欄一顆細胞、每一列一個基因；九成以上的格子是 0，這是技術的本質，不是資料壞掉

三個檔案

barcodes.tsv

每欄一顆細胞的 barcode

features.tsv


每列一個基因

matrix.mtx

只存非零的格子（稀疏格式）

九成是 0：零有兩種，結論永遠建立在一群細胞上

矩陣九成是 0：這是技術的本質，也是分析的出發點



一個 0 有兩種可能

1 真的沒表現

例：T 細胞裡的 SOX2。
這種 0 是訊號，是我們要的

2 有表現但沒抓到 (dropout)

每顆細胞只抓到 10–30% 的 mRNA；
低表現基因常常漏掉。這種 0 是雜訊，
靠「一群細胞一起看」補回來

所以：不要對單顆細胞的單一基因下結論；
結論永遠建立在「一群細胞」的分布上


零的比例主要由表現量決定，是技術期望，不是資料壞掉。所以看單顆細胞的單一基因沒有意義——這是後面所有分析都「一群一群看」的理由

矩陣裡不是每一欄都是細胞



垂死／破損細胞

腫瘤解離很暴力：壞死區、
酵素消化，
粒線體 RNA 比例衝高。
腫瘤樣本的 percent.mt 常
常是雙峰



空滴（ ambient RNA）

壞死釋出的游離 RNA 特別多。
空滴會帶著惡性細胞的基因，
看起來像「低品質的惡性細胞」



doublet

惡性細胞+巨噬細胞黏在
一起，會被誤讀成「表現免
疫基因的腫瘤細胞」
——文獻裡真的出現過



解離壓力反應



FOS、JUN、
HSPA1A 衝高的細胞散在各型
別裡。不是壞細胞，
但它們的「活化」是假的



腫瘤樣本這四種東西特別多。它們都有 barcode，看起來就像細胞——所以流程第一步是 QC

實驗設計的三個數字：病人數、細胞數、深度

實驗設計的三個數字：病人數、每個樣本的細胞數、每顆細胞的深度



病人數決定統計功效 (Q3) ；細胞數決定看不看得到稀有群；深度過了膝點就該把錢花在更多病人上

決定順序是：先病人數 (功效) ，再細胞數 (最稀有的群) ，最後深度 (過膝點就浪費) 。預算固定時，多一位病人幾乎永遠比多一萬顆細胞值

03


流程在做什麼

記住每一步解決的問題，就記住了流程

九步，每一步一個問題

標準流程九步：每一步解決一個問題

藍色深底 = 對腫瘤資料特別關鍵的步驟；紅色卡 = 腫瘤資料的特殊之處



標準流程到 DE 為止。之後的路（惡性判定、細胞通訊、軌跡、反卷積）每一條都需要對的資料——Q3 會給你選路的表

這是 Q2 會用一份真實 GBM 資料逐行跑一遍的路線。紅色卡是腫瘤資料的特殊之處

分析發生在 PC 空間，UMAP 只是投影機


PC 空間（10-30 維，看不到）

- 分群：KNN 圖與社群偵測
- 細胞間距離、鄰居
- 整合（Harmony 校正的就是這裡）
- 軌跡、擬時序

RunUMAP

投影

UMAP（2 維，看得到）



只用來看：哪些細胞彼此相似。
距離、面積、形狀都不是證據

分群、距離、整合、軌跡都在左邊做；右邊只是畫給眼睛看。這句記住了，一半的誤讀不會發生

04

範例的特殊之處：腫瘤資料的兩個現象

每種組織都有自己的特殊之處；腫瘤的這兩件事最容易踩錯



現象一：惡性細胞按病人分群，正常細胞跨病人混合

腫瘤資料最重要的現象：惡性細胞按病人分群，正常細胞跨病人混合

● 惡性 ● 髓系 ● T ● 寡樹突 ● 血管

按細胞型別上色

按病人上色




原因：每位病人的腫瘤有自己的 CNV 與突變組合。這不是批次效應，整合時要小心不要把它「修掉」 (Q3)

每位病人的腫瘤有自己的 CNV 與突變組合。這不是批次效應——整合時千萬不要把它修掉 (Q3)

現象二：惡性與正常的分界要靠基因體，不靠 marker

惡性細胞的身分證是基因體：用表現量的「染色體級趨勢」推回 CNV



一個基因的表現量說不了什麼；但同一條染色體上一百個基因「一起」偏高或偏低，只有一種解釋：
這段 DNA 的拷貝數變了。這就是 inferCNV 的原理，也是腫瘤資料裡分辨惡性與正常最可靠的依據（Q3 實作）

SOX2、EGFR 只能說「膠質譜系」；星狀細胞也表現。惡性的證據是整段染色體一起偏移——inferCNV 的原理

腫瘤微環境裡的四塊大陸

註釋腫瘤資料的第一刀，永遠是這四塊

免疫 + 血管 + 正常組織

跨病人混合、marker 明確

- PTPRC：所有免疫細胞的門牌
- PECAM1 / VWF：血管內皮
- MBP / PLP1：寡樹突細胞——inferCNV 的好參考

膠質 / 惡性

按病人分島、marker 只說譜系


- SOX2 / OLIG2 / PTPRZ1 / EGFR
- 惡性判定另外做：CNV (Q3)
- 惡性細胞內部再看狀態 (MES / AC / OPC / NPC 樣)

05

看懂單細胞的圖

多數人一生只需要這個技能

UMAP 能告訴你的，與不能告訴你的



能告訴你

- ✓ 哪些細胞彼此相似（局部鄰居可信）
- ✓ 大致有幾群、哪些群相連
- ✓ 某個基因亮在哪一群（FeaturePlot）


不能告訴你

- ✗ 兩群離多遠 $\neq$ 親緣多遠（換 seed 就換位置）
- ✗ 群的面積 $\neq$ 細胞數（用 table() 數）
- ✗ 拉長的形狀 $\neq$ 分化軌跡
- ✗ 惡性細胞分四島 $\neq$ 四種亞型（那是四位病人）

最後一條是腫瘤專屬的誤讀：惡性細胞的四座島不是四種亞型，是四位病人

同一份資料，只換隨機種子

同一份腫瘤資料、同一行程式碼，只換隨機種子




群的位置與形狀全變了；每顆細胞的 cluster 標籤一個都沒變——因為分群在 PC 空間做，不在這張圖上

群的位置與形狀全變、標籤一個都沒變。「群 A 靠近群 B 暗示親緣」這種句子沒有證據力

dotplot：兩個維度要分開讀

dotplot：一張圖回答「哪一群表現什麼」——腫瘤微環境的 marker 面板



兩個維度分開讀

- 20%
- 60%
- 100%

大小 = 多少比例的細胞有表現
顏色 = 平均表現量

沿對角線一塊塊亮起來，就是好的註釋。PTPRC 同時亮在三種免疫細胞：它是「免疫大陸」的門牌，不是型別 marker

點的大小是「多少比例的細胞表現」，顏色是「表現多高」。沿對角線一塊塊亮起來就是好的註釋

FeaturePlot：有顏色不一定是表現

FeaturePlot：同樣是「有顏色」，三種情況三種意思


乾淨的 marker：PTPRC

環境 RNA：MBP


低偵測基因：IL2



只在免疫細胞亮，其他幾乎全灰——可以當門牌



寡樹突細胞很亮，但所有細胞都有一點——
裂解細胞放出的 mRNA 漂進每一顆液滴



零星幾顆亮，沒有群的形狀——不能
用單顆細胞下結論

乾淨的門牌只亮一塊；環境 RNA 讓每顆都有一點；低偵測基因零星幾點。看這種圖先問：亮的地方有沒有「群的形狀」

四種最普遍的誤讀

你看到	你以為	其實
兩群離得遠	親緣很遠	UMAP 不保留全域距離；換 seed 就換位置
某群面積很大	細胞很多	面積反映密度與參數；用 table() 數
群拉成一條長帶	分化軌跡	可能是週期、深度梯度、doublet 橋
惡性細胞分成四島	四種惡性亞型	四位病人；亞型要在病人內用狀態分數看

讀一篇單細胞論文的 Figure 1：先問五件事

五個答案都在方法段與補充圖裡；找不到，就把結論打折

問題	為什麼重要	去哪裡找
幾位病人？每組幾位？	n 是病人； $n < 3$ 的組間比較只是描述	Table 1、方法「樣本」段
細胞怎麼 QC、去 doublet？	沒做 doublet 的資料，「雙表現」型別多半是假的	方法「QC」段、補充圖 1
整合了什麼、修掉了什麼？	按病人整合會把惡性細胞的真實差異抹平 (Q3)	方法「整合」段、整合前後的 UMAP
惡性怎麼判定？	只靠 marker 的「腫瘤細胞」不可信；要有 CNV 或突變	inferCNV / copyKAT 熱圖
DE 的單位是細胞還是病人？	cell-level 檢定給出上千個假陽性 (Q3)	方法「差異表達」段：有無 pseudobulk

06

踩雷區

三個觀念層級的雷——程式不會報錯，結論會錯

雷一：把細胞數當樣本數

雷是什麼

一位病人的腫瘤 vs 一位病人的正常腦，三萬顆細胞做檢定，找到三千個「疾病基因」。



為什麼會踩

每顆細胞看起來都是一個獨立觀察值。

踩了會怎樣

同一位病人的細胞彼此相關， n 其實是 1。這些基因大半在下一位病人身上不成立。

雷二：把解離壓力當成腫瘤生物學

雷是什麼

發現一群 FOS、JUN、HSPA1A 高表現的惡性細胞，寫成「壓力反應亞群」。



為什麼會踩

marker 乾淨、富集分析顯著、跟文獻上某個「MES 樣狀態」很像。

踩了會怎樣

那是酵素解離時的立即早期反應，散在所有型別裡。腫瘤組織解離時間長，這個假象特別強。

雷三：用 marker 判定惡性

雷是什麼

「這群表現 EGFR 和 SOX2，所以是腫瘤細胞。」



為什麼會踩

這些基因在教科書裡確實是 GBM 的標誌。

踩了會怎樣

反應性星狀細胞、OPC 也表現它們。惡性的證據是 CNV；沒有 CNV 佐證的「腫瘤細胞」審稿人不會接受。

單細胞轉錄體之後還有什麼

這三集只做 RNA。知道地圖上還有哪些國家，讀論文時才不會迷路

多模態



RNA + 蛋白 / 染色質。CITE-seq 同時量表面蛋白（免疫細胞更準）；10x Multiome 同時量 ATAC（調控與譜系）。分析骨架與本課相同

空間轉錄體



Visium、Xenium、MERFISH
保留位置：誰在血管旁、誰在壞死區、核心與邊緣的界線在哪。常用單細胞資料當參考來反卷積

譜系與基因體



TCR / BCR 定序追克隆；scDNA-seq 或 mitochondrial variants 追亞株。腫瘤演化研究常把它們跟表現資料配對

一句話總結

**腫瘤是生態系，單細胞把它拆開；
分析在 PC 空間，UMAP 只是投影；
惡性看基因體，病人是統計單位。**

三句話。Q2 的每一行程式碼、Q3 的每一個決定，都建立在這三句上。

自測 1

bulk RNA-seq 顯示腫瘤 A 的 CD8A 比腫瘤 B 高三倍。最保守的解讀？

A A 的 T 細胞更有攻擊性

B A 的 CD8 T 細胞比例可能較高，或每顆表現較高——bulk 分不開

C A 對免疫治療反應較好

答 B。組成改變 vs 內在改變在 bulk 裡長得一樣。A 與 C 都是過度詮釋，要單細胞資料（加上多位病人）才能往那個方向推。

自測 2

四位病人的 GBM 資料，UMAP 上惡性細胞分成四座島、巨噬細胞混成一群。這代表？

- A 有嚴重批次效應，要整合
- B 惡性細胞有四種亞型
- C 正常現象：惡性細胞帶病人特異的 CNV，正常細胞沒有

答 C。巨噬細胞混合得很好，證明技術批次不大；惡性細胞分島來自基因體差異。硬整合會把真實的病人差異抹掉。

自測 3

要證明某群細胞是惡性的，最有力的證據是？

A 高表現 EGFR、SOX2

B 整段染色體（如 chr7 增加、chr10 缺失）的表現一起偏移

C 在 UMAP 上離免疫細胞很遠

答 B。marker 只能說譜系，UMAP 距離沒有證據力；CNV 是基因體層級的證據，也是 inferCNV 的原理。

下一集

Q2：實作篇 I——單一樣本的標準流程

觀念有了，換手指。下一集用 10x 公開的 GBM 5k (5,604 顆細胞) 從讀檔一路做到註釋，附三支練習腳本，每一段程式碼都可以直接複製。