

Q2 Q 系列

實作篇 I：單一樣本的標準流程 從矩陣到細胞型別

以 10x 公開的 GBM 5k (5,604 顆) 為練習資料。從讀檔做到每一群有名字、惡性細胞有狀態分數。

約 55 分鐘 | 前置：Q1 | 腳本：R/00-03 | 深入：B1、B5-B10


55 分鐘後，你會有這張圖

這一集的終點：從編號到名字

示意／模擬資料

分群後：八個編號

註釋後：八個名字



編號是任意的（按群大小排），換個參數就重排；名字才是能寫進論文的东西

八群，每群有名字；惡性細胞標成「膠質 / 待 CNV」而不是硬稱腫瘤。而且每個參數你都答得出為什麼

這一集的規則

每段程式碼只講兩件事： 這行在做什麼、參數為什麼這樣設。

完整程式碼在三支練習腳本裡（R/01-03），每支結尾有練習題。右下角「深入：Bx」是 B 系列講透它的那一集。

這一集你會做到

- 1 把 GBM 5k 讀進 Seurat v5，用「這份資料的分布」定三條 QC 線，並標記 doublet
- 2 跑完 normalization → HVG → scaling → PCA → 分群 → UMAP，做三個保命檢查（PC1、nPC、每群 QC）
- 3 用門牌基因劃四塊大陸、用 marker + SingleR 掛名字、用 Neftel 基因集給惡性細胞打狀態分數

01

環境與資料

腳本 00：裝套件、下載資料、建專案

練習資料：一份真實的腫瘤樣本（GBM 5k）

練習資料：

Human Glioblastoma Multiforme 5k

來源	10x Genomics 公開資料集 (Chromium 3' v3)
組織	人類多形性膠質母細胞瘤 (GBM) 解離腫瘤組織
細胞數	5,604 顆 (Cell Ranger 4.0.0 判定)
檔案	filtered_feature_bc_matrix.tar.gz (≈30 MB)
為什麼選它	一份真實腫瘤：惡性、免疫、血管、正常腦細胞共存；筆電 5 分鐘跑完

它不能回答什麼

- ✗ 只有一位病人：任何「病人之間」的推論都不成立 (n=1)
- ✗ 沒有配對正常組織：惡性判定要靠內部參考（免疫、寡樹突細胞）
- ✗ 沒有臨床資料：不能連結治療反應或存活
- ➡ Q3 會換成 4 位病人的資料補上這些

先讀右邊：一份資料能回答什麼、不能回答什麼，比它有幾顆細胞重要

裝套件、鎖版本、設 seed

```
install.packages(c("Seurat", "dplyr", "ggplot2", "clustree"))
BiocManager::install(c("scDb1Finder", "SingleR", "cellidex"))
library(Seurat); library(dplyr); library(ggplot2)
stopifnot(packageVersion("Seurat") >= "5.0.0") # v4 教學碼在 v5 會炸
set.seed(1234) # 全系列固定
for (d in c("data", "R", "output")) dir.create(d, showWarnings = FALSE)
```

不用 setwd()、不用絕對路徑：開 RStudio Project，工作目錄就是專案根 | 腳本：00 | 深入：B1

下載、解壓、讀檔

```
url <- paste0("https://cf.10xgenomics.com/samples/cell-exp/4.0.0/",  
             "Parent_SC3v3_Human_Glioblastoma/",  
             "Parent_SC3v3_Human_Glioblastoma_filtered_",  
             "feature_bc_matrix.tar.gz")  
download.file(url, "data/gbm5k.tar.gz", mode = "wb") # 約 30 MB  
untar("data/gbm5k.tar.gz", exdir = "data/gbm5k")  
  
mtx.dir <- "data/gbm5k/filtered_feature_bc_matrix"  
gbm.data <- Read10X(data.dir = mtx.dir) # 吃資料夾  
gbm <- CreateSeuratObject(counts = gbm.data, project = "gbm5k",  
                          min.cells = 3, min.features = 200)
```

gbm

An object of class Seurat
~25,000 features across ~5,500 samples within 1 assay

min.cells / min.features 只是粗篩；真正的閾值下一段用分布決定。實際數字以你跑出來的為準 | 腳本：01 \$1

讀進來先摸一遍：維度、稀疏度、基因命名

```
dim(gbm) # 基因 × 細胞
cnt <- LayerData(gbm, layer = "counts")
1 - Matrix::nnzero(cnt) / prod(dim(cnt)) # 稀疏度：> 0.9 才正常
summary(Matrix::colSums(cnt)) # 每顆細胞的 UMI 總數
grep("^MT-", rownames(gbm), value = TRUE) # 人 MT-、鼠 mt-
head(grep("^RP[LS]", rownames(gbm), value = TRUE)) # 核糖體
cnt[c("PTPRC", "SOX2", "MBP"), 1:5] # 三個門牌基因
```

```
[1] 25xxx 55xx
[1] 0.93
  Min. 1st Qu. Median   Mean 3rd Qu.  Max.
  5xx    2xxx    4xxx    6xxx    8xxx   6xxxx
[1] "MT-ND1" "MT-ND2" "MT-CO1" ... (13 個)
```

三十秒的檢查，避免三個常見事故：物種弄錯（MT- vs mt-）、讀到 raw 矩陣（幾十萬欄）、基因用了 Ensembl ID | 腳本：01 \$1

raw、filtered、還有「湯」

Cell Ranger 給你兩個矩陣；我們讀 filtered，但 raw 還有一個用途

raw 矩陣



raw_feature_bc_matrix：所有 barcode（幾十萬欄），絕大多數是空液滴。空液滴裡的 RNA 就是背景「湯」的樣本

filtered 矩陣



filtered_feature_bc_matrix：Cell Ranger 用 EmptyDrops 判定為細胞的 barcode（本資料 5,604 顆）。這是我們讀的；還會混著 doublet 與壞細胞

環境 RNA



裂解細胞釋出的 mRNA 漂進每顆液滴：每顆細胞都混了一點別人的基因。壞死多、解離久的腫瘤特別嚴重


環境 RNA：怎麼看出來、怎麼扣掉

環境 RNA：矩陣裡每顆細胞都混了一點「湯」

示意／模擬資料

校正前：MBP

SoupX 校正後：MBP



每一顆細胞都有一點 MBP——不是寡
樹突細胞無所不在，
是裂解細胞的 mRNA 飄進了每顆液滴



背景被估計並扣除；
門牌基因回到只在該亮的地方亮

門牌基因到處都有一點 → 先估污染比例； ρ 超過 10% 就值得跑 SoupX (或 CellBender)，再進 QC

SoupX 在做什麼

- ① 用「空液滴」(raw 矩陣裡 UMI 很少的 barcode) 估計背景 (soup) 的基因組成
- ② 用一組「某型別絕不表現」的基因 (例如非寡樹突細胞的 MBP) 估計每顆細胞的污染比例 ρ
- ③ 依 ρ 從每顆細胞扣掉背景，回傳校正後的整數 counts

什麼時候一定要做：壞死多、解離久的腫瘤；
 $\rho > 10\%$ ；門牌基因 (PTPRC、MBP、HBB)
到處都有一點時

SoupX：估湯、扣湯（選做，腳本 01 §0）

```
library(SoupX)
sc <- load10X("data/gbm5k_outs/")           # 需 raw + filtered 同在
sc <- setClusters(sc, gbm$seurat_clusters)    # 先粗分群
sc <- autoEstCont(sc)                        # 估污染比例 rho
sc$fit$rhoEst                                # 例：0.06 → 可做可不做
adj <- adjustCounts(sc, roundToInt = TRUE)    # 校正後整數 counts
gbm <- CreateSeuratObject(adj, project = "gbm5k",
                           min.cells = 3, min.features = 200)
```

需要 raw 矩陣，所以 10x 官網只給 filtered 的資料集做不了；自己的資料一定要保留 raw。ρ < 5% 可以略過 | 深入：B5

02

QC：三條線，跟著資料走

先看分布，再定線；過濾前先存一份原始物件

三大指標，先看再砍


```
gbm[["percent.mt"]] <- PercentageFeatureSet(gbm, pattern = "^MT-")  
saveRDS(gbm, "output/gbm_raw.rds")      # 過濾前先存：截斷之後回不去  
  
VlnPlot(gbm, features = c("nFeature_RNA", "nCount_RNA", "percent.mt"),  
        ncol = 3, pt.size = 0.1)  
FeatureScatter(gbm, "nCount_RNA", "percent.mt")  
FeatureScatter(gbm, "nCount_RNA", "nFeature_RNA")
```

nCount 抓空滴與 doublet、nFeature 抓碎片、percent.mt 抓垂死細胞 | 腳本：01 §2 | 深入：B5

QC 分布：以腫瘤樣本為例

三大 QC 指標的分布（腫瘤樣本典型長相）

示意／模擬資料





腫瘤的 percent.mt 主體本來就比 PBMC 高（惡性細胞代謝旺盛），而且常有第二個峰。抄 5% 會砍掉一大塊活細胞

percent.mt 主體比 PBMC 高，而且常有第二個峰。那個峰是垂死細胞，線要畫在兩峰之間

兩張散點圖，三種壞細胞各佔一個角落

兩張散點圖交叉看：三種壞細胞各佔一個角落

示意／模擬資料



● 乾淨細胞

● 垂死／破損

● 空滴／碎片

● doublet

單一指標會誤判；兩兩配對看。右上角的 doublet 候選，等一下用專門工具確認

用 MAD 定三條線，再過濾

```
mad.hi <- function(x, k = 3) median(x) + k * mad(x)    # mad() 已含 1.4826
mad.lo <- function(x, k = 3) median(x) - k * mad(x)

mt.hi  <- mad.hi(gbm$percent.mt)                       # 例：≈ 12.8 (依你的資料)
nf.lo  <- 10^mad.lo(log10(gbm$nFeature_RNA))           # 在 log 尺度算下限
nc.hi  <- 10^mad.hi(log10(gbm$nCount_RNA))             # 在 log 尺度算上限
c(mt.hi = mt.hi, nf.lo = nf.lo, nc.hi = nc.hi)



gbm <- subset(gbm, subset = percent.mt < mt.hi &
              nFeature_RNA > nf.lo & nCount_RNA < nc.hi)
gbm                                     # 記下濾掉幾顆
```

nCount / nFeature 是對數常態，MAD 要在 log10 尺度算；percent.mt 直接算 | 腳本：01 §3

同一條規則，兩份資料，兩條不同的線

同一條規則，兩份資料給出不同的線——這就是它比「抄 5%」好的地方

示意／模擬資料



在 GBM 上照抄 5% 會砍掉一半的活細胞——而且砍掉的多半是代謝旺盛的惡性細胞

方法段可以直接抄

「細胞保留條件： $\text{percent.mt} < \text{中位數} + 3 \times \text{MAD} (= 12.8\%)$ 、
 nFeature 與 nCount 在 $\log_{10}$ 尺度中位數 $\pm 3 \times \text{MAD}$ 內；
5,604 顆中保留 N 顆。」

把 N 與三個數字填成你自己跑出來的。每條線都有數字、有理由。

doublet : 用 scDbfFinder 標記，先不刪

```
library(scDbfFinder)
sce <- scDbfFinder(as.SingleCellExperiment(gbm)) # dbr 自動估
gbm$dbl.score <- sce$scDbfFinder.score
gbm$dbl.class <- sce$scDbfFinder.class
table(gbm$dbl.class) # 例 : singlet ~5,000 / doublet ~300
```

singlet	doublet
5012	284

先標記、留在 metadata ; 分群後看「哪一群整群是 doublet」再決定 | 腳本 : 01 §4 | 深入 : B5


scDblFinder 在做什麼

doublet：指標抓不到的那種，要靠專門工具

示意／模擬資料

scDblFinder 的直覺

- ① 隨機挑兩顆細胞，把表現量相加 → 人造 doublet
- ② 把人造 doublet 丟回 PC 空間，看誰跟它們當鄰居
- ③ 鄰居裡人造 doublet 比例高的細胞 → 高 doublet 分數



腫瘤特有的風險：惡性 + 巨噬細胞的 doublet 會長得像「表現免疫基因的腫瘤細胞」。先標記，分群後再檢查整群 doublet 比例

腫瘤的 doublet 風險特別高：惡性 + 巨噬細胞黏在一起，會長得像「表現免疫基因的腫瘤細胞」

doublet 工具怎麼選、期望值是多少

裝載越多細胞，doublet 越多：10x 的經驗法則是每 1,000 顆約 0.8%

工具	原理	優點	要注意
scDbtFinder (本課)	人造 doublet + kNN 分類器；dbr 可指定期望率	快、穩、Bioconductor 維護；同型 doublet 也抓得到一部分	要先粗分群；多樣本時按樣本分開跑
DoubletFinder	人造 doublet + pANN 比例	Seurat 生態、文獻多	要自己給期望率與 pK；慢
Scrublet (Python)	同上，scanpy 內建	Python 流程預設	同型 doublet 幾乎抓不到
hashing / demuxlet	實驗端：抗體標籤或 SNP 分樣本	唯一能抓「同型」的方法；多病人混跑時免費得到	實驗設計時就要決定事後做不了

03

Normalize、HVG、Scale、PCA

腳本 02：四行程式碼、三個保命檢查

三個問題，三步解

問題一：深度不同

惡性細胞 RNA 多、T 細胞 RNA 少，
總分子數差 5-10 倍。直接比就是比深度

NormalizeData

每顆除以總量 $\times 1e4$ ，取 $\log_{1p}$

問題二：基因太多

3.6 萬個基因裡多數在
細胞間沒差異，只是雜訊

FindVariableFeatures

挑 2,000 個變異超出技術預期的基因

問題三：量級不等

MALAT1 上千、轉錄因子個位數。
不拉平，PCA 被大聲的基因綁架

ScaleData

每基因 z-score，clip ± 10

後面每一步都吃這一步的輸出：PCA 用的是 2,000 個 HVG 的 scale.data

惡性細胞的 RNA 總量常是 T 細胞的十倍——第一步就是把這個差異除掉

四行，每行一個目的；順手算週期分數

```
gbm <- NormalizeData(gbm) # CP10K + log1p : 除掉深度
gbm <- FindVariableFeatures(gbm, nfeatures = 2000) # 挑 2,000 個 HVG
head(VariableFeatures(gbm), 10) # 先看一眼名單

gbm <- CellCycleScoring(gbm, s.features = cc.genes.updated.2019$s.genes,
                        g2m.features = cc.genes.updated.2019$g2m.genes)
gbm <- ScaleData(gbm) # z-score、clip  $\pm 10$  (只做 HVG)
gbm <- RunPCA(gbm, npcs = 50) # 50 個 PC 先算存著
```

週期分數先算好，等一下看增殖細胞有沒有自成一群；本系列預設不 regress | 腳本：02 §1 | 深入：B6

LogNormalize 還是 SCTransform ?

兩者都對；本課用前者，因為每一步都看得見、也跟 pseudobulk 與 inferCNV 相容

LogNormalize (本課)

CP10K + log1p ; HVG 用 vst

- 簡單、快、可解釋；data 層直接拿來畫 FeaturePlot / DotPlot
- counts 層原封不動——pseudobulk、inferCNV、SoupX 都要它
- 深度差異極大時（惡性 vs T 細胞）殘留一點深度效應，用 PC1 檢查抓

SCTransform


負二項回歸，深度除得更乾淨

- HVG 挑得更穩，分群常更乾淨；v2 對深度差大的資料尤其好
- 多一個 SCT assay；FindMarkers 要先 PrepSCTFindMarkers；整合時各樣本要分開跑
- DE、CNV、pseudobulk 仍然回到 RNA 的 counts 層——別用 SCT 的值

HVG 名單本身就有生物學

HVG：從 3.6 萬個基因裡挑出 2,000 個有話要說的

示意／模擬資料



GBM 的 HVG 前幾名會是誰

- 惡性 vs 正常的差異基因 (EGFR、SOX2、PTPRZ1)
- 免疫基因 (CD74、HLA、CCL4)
- 寡樹突 (MBP、PLP1)、血管 (VWF)
- 這份名單本身就有生物學——先看一眼再往下

GBM 的前幾名會是惡性 vs 正常、免疫、寡樹突的基因。先看一眼，你已經知道資料裡有誰

保命檢查一：PC1 是生物學，不是深度

```
print(gbm[["pca"]], dims = 1:2, nfeatures = 6)
cor(Embeddings(gbm, "pca")[, 1], gbm$nCount_RNA) # |r| < 0.3 過關
```

PC_ 1

Positive: PTPRZ1, SOX2, BCAN, OLIG1, EGFR, GPM6B ← 膠質 / 惡性

Negative: PTPRC, CD74, HLA-DRA, C1QB, AIF1, TYROBP ← 免疫

[1] 0.07


GBM 的 PC1 幾乎一定是「免疫 vs 膠質」。接近 1 → 回去檢查 NormalizeData | 腳本：02 §2 | 深入：B7

PC1 與拐點

PCA：先看 PC1 是不是生物學，再決定取幾個

示意／模擬資料


PC1 = 免疫 vs 惡性／膠質這條軸



腫瘤結構複雜（多種型別 + 惡性狀態 + 病人差異），dims 建議 20-30，比 PBMC 的 10 多。取多一點比取少安全

腫瘤結構複雜，拐點通常比 PBMC 晚。dims 取 20-30；取多一點比取少安全

ElbowPlot：腫瘤資料拐點通常比 PBMC 晚



保命檢查二：取幾個 PC

```
ElbowPlot(gbm, ndims = 50)
pct <- gbm[["pca"]] $\text{@stdev}$  /  $\text{sum}(\text{gbm[["pca"]]\text{@stdev}}$ ) * 100
cumu <- cumsum(pct)
which(cumu > 90 & pct < 5)[1]      # 累積 90% 且單 PC < 5%
npc <- 25                          # GBM：三法交集約 20-30，取 25
```

把拐點變成數字，寫得進方法段。取太少會讓亞群消失，取太多只是多一點雜訊 | 腳本：02 \$2

週期分數要不要回歸掉？看兩件事再決定

腫瘤資料的增殖細胞是生物學；預設不回歸，除非它劫持了分群

不回歸（預設）

增殖細胞自成一群、其他群仍按型別分

- 檢查：DimPlot(group.by = "Phase") 只有一小塊是 S / G2M
- 檢查：PC1–PC5 的載荷裡沒有 MKI67、TOP2A 這類週期基因
- 處理方式：註釋時把那群標成「增殖中的 X」，不是新型別（雷三）

回歸（vars.to.regress）

每一型別都被週期切成兩半時

- ScaleData(vars.to.regress = c("S.Score", "G2M.Score"))，或只回歸 S – G2M 的差（保留「在不在分裂」）
- 代價：增殖本身的訊號消失；腫瘤研究常常正是要它
- 同樣的邏輯適用 percent.mt：只有它主導 PC 時才回歸

04

分群與 UMAP

分群在 PC 空間；resolution 掃一遍；分群後回頭做 QC


鄰居圖 → 社群 → 投影 → 掃描

```
gbm <- FindNeighbors(gbm, dims = 1:npc)           # PC 空間建 KNN/SNN 圖
gbm <- FindClusters(gbm, resolution = 0.5)        # 起點，不是答案
gbm <- RunUMAP(gbm, dims = 1:npc)                 # 同一組 dims

for (r in seq(0.2, 1.2, by = 0.2))
  gbm <- FindClusters(gbm, resolution = r, verbose = FALSE)
library(clustree); clustree(gbm, prefix = "RNA_snn_res.")
Idents(gbm) <- "RNA_snn_res.0.5"                  # 掃完指回定案欄位
DimPlot(gbm, label = TRUE)
```

掃描後 active identity 停在最後跑的那個——一定要指回來 | 腳本：02 §3 | 深入：B8、B9

clustree : 找穩定層



找「連續幾層結構不變」的穩定層；箭頭交叉、細胞來回流動的層退回去。多切的每一刀都要有 marker 支持

腫瘤資料在低 resolution 就會把免疫 / 膠質 / 寡樹突分開；再往下切的是惡性狀態與免疫亞群，每一刀都要 marker 支持

群穩不穩：換 seed、換 k、看群大小

1. 同一 resolution 換 seed: ARI 接近 1 才算穩

```
gbm <- FindClusters(gbm, resolution = 0.5, random.seed = 42, cluster.name = "seed42")  
mclust::adjustedRandIndex(gbm$RNA_snn_res.0.5, gbm$seed42) # 例: 0.9x
```

2. 換 k.param (預設 20) : 群的骨架不該因此改變

```
gbm <- FindNeighbors(gbm, dims = 1:20, k.param = 30)  
gbm <- FindClusters(gbm, resolution = 0.5, cluster.name = "k30")  
table(gbm$RNA_snn_res.0.5, gbm$k30) # 對角線清楚 = 穩
```

3. 群大小 : 小於 30 顆的群先存疑

```
sort(table(gbm$RNA_snn_res.0.5))
```

三個檢查十秒鐘。ARI < 0.8、或某群在換 k 後消失 → 那一刀不穩，用 marker 決定要不要留 | 腳本：02 \$3

保命檢查三：分群後回頭看每群的 QC 與 doublet

```
gbm@meta.data |>
  group_by(cluster = RNA_snn_res.0.5) |>
  summarise(n = n(), mt = median(percent.mt), nF = median(nFeature_RNA),
            dbl = mean(dbl.class == "doublet"), cyc = mean(Phase != "G1")) |>
  arrange(desc(dbl))
```

cluster	n	mt	nF	dbl	cyc	
7	142	6.1	3120	0.62	0.31	← 六成 doublet、卡在惡性與髓系之間 → 整群移除
3	410	5.4	2210	0.05	0.04	
...						

整群 doublet 比例過半、又卡在兩大群之間 → 整群移除並記錄；mt 一枝獨秀的群 → 回 QC 修線 | 腳本：02 \$4

05

註釋：四塊大陸，然後亞群

腳本 03：門牌基因 → marker → SingleR → 狀態分數

先用四個門牌基因劃大陸

FeaturePlot：先用四張「門牌」基因劃大陸塊


示意／模擬資料

PTPRC

SOX2

MBP

PECAM1



免疫（PTPRC）、膠質／惡性（SOX2）、寡樹突（MBP）、血管（PECAM1）——四塊劃清楚，再進入亞群

免疫（PTPRC）、膠質／惡性（SOX2）、寡樹突（MBP）、血管（PECAM1）。四塊劃清楚，再進亞群

門牌基因與 marker 面板

```
FeaturePlot(gbm, features = c("PTPRC", "SOX2", "MBP", "PECAM1"), ncol = 4)

panel <- c("PTPRC", "CD68", "CD163", "P2RY12", "TMEM119", "CD3E",    # 免疫
          "SOX2", "OLIG2", "PTPRZ1", "EGFR",                        # 膠質 / 惡性
          "MBP", "PLP1", "PECAM1", "VWF", "PDGFRB", "RGS5",        # 寡樹突 / 血管 / 周細胞
          "MKI67", "TOP2A")                                         # 週期
DotPlot(gbm, features = panel) + RotatedAxis()
```

沿對角線一塊塊亮起來就是好的分群；PTPRC 亮在三種免疫細胞是正常的 | 腳本：03 §1 | 深入：B10

GBM 微環境的 marker 面板

GBM 腫瘤微環境的 marker 面板

族群	經典 marker	一句話
● 免疫大陸	PTPRC (CD45)	所有免疫細胞的門牌
● 巨噬細胞	CD68, CD163, C1QB, AIF1	腫瘤相關巨噬細胞 (TAM)，GBM 裡最多的免疫細胞
● 小膠質細胞	P2RY12, TMEM119, CX3CR1	腦內駐留的巨噬細胞；與血液來源的 TAM 區分
● T 細胞	CD3E, CD3D, CD2 (+CD8A / IL7R)	GBM 是「免疫冷」腫瘤，T 細胞通常很少
● 惡性 / 膠質	SOX2, OLIG2, PTPRZ1, EGFR	marker 只能說「膠質譜系」；惡性要靠 CNV 判定 (Q3)
● 寡樹突細胞	MBP, PLP1, MOG	被浸潤的正常白質；inferCNV 的好參考
● 血管內皮	PECAM1, VWF, CLDN5	GBM 血管增生明顯
● 周細胞	PDGFRB, RGS5, ACTA2	血管周圍的基質細胞
● 增殖中	MKI67, TOP2A	不是型別，是狀態；會疊在惡性細胞上

小膠質 vs 血液來源巨噬細胞、增殖狀態 vs 型別——這兩組是腫瘤註釋最常搞混的

每群的證人：FindAllMarkers

```
markers <- FindAllMarkers(gbm, only.pos = TRUE,  
                           min.pct = 0.25, logfc.threshold = 0.5)  
markers |> group_by(cluster) |> slice_max(avg_log2FC, n = 5) |>  
  select(cluster, gene, avg_log2FC, pct.1, pct.2) |> print(n = 50)
```

cluster	gene	avg_log2FC	pct.1	pct.2	
2	C1QB	高	~0.95	~0.05	← 巨噬細胞
4	MBP	高	~0.98	~0.08	← 寡樹突
0	PTPRZ1	高	~0.9	~0.2	← 膠質 (惡性待 CNV)

看表順序：avg_log2FC → pct.1 / pct.2 → p。pct.2 接近 0 才是乾淨的 marker | 腳本：03 \$2

marker 表怎麼篩：四個欄位、四個問題

p 值最後看——五千顆細胞幾乎什麼都顯著

欄位	它回答	好的 marker	陷阱
avg_log2FC	這群比其他群高多少	> 1 (兩倍以上)	低表現基因的 FC 會被 pseudocount 壓小
pct.1	這群裡多少比例表現	> 0.5	pct.1 = 0.3 的「marker」只描述群的一部分——可能藏著亞群或 doublet
pct.2	其他群裡多少比例表現	< 0.1	環境 RNA 會把 pct.2 抬高；MBP 的 pct.2 = 0.3 不代表寡樹突到處都是
p_val_adj	差異是不是偶然	< 0.05 (幾乎都是)	同群細胞不是獨立觀察值，p 值被高估幾個量級——只當篩子

第二證人：SingleR

```
library(SingleR); library(cellidex)
ref <- cellidex::HumanPrimaryCellAtlasData()
pred <- SingleR(test = GetAssayData(gbm, layer = "data"), ref = ref,
               labels = ref$label.main, clusters = gbm$RNA_snn_res.0.5)
data.frame(cluster = rownames(pred), SingleR = pred$labels)
```

cluster	SingleR	
0	Astrocyte	← 參考集裡沒有「GBM 惡性細胞」，被塞成最像的正常型別
2	Macrophage	
4	Oligodendrocytes	
5	Endothelial_cells	

免疫、寡樹突、血管很準；惡性細胞會被標成星狀或神經前驅——那不是答案，是提醒 | 腳本：03 §3

自動註釋的定位（以腫瘤資料為例）

自動註釋（SingleR/ Azimuth）在腫瘤資料的定位

- ✓ 免疫細胞：很準。
參考集（HPCA、Blueprint）涵蓋完整
- ✓ 寡樹突、內皮：準
- ✗ 惡性細胞：參考集裡沒有「GBM 惡性細胞」，會被硬塞成最像的正常型別（astrocyte、neural progenitor）
- 結論：自動註釋當第二證人；惡性判定另外做

交叉驗證表（範例）

群	手動 marker	SingleR	裁決
2	巨噬細胞	Macrophage	✓
3	T 細胞	T_cells	✓
4	寡樹突	Oligodendrocyte	✓
0	惡性 AC 樣	Astrocyte	CNV 決定
1	惡性 OPC 樣	Neural progenitor	CNV 決定
5	內皮	Endothelial	✓

三欄交叉驗證：一致的群直接過；膠質群的裁決留給 CNV（Q3）

註釋策略總覽：四條路，通常一起走

沒有一條路單獨可靠；本課的順序是 門牌 → marker → 自動參考 → 分數

策略	怎麼做	強項	弱項	工具
手動 marker	每群看 dotplot / FeaturePlot，對照文獻 marker	可解釋、能發現新型別	慢、主觀、依賴分群	Seurat
參考集分類	每顆細胞或每群與已註釋參考比相關	快、可重現；正常型別準	參考集沒有的型別（腫瘤）會被塞成最像的	SingleR, scType, CellTypist
基因集打分數	一組基因的平均 / AUC 當一個分數	連續、跨研究可比 適合「狀態」	分數高不等於型別；門檻主觀	AddModuleScore, UCell, AUCell
圖譜投影	把細胞投到大型參考圖譜，繼承標籤	亞群最細、標籤一致	需要好的圖譜 惡性細胞投不上去	Azimuth, scArches

自動註釋工具怎麼選

同一份 GBM 資料跑三種，正常型別的一致率通常 > 90%；不一致的地方就是要人看的地方

工具	原理	參考	單位	適合 / 注意
SingleR (本課)	Spearman 相關 + 微調	celldex (HPCA、Blueprint、Monaco 免疫)	細胞或群	正常型別的預設選擇；換免疫專用參考可分 T 亞群
scType	marker 資料庫 + 群層級打分	內建人 / 鼠組織 marker 表	群	十秒出結果；腦組織的表不含腫瘤
CellTypist	邏輯迴歸模型	免疫圖譜、人體多組織	細胞	免疫亞群最強 (Python)
Azimuth	錨點投影到參考 UMAP	PBMC、人腦、肺腎、骨髓...	細胞	附帶 UMAP 座標；人腦參考對 GBM 的惡性細胞無效
scANVI / scArches	半監督深度模型	任何你訓練的圖譜	細胞	跨技術、大型；要 GPU

掛名字：暫時的、誠實的

```
new.ids <- c("0" = "Glial (CNV pending)", "1" = "Glial (CNV pending)",  
            "2" = "Macrophage", "3" = "Microglia", "4" = "Oligodendrocyte",  
            "5" = "Endothelial", "6" = "Pericyte", "8" = "T cell")  
gbm <- subset(gbm, idents = "7", invert = TRUE) # 移除 doublet 群  
gbm <- RenameIdents(gbm, new.ids)  
gbm$celltype <- Idents(gbm) # 存進 metadata  
DimPlot(gbm, label = TRUE, repel = TRUE) + NoLegend()
```


對照你自己的 DotPlot 再掛；編號與名字的對應每份資料都不同 | 腳本：03 \$4

層級式註釋：大陸定了，再進亞群


層級式註釋：先大陸，再亞群，每一層都重新降維

示意／模擬資料

第一層：四塊大陸



第二層：免疫亞群（只用免疫細胞重算）



為什麼要重算

- 1 全體的 HVG 被「惡性 vs 免疫」佔滿，免疫內部的差異排不進前 2,000
- 2 PCA 的前幾軸也一樣——亞群的訊號在第 20 軸之後
- 3 只留免疫細胞重跑，T 細胞的 CD4/CD8、TAM 的來源才分得開

免疫大陸單獨拿出來重跑 HVG、PCA、分群，CD4 / CD8、小膠質 / 血液來源巨噬細胞才分得開。惡性大陸的「亞群」用狀態分數，不用分群

亞群：subset 之後整條流程重跑一次


```
imm <- subset(gbm, celltype %in% c("Macrophage", "Microglia", "T cell"))
imm <- NormalizeData(imm) |> FindVariableFeatures(nfeatures = 2000) |>
  ScaleData() |> RunPCA(npcs = 30)
ElbowPlot(imm) # 亞群通常 15-20 個 PC 就夠
imm <- FindNeighbors(imm, dims = 1:20) |> FindClusters(resolution = 0.6) |>
  RunUMAP(dims = 1:20)
imm.panel <- c("P2RY12", "TMEM119", "CX3CR1", # 小膠質
  "CD163", "LYZ", "TGFB1", "S100A8", "VCAN", # 血液來源 TAM / 單核球
  "CD3E", "CD8A", "GZMK", "CD4", "IL7R", "FOXP3",
  "PDCD1", "HAVCR2", "NKG7", "GNLY", "CD1C", "MKI67")
DotPlot(imm, features = imm.panel) + RotatedAxis()
# 只想切某一群、不重跑：FindSubCluster(gbm, cluster = "2", graph.name = "RNA_snn")
```

subset 之後一定重算 HVG 與 PCA；直接在舊的 UMAP 上圈是常見錯誤。單細胞數 < 200 的亞群不要再切 | 腳本：03 \$4b

免疫亞群面板：對角線就是證據

亞群註釋：一張 dotplot 對角線就是證據
免疫亞群 marker 面板 (GBM)

示意／模擬資料



怎麼讀

PTPRC 一整欄都亮：
門牌，不是亞群 marker

小膠質 vs 血液來源 TAM：
P2RY12/TMEM119 對
CD163/TGFB1

耗竭 T 是 CD8+
PDCD1/HAVCR2，
不是新型別

增殖免疫只有 MKI67
亮：狀態，併回原型別

小膠質 vs 血液來源 TAM、CD8 vs 耗竭 CD8、Treg——每一刀都要有自己的 marker；只有 MKI67 亮的群是狀態，併回去

惡性細胞的狀態分數 (Neftel 2019)


```
neftel <- list(                                     # 每組取前 8 個示範
  MES = c("CHI3L1", "ANXA2", "ANXA1", "CD44", "VIM", "MT2A"),
  AC  = c("CST3", "S100B", "SLC1A3", "HOPX", "MT3", "SPARCL1"),
  OPC = c("BCAN", "PLP1", "GPR17", "FIBIN", "LHFPL3", "OLIG1"),
  NPC = c("DLL3", "DLL1", "SOX4", "TUBB3", "HES6", "TAGLN3"))
glial <- subset(gbm, idents = "Glial (CNV pending)")
glial <- AddModuleScore(glial, features = neftel, name = names(neftel))
FeaturePlot(glial, features = paste0(names(neftel), 1:4), ncol = 4)
```

完整基因集請用論文附表 (每組 50 個基因) ; 這裡各取前 8 個示範 | 腳本 : 03 §5 | 深入 : B13

為什麼是「打分數」而不是再分一次群

示意／模擬資料

惡性細胞的四種狀態 (Neftel 2019 基因集, AddModuleScore)



為什麼要算「狀態分數」而不是再分一次群

- 惡性細胞的狀態是連續的，硬切成群會製造假邊界
- 用已發表的基因集打分數，結果可以跨研究比較
- 同一位病人的腫瘤同時含四種狀態——這是治療抗性的來源之一
- 週期分數 (G2M/S) 要一起算，否則增殖細胞會自成一類

惡性狀態是連續的；打分數保留連續性，也能跨研究比較。週期分數要一起看

打分數的三種算法：AddModuleScore、UCell、AUCell

```
# 1. AddModuleScore ( Seurat ) : 基因集平均 - 表現量相近的對照基因平均。快，但受深度影響
glial <- AddModuleScore(glial, features = nefte1, name = names(nefte1))

# 2. UCell : 以基因在每顆細胞內的「排名」算 Mann-Whitney U 分數，對深度與稀疏穩健
library(UCell)
glial <- AddModuleScore_UCell(glial, features = nefte1, name = "_UCell")

# 3. AUCell : 每顆細胞的基因排名前 5% 裡有多少基因集成員 ( AUC ) ; SCENIC 也用它
library(AUCell)
rank <- AUCell_buildRankings(LayerData(glial, layer = "counts"))
auc <- AUCell_calcAUC(nefte1, rank)



FeaturePlot(glial, features = paste0(names(nefte1), "_UCell"), ncol = 4)
cor(glial$MES1, glial$MES1_UCell) # 三種算法的排序通常高度一致
```

狀態分數要報告算法與基因集來源；三種算法結論不一致時，相信 UCell (最不受深度影響) | 腳本：03 \$5

註釋的品質檢查：交叉表與 marker 熱圖

註釋做完要交兩張證據：交叉表與 marker 熱圖

示意／模擬資料



左：對角線清楚、惡性被拆到星狀／神經前驅是預期（參考集沒有腫瘤）；右：對角線區塊一塊塊亮起來、沒有一群「什麼都亮」

左：手動 vs 自動的對角線清楚，偏離處都解釋得了；右：每群 top marker 一塊塊亮、沒有一群什麼都亮。這兩張放補充圖

品質檢查的程式碼：交叉表、熱圖、分群樹、輪廓係數

```
# 交叉表：手動標籤 vs SingleR ( 每列加總為 1 )
round(prop.table(table(gbm$celltype, gbm$singler), 1), 2)

# 每群 top 5 marker 熱圖 ( 每群最多抽 100 顆，否則圖太重 )
top5 <- markers |> group_by(cluster) |> slice_max(avg_log2FC, n = 5)
DoHeatmap(subset(gbm, downsample = 100), features = top5$gene, group.by = "celltype")

# 分群樹：型別之間的相似結構是否合理 ( 免疫一支、膠質一支 )
gbm <- BuildClusterTree(gbm, dims = 1:20); PlotClusterTree(gbm)

# 輪廓係數：每群在 PC 空間裡有多「自成一格」 ( < 0.1 的群要存疑 )
library(cluster)
sil <- silhouette(as.integer(Ids(gbm)), dist(Embeddings(gbm, "pca")[, 1:20]))
tapply(sil[, "sil_width"], Ids(gbm), mean)
```

四個檢查各回答一個問題：自動同不同意、marker 乾不乾淨、結構合不合理、群分不分得開 | 腳本：03 \$5b

命名規範：三層標籤都存進 metadata

論文用第二層，補充表用第三層，統計檢定常常只用第一層

欄位	內容	例	規則
celltype_l1	大陸	Immune / Malignant / Oligo / Vascular / Stromal	五到七個；組成分析用它
celltype_l2	型別	Microglia、Blood-derived TAM CD8 T、Malignant (CNV)	每個都有 ≥ 2 個 marker 支持；名字對齊 Cell Ontology
celltype_l3	狀態 / 亞群	Exhausted CD8 T、Cycling TAM 、MES-like	狀態用「形容詞 + 型別」，不要發明新名詞
celltype_conf	信心	high / medium / unresolved	不確定的誠實寫 unresolved，不要硬塞

常見的誤註釋：五種「新型別」其實是什麼

看起來像	其實是	怎麼抓	怎麼處理
表現免疫基因的腫瘤細胞	惡性 + 巨噬細胞 doublet	整群 dbl 比例高、nCount 偏高、卡在兩大群之間	整群移除並記錄
幹細胞樣亞群	增殖中的既有型別	marker 只有 MKI67 / TOP2A ; Phase 幾乎全是 S/G2M	併回原型別，加「cycling」
壓力反應亞群	解離假象	FOS / JUN / HSPA1A 高；散在每一型別裡各一撮	回歸或註明；不當生物學
低分化 / 未知型別	低品質細胞	nFeature 最低、mt 最高、marker 什麼都不亮	回 QC 修線
表現寡樹突基因的免疫細胞	環境 RNA	MBP / PLP1 在所有群都有一點 pct.2 偏高	SoupX 後重跑

交付：論文 Figure 1 的三張圖與一張表

```
p1 <- DimPlot(gbm, group.by = "celltype", label = TRUE,
              repel = TRUE) + NoLegend()
p2 <- DotPlot(gbm, features = panel, group.by = "celltype") + RotatedAxis()
p3 <- VlnPlot(gbm, features = c("nFeature_RNA", "percent.mt"),
              group.by = "celltype", pt.size = 0, ncol = 2)
(p1 | p2) / p3 # patchwork 排版
ggsave("output/figs/03_fig1_annotation.pdf", width = 14, height = 9, bg = "white")

comp <- gbm@meta.data |> dplyr::count(celltype) |>
  mutate(pct = round(100 * n / sum(n), 1))
write.csv(comp, "output/03_composition.csv", row.names = FALSE)
```

celltype	n	pct
Malignant (glial, CNV pending)	3xxx	6x.x
Macrophage / microglia	1xxx	2x.x
Oligodendrocyte	3xx	x.x
...		

UMAP 給位置、dotplot 給證據、violin 給 QC 一致性、表給數字。四樣一起交，審稿人的第一輪問題少一半 | 腳本：03 §6

收工：存物件、記版本

```
saveRDS(gbm, "output/gbm_annotated.rds")  
write.csv(markers, "output/03_markers.csv", row.names = FALSE)  
sessionInfo() # 收進附錄；審稿人的好朋友
```

output/ 裡的每一個檔案都能從 R/ 的腳本重生——這就是可重現 | 腳本：03 \$6

06

踩雷區

三個腫瘤資料最常見的實作雷



雷一：percent.mt 照抄 5%

雷是什麼

用 PBMC 教學的 5% 直接套在 GBM 上。



為什麼會踩

每份教學都用 PBMC，5% 看起來像常識。

踩了會怎樣

砍掉一半活細胞，而且砍掉的多半是代謝旺盛的惡性細胞。剩下的資料裡免疫細胞比例被灌大，之後的組成分析全歪。

雷二：doublet 群當成「免疫樣腫瘤細胞」

雷是什麼

一群同時表現 SOX2 與 CD74 的細胞，寫成「具抗原呈現能力的惡性亞群」。



為什麼會踩

marker 看起來很有趣，也有文獻可以引。

踩了會怎樣

整群六成是 scDblFinder 標的 doublet，又剛好卡在惡性與髓系之間。保命檢查三就是為了抓這個。

雷三：增殖細胞當成新型別

雷是什麼

一群 MKI67、TOP2A 高的細胞自成一島，被命名為「幹細胞樣亞群」。



為什麼會踩

週期基因訊號很強，容易主導分群。

踩了會怎樣

那是狀態不是型別：裡面混著正在分裂的惡性細胞與巨噬細胞。先看 Phase 欄位，再決定要不要 regress。

Q2 checklist

Q2 checklist：九格全勾，物件才能進 Q3



原始物件在過濾前存了一份



三條 QC 線各有數字與理由 (MAD)



doublet 分數在 metadata 裡



PC1 與 nCount 的
相關 $|r| < 0.3$



dims 有依據 (拐點
+ 量化 cutoff)



resolution 掃過，
穩定層有 marker 支持



四塊大陸用門牌基因劃清楚



每群名字有兩個證人
(marker+自動註釋)



惡性標籤暫時標「膠質／待 CNV」

九格全勾，物件才能進 Q3

一句話總結

**每個參數是一個假設：有數字、有理由、有紀錄。
惡性標籤先誠實地寫「待 CNV」。**

做到這些，你的流程可重現、可辯護。Q3 把「待 CNV」補上。

自測 1

GBM 資料 percent.mt 中位數 7%、 $\text{median} + 3 \times \text{MAD} = 13\%$ 。閾值該怎麼定？

- A 照慣例 5%
- B 13%，並把數字與理由寫進方法段
- C 不過濾 percent.mt

答 B。閾值是資料的性質。5% 會砍掉大半活細胞；不過濾則會留下第二個峰的垂死細胞。

自測 2

某群同時高表現 SOX2 與 C1QB，scDbtFinder 標記其中 65% 為 doublet。
該怎麼處理？

A 這是有趣的新亞群，寫進結果

B 整群移除並記錄理由

C 只移除被標記的 65%

答 B。過半被標記、又卡在兩大群之間，整群就是 doublet 的產物；剩下的 35% 是工具沒抓到的，不是真細胞。

自測 3

SingleR 把 0 號群標成 Astrocyte，marker 是 SOX2 / PTPRZ1 / EGFR。
最誠實的標籤？

A Astrocyte

B Malignant

C Glial (惡性待 CNV 判定)

答 C。參考集裡沒有 GBM 惡性細胞，SingleR 只能塞最像的；marker 只說譜系。惡性要 CNV 證據，Q3 補上。

下一集

Q3：實作篇 II——多樣本分析

換成 4 位病人、核心 vs 邊緣的 GBM 資料 (GSE84465)。inferCNV 把「待 CNV」補上，pseudobulk 讓 DE 以病人為單位，最後給你一張下游選路表。