

Q 系列 Q2

實作篇 I：單一樣本標準流程 從原始矩陣到細胞註釋

以 10x 公開的 GBM 5k（5,604 顆）為練習資料。從讀檔做到每一群有名字、惡性細胞有狀態分數。

約 55 分鐘 | 前置：Q1 | 腳本：R/00-03 | 深入：B1、B5-B10




[https://github.com/
Charlene717/scRNA-seq-
tutorial-Qseries](https://github.com/Charlene717/scRNA-seq-tutorial-Qseries)


本集成果預覽

這一集的終點：從編號到名字

分群後：13 個編號



註釋後：7 個名字



13 群不等於 13 種細胞：四群都是膠質、三群都是巨噬細胞，還有一群是 doublet 被整群移除。編號會隨參數重排，名字才是能寫進論文的东西

13 個編號、7 個名字：四群都是膠質、三群都是巨噬細胞，一群 doublet 整群移除。
惡性細胞標為「膠質 (待判定)」而非逕稱腫瘤

這一集的規則

每段程式碼只講兩件事： 這行在做什麼、參數為什麼這樣設。

完整程式碼在三支練習腳本裡（R/01-03），每支結尾有練習題。右下角「深入：Bx」是 B 系列講透它的那一集。

本集目標

- 1 把 GBM 5k 讀進 Seurat v5 ，用「這份資料的分布」定三條 QC 線，並標記 doublet
- 2 跑完 normalization → HVG → scaling → PCA → 分群 → UMAP ，做三個必要檢查（ PC1 、 nPC 、 每群 QC ）
- 3 用譜系標誌基因劃四個主要類群、用 marker + SingleR 命名、用 Neftel 基因集給惡性細胞打狀態分數

01

環境與資料

腳本 00：裝套件、下載資料、建專案

練習資料：一份真實的腫瘤樣本（GBM 5k）

練習資料：Human Glioblastoma Multiforme 5k

來源	10x Genomics 公開資料集 (Chromium 3' v3)
組織	人類膠質母細胞瘤 (GBM) 解離後的腫瘤組織
細胞數	5,604 顆 (Cell Ranger 4.0.0 判定)
檔案	filtered_feature_bc_matrix.tar.gz ($\approx$ 30 MB)
為什麼選它	一份真實腫瘤：惡性、免疫、血管、 正常腦細胞共存；筆電 5 分鐘跑完

它不能回答什麼

- ✗ 只有一位病人：任何「病人之間」的推論都不成立 ($n=1$)
- ✗ 沒有配對正常組織：惡性判定要靠內部參考（免疫、寡樹突細胞）
- ✗ 沒有臨床資料：不能連結治療反應或存活
- ➡ Q3 會換成 4 位病人的資料補上這些

先讀右邊：一份資料能回答什麼、不能回答什麼，比它有幾顆細胞重要

裝套件、鎖版本、設 seed

```
install.packages(c("Seurat", "dplyr", "ggplot2", "clustree"))
BiocManager::install(c("SingleR", "celldex", "scDbFinder"))
remotes::install_github("chris-mcginnis-ucsf/DoubletFinder") # 只在 GitHub
library(Seurat); library(dplyr); library(ggplot2)
stopifnot(packageVersion("Seurat") >= "5.0.0") # v4 教學碼在 v5 會炸
set.seed(1234) # 全系列固定
for (d in c("data", "R", "output")) dir.create(d, showWarnings = FALSE)
```

不用 setwd()、不用絕對路徑：開 RStudio Project，工作目錄就是專案根 | 腳本：00 | 深入：B1

下載、解壓、讀檔

```
url<-paste0("https://cf.10xgenomics.com/samples/cell-exp/4.0.0/",
            "Parent_SC3v3_Human_Globlastoma/",
            "Parent_SC3v3_Human_Globlastoma_filtered_",
            "feature_bc_matrix.targz")
download.file(url,"data/gbm5k.targz",mode="wb") # 約 30 MB
untar("data/gbm5k.targz",exdir="data/gbm5k")

mtx.dir<- "data/gbm5k/filtered_feature_bc_matrix"
gbm.data<-Read10X(data.dir=mtx.dir) # 吃資料夾
gbm<-CreateSeuratObject(counts=gbm.data,project="gbm5k",
                        min.cells=3,min.features=200)
gbm
```

An object of class Seurat

~ 25,000 features across ~ 5,500 samples within 1 assay

min.cells / min.features 只是粗篩；真正的閾值下一段用分布決定。實際數字以我們自己跑出來的為準 | 腳本：01 §1

載入後的初步檢查：維度、稀疏度、基因命名

```
dim(gbm)           # 基因 × 細胞
cnt <- LayerData(gbm, layer = "counts")
1 - Matrix::nnzero(cnt) / prod(dim(cnt)) # 稀疏度：> 0.85 才正常
sum(mapply(Matrix::colSums(cnt)))        # 每顆細胞的 UMI 總數
grep("^MT-", rownames(gbm), value = TRUE) # 人 MT-、鼠 mt-
head(grep("^RP[LS]", rownames(gbm), value = TRUE)) # 核糖體
cnt[intersect(c("PTPRC", "SOX2", "MBP"), rownames(cnt)), 1:5] # 三個譜系標誌基因
```

```
[1] 25xxx 55xx
[1] 0.86
  Min. 1st Qu. Median   Mean 3rd Qu.  Max.
  5xx   2xxx   4xxx   6xxx   8xxx  6xxxx
[1] "MT-ND1" "MT-ND2" "MT-CO1" ... (13 個)
```

三十秒的檢查，避免三個常見事故：物種弄錯（MT- vs mt-）、讀到 raw 矩陣（幾十萬欄）、基因用了 Ensembl ID | 腳本：01 §1

raw、filtered 與環境 RNA

Cell Ranger 給了我們兩個矩陣；我們讀 filtered，但 raw 還有一個用途

raw 矩陣



raw_feature_bc_matrix：所有 Barcode（幾十萬欄），絕大多數是空液滴。空液滴裡的 RNA 就是背景「湯」的樣本

filtered 矩陣



filtered_feature_bc_matrix：Cell Ranger 用 EmptyDrops 判定為細胞的 Barcode（本資料 5,604 顆）。這是我們讀的；還會混著 doublet 與壞細胞

環境 RNA



裂解細胞釋出的 mRNA 漂進每顆液滴：每顆細胞都混了一點別人的基因。壞死多、解離久的腫瘤特別嚴重


環境 RNA：怎麼看出來、怎麼扣掉

環境 RNA：矩陣裡每顆細胞都混了一點「湯」

示意／模擬資料

校正前：MBP

SoupX 校正後：MBP



每一顆細胞都有一點 MBP——不是寡樹突細胞無所不在，是裂解細胞的 mRNA 飄進了每顆液滴



背景被估計並扣除；譜系標誌基因回到只在該亮的地方亮

SoupX 在做什麼

- ① 用「空液滴」（raw 矩陣裡 UMI 很少的 Barcode）估計背景（soup）的基因組成
- ② 用一組「某型別絕不表現」的基因（例如非寡樹突細胞的 MBP）估計每顆細胞的污染比例 ρ
- ③ 依 ρ 從每顆細胞扣掉背景，回傳校正後的整數 counts

什麼時候一定要做：壞死多、解離久的腫瘤； $\rho > 10\%$ ；譜系標誌基因（PTPRC、MBP、HBB）到處都有一點時

譜系標誌基因到處都有一點 → 先估污染比例； ρ 超過 10% 就值得跑 SoupX（或 CellBender），再進 QC

SoupX：估計並校正環境 RNA（選做，腳本 01 §0）

```
library(SoupX)
sc <- load10X("data/gbm_5k_outs/")      # 需 raw + filtered 同在
sc <- setClusters(sc, gbm$seurat_clusters) # 先粗分群
sc <- autoEstCont(sc)                   # 估污染比例 rho
sc$fit$rhoEst                           # 例：0.06 → 可做可不做
adj <- adjustCounts(sc, roundToInt = TRUE) # 校正後整數 counts
gbm <- CreateSeuratObject(adj, project = "gbm_5k",
                           min.cells = 3, min.features = 200)
```

需要 raw 矩陣，所以 10x 官網只給 filtered 的資料集做不了；自己的資料一定要保留 raw。 $p < 5\%$ 可以略過 | 深入：B5

文獻：Young MD, Behjati S. Gigascience. 2020;9(12):giaa151. doi:10.1093/gigascience/giaa151

02

品質管制：依資料分布設定三項閾值

先看分布，再定線；過濾前先存一份原始物件


三項 QC 指標：先檢視分布，再過濾

```
gbm[["percent.mt"]] <- PercentageFeatureSet(gbm, pattern = "^MT-")  
saveRDS(gbm, "output/rds/01_gbm_raw.rds") # 過濾前先存：截斷之後回不去  
  
VlnPlot(gbm, features = c("nFeature_RNA", "nCount_RNA", "percent.mt"),  
        ncol = 3, pt.size = 0.05)  
FeatureScatter(gbm, "nCount_RNA", "percent.mt")  
FeatureScatter(gbm, "nCount_RNA", "nFeature_RNA")
```

nCount 抓空滴與 doublet、nFeature 抓碎片、percent.mt 抓垂死細胞 | 腳本：01 §2 | 深入：B5

QC 分布：以腫瘤樣本為例

示意／模擬資料





腫瘤的 percent.mt 主體本來就比 PBMC 高（惡性細胞代謝旺盛），而且常有第二個峰。抄 5% 會砍掉一大塊活細胞

percent.mt 主體比 PBMC 高，而且常有第二個峰。那個峰是垂死細胞，線要畫在兩峰之間

QC 散點圖：三類低品質細胞的位置

兩張散點圖交叉看：三種壞細胞各佔一個角落

示意／模擬資料



● 乾淨細胞

● 垂死／破損

● 空滴／碎片

● doublet

單一指標會誤判；兩兩配對看。右上角的 doublet 候選，等一下用專門工具確認

以 MAD 設定動態閾值後過濾

```
m.ad.hi <- function(x, k = 3) m.edian(x) + k * m.ad(x) # m.ad() 已含 1.4826
m.ad.lo <- function(x, k = 3) m.edian(x) - k * m.ad(x)

m.thi <- m.ad.hi(gbm$percent.mt) # 這份資料實跑 = 13.1
nf.lo <- 10^m.ad.lo(log10(gbm$nFeature_RNA)) # 在 log 尺度算下限
nc.hi <- 10^m.ad.hi(log10(gbm$nCount_RNA)) # 在 log 尺度算上限
c(m.thi = m.thi, nf.lo = nf.lo, nc.hi = nc.hi)



gbm <- subset(gbm, subset = percent.mt < m.thi &
              nFeature_RNA > nf.lo & nCount_RNA < nc.hi)
gbm # 記下濾掉幾顆
```

nCount / nFeature 是對數常態，MAD 要在 log10 尺度算；percent.mt 直接算 | 腳本：01 §3

文獻：Amezquita RA, et al. Nat Methods. 2020;17(2):137-145. doi:10.1038/s41592-019-0654-x

同一條規則，兩份資料，兩條不同的線

示意／模擬資料



在 GBM 上照抄 5% 會砍掉一半的活細胞——而且砍掉的多半是代謝旺盛的惡性細胞

方法段可以直接抄

「細胞保留條件：

**percent.mt < 中位數 + 3×MAD (13.1%) ;
nFeature / nCount 於 log10 尺度取中位數 ±3×MAD ;
5,506 顆中保留 5,261 顆。」**

原始 5,604 個 barcode 先被 min.features = 200 濾掉 98 顆，MAD
三條線是從 5,506 顆開始算的。換自己的資料時三個數字都要重算。

doublet：用 DoubletFinder 標記，先不刪

```
library(DoubletFinder)
# DoubletFinder 在 PC 空間找鄰居 → 先做一份暫時物件（正式分群在 02）
tm.p <- NormalizeData(gbm) |> FindVariableFeatures(nfeatures = 2000) |> ScaleData() |>
  RunPCA(npcs = 30) |> FindNeighbors(dim.s = 1:20) |> FindClusters(resolution = 0.5)
# ① 掃 pK：唯一要調的參數
bcm.vn <- find.pK(summarizeSweep(paramSweep(tm.p, PCs = 1:20, sct = FALSE), GT = FALSE))
pK.sel <- as.numeric(as.character(bcm.vn$pK[which.max(bcm.vn$BCMetric)]))
# ② 期望 doublet 數要「自己給」：10x 每千顆約 0.8%，再扣掉同型 doublet
nExp <- round(0.008 * ncol(tm.p) / 1000 * ncol(tm.p))
nExp <- round(nExp * (1 - modelHomotypic(tm.p$seurat_clusters)))
tm.p <- doubletFinder(tm.p, PCs = 1:20, pN = 0.25, pK = pK.sel, nExp = nExp, sct = FALSE)
pann <- grep("^pANN_", colnames(tm.p@meta.data))[1] # 欄名帶參數，用 grep 取
dfcl <- grep("^DF.classifications_", colnames(tm.p@meta.data))[1]
gbm$dbl.score <- tm.p@meta.data[[pann]]
gbm$dbl.class <- tolower(tm.p@meta.data[[dfcl]])
table(gbm$dbl.class)
```

期望率 4.2%（5,261 顆）→ $nExp = 221$ → 扣掉同型 doublet 後 = 198
table() 的 doublet 數就等於 198——是我們給的，不是工具自己找出來的

期望率由我們給、標記數就等於 $nExp$ ——這個數字必須寫進方法段 | 腳本：01 §4 | 深入：B5


文獻：McGinnis CS, Murrow LM, Gartner ZJ. Cell Syst. 2019;8(4):329–337.e4. doi:10.1016/j.cels.2019.03.003

DoubletFinder 在做什麼

doublet：指標抓不到的那種，要靠專門工具

示意／模擬資料

- ① 隨機挑兩顆細胞，把表現量相加 → 人造 doublet
- ② 把人造 doublet 丟回 PC 空間，看誰跟它們當鄰居
- ③ 鄰居裡人造 doublet 多的細胞 → 高 doublet 分數



腫瘤的 doublet 風險特別高：惡性 + 巨噬細胞黏在一起，會長得像「表現免疫基因的腫瘤細胞」

文獻： McGinnis CS, Murrow LM, Gartner ZJ. Cell Syst. 2019;8(4):329-337.e4. doi:10.1016/j.cels.2019.03.003

doublet 工具怎麼選、期望值是多少

裝載越多細胞，doublet 越多：10x 的經驗法則是每 1,000 顆約 0.8%

工具	原理	優點	要注意
DoubletFinder	人造 doublet + pANN 比例； 取分數最高的 nExp 顆	Cell Systems 發表；Xi & Li 2021 benchmark 準確度第一	期望率與 pK 都要自己給； pK 掃描慢
scDbfFinder (交叉比對)	人造 doublet + kNN 分類器； 自動估期望率與閾值	一行跑完、Bioconductor 維護、原生多樣本	發表於 F1000Research；上述 benchmark 未納入
Scrublet (Python)	同上，scanpy 內建	Python 流程預設	同型 doublet 抓不到
hashing / demuxlet	實驗端：抗體標籤或 SNP 分樣本	唯一能抓「同型」的方法； 多病人混跑時免費得到	實驗設計時就要決定 事後做不了

文獻：Xi NM, Li JJ. Cell Syst. 2021;12(2):176–194.e6. doi:10.1016/j.cels.2020.11.008 | Germain PL, Lun A, et al. F1000Res. 2021;10:979. doi:10.12688/f1000research.73600.2

03

Normalize、HVG、Scale、PCA

腳本 02：四行程式碼、三個必要檢查

三個問題，三步解

問題一：深度不同

惡性細胞 RNA 多、T 細胞 RNA 少，
總分子數差 5-10 倍。直接比就是比深度

NormalizeData

每顆除以總量 $\times 1e4$ ，取 $\log_{1p}$

問題二：基因太多

3.6 萬個基因裡多數在
細胞間沒差異，只是雜訊

FindVariableFeatures

挑 2,000 個變異超出技術預期的基因

問題三：量級不等

MALAT1 上千、轉錄因子個位數。
不拉平，PCA 被大聲的基因綁架

ScaleData

每基因 z-score，clip ± 10

後面每一步都吃這一步的輸出：PCA 用的是 2,000 個 HVG 的 scale.data

惡性細胞的 RNA 總量常是 T 細胞的十倍——第一步就是把這個差異除掉

前處理四步驟，並同時計算週期分數

```
gbm <- NormalizeData(gbm)           # CP10K + log1p：除掉深度
gbm <- FindVariableFeatures(gbm, nfeatures = 2000) # 挑 2,000 個 HVG
head(VariableFeatures(gbm), 10)      # 先看一眼名單

gbm <- CellCycleScoring(gbm, s.features = cc.genes.updated.2019$s.genes,
                        g2m.features = cc.genes.updated.2019$g2m.genes)
gbm <- ScaleData(gbm)                # z-score、clip  $\pm 10$ （只做 HVG）
gbm <- RunPCA(gbm, npcs = 50)         # 50 個 PC 先算存著
```

週期分數先算好，等一下看增殖細胞有沒有自成一群；本系列預設不 regress | 腳本：02 §1 | 深入：B6

LogNormalize 還是 SCTransform ?

兩者都對；本課用前者，因為每一步都看得見、也跟 pseudobulk 與 inferCNV 相容

LogNormalize (本課)

CP10K + log1p ; HVG 用 vst

- 簡單、快、可解釋；data 層可以直接拿來畫 FeaturePlot / DotPlot
- counts 層原封不動：
pseudobulk、inferCNV、SoupX 都要它
- 深度差異極大時會殘留一點深度效應，用 PC1 檢查得出來

SCTransform


負二項回歸，深度除得更乾淨

- HVG 挑得更穩，分群常更乾淨；v2 對深度差大的資料尤其好
- 多一個 SCT assay ; FindMarkers 前要先跑 PrepSCTFindMarkers
- DE、CNV、pseudobulk 仍要回到 RNA 的 counts 層，別用 SCT 的值

HVG 名單本身就有生物學——但排名會騙人

HVG：從 3.6 萬個基因裡挑出 2,000 個有話要說的

示意／模擬資料



GBM 的 HVG 前幾名會是誰

- 惡性 vs 正常的差異基因 (EGFR、SOX2、PTPRZ1)
- 免疫基因 (CD74、HLA、CCL4)
- 寡樹突 (MBP、PLP1)、血管 (VWF)
- 這份名單本身就有生物學——先看一眼再往下

這份資料前 20 名幾乎全是基質基因，來自只有 140 顆的纖維母細胞群。HVG 排的是變異量，不是重要性 | 腳本：02 §1

必要檢查一： PC1 是生物學，不是深度

```
print(gbm[["pca"]], dims = 1:2, nfeatures = 6)
cor(Embeddings(gbm, "pca")[, 1], gbm$nCount_RNA) # < 0.3 放心; 0.3-0.5 看載荷; > 0.5 要查
```

PC_1

Positive: PM P2, CALD1, PTN, GAP43, ITM2C, SEC61G ← 膠質／惡性

Negative: LAPTM5, TYROBP, SRGN, FCER1G, CYBA, AIF1 ← 免疫

[1] 0.47


GBM 的 PC1 幾乎一定是「免疫 vs 膠質」。0.47 落在腫瘤常見的區間——判斷看載荷，不是看係數 | 腳本：02 §2 | 深入：B7

PC1 與拐點

PCA：先看 PC1 是不是生物學，再決定取幾個

示意／模擬資料


PC1 = 免疫 vs 惡性／膠質這條軸



PC1 載荷

腫瘤結構複雜（多種型別 + 惡性狀態 + 病人差異），dims 建議 20-30，比 PBMC 的 10 多。取多一點比取少安全

ElbowPlot：腫瘤資料拐點通常比 PBMC 晚



腫瘤結構複雜，拐點通常比 PBMC 晚。dims 取 20-30；取多一點比取少安全

必要檢查二：取幾個 PC

```
ElbowPlot(gbm, ndims = 50)
pct <- gbm[["pca"]@stddev / sum(gbm[["pca"]@stddev) * 100
cum_u <- cumsum(pct)
which(cum_u > 90 & pct < 5)[1]      # 累積 90% 且單 PC < 5%
npc <- 25                          # GBM : 三法交集約 20-30, 取 25
```

把拐點變成數字，寫得進方法段。取太少會讓亞群消失，取太多只是多一點雜訊 | 腳本：02 §2

週期分數要不要回歸掉？看兩件事再決定

腫瘤資料的增殖細胞是生物學；預設不回歸，除非它劫持了分群

不回歸（預設）

增殖細胞自成一群、其他群仍按型別分

- 檢查 `DimPlot(group.by = "Phase")`：
只有一小塊是 S / G2M
- 檢查 PC1-PC5 的載荷：沒有
MKI67、TOP2A
- 處理：標成「增殖中的 X」，不是新型別

回歸（`vars.to.regress`）

每一型別都被週期切成兩半時

- `ScaleData(vars.to.regress = c("S.Score", "G2M.Score"))`
- 只回歸 S – G2M 的差，可保留「在不在分裂」
- 代價：增殖本身的訊號會消失，
而腫瘤研究常常正是要它

04

分群與 UMAP

分群在 PC 空間；resolution 掃一遍；分群後回頭做 QC

鄰居圖 → 社群 → 投影 → 掃描


```
gbm <- FindNeighbors(gbm , dims = 1:npc)           # PC 空間建 KNN/SNN 圖
gbm <- FindClusters(gbm , resolution = 0.5)        # 起點，不是答案
gbm <- RunUMAP(gbm , dims = 1:npc)                 # 同一組 dims

for (r in seq(0.2, 1.2, by = 0.2))
  gbm <- FindClusters(gbm , resolution = r, verbose = FALSE)
library(clustree); clustree(gbm , prefix = "RNA_snn_res.")
Idents(gbm ) <- "RNA_snn_res.0.5"                  # 掃完指回定案欄位
DimPlot(gbm , label = TRUE)
```

掃描後 active identity 停在最後跑的那個——一定要指回來 | 腳本：02 §3 | 深入：B8、B9

文獻：Traag VA, Waltman L, van Eck NJ. Sci Rep. 2019;9(1):5233. doi:10.1038/s41598-019-41695-z | McInnes L, Healy J, Melville J. arXiv:1802.03426. doi:10.48550/arXiv.1802.03426

clustree：找穩定層



找「連續幾層結構不變」的穩定層；箭頭交叉、細胞來回流動的層退回去。多切的每一刀都要有 marker 支持

腫瘤資料在低 resolution 就會把免疫／膠質／寡樹突分開；再往下切的是惡性狀態與免疫亞群，每一刀都要 marker 支持

群穩不穩：換 seed、換 k、看群大小

```
# 1. 同一 resolution 換 seed: ARI 接近 1 才算穩
gbm <- FindClusters(gbm, resolution = 0.5, random.seed = 42, cluster.name = "seed42")
mclust::adjustedRandIndex(gbm$RNA_snn_res.0.5, gbm$seed42) # 例: 0.9x

# 2. 換 k.param (預設 20): 群的骨架不該因此改變
gbm <- FindNeighbors(gbm, dims = 1:20, k.param = 30)
gbm <- FindClusters(gbm, resolution = 0.5, cluster.name = "k30")
table(gbm$RNA_snn_res.0.5, gbm$k30) # 對角線清楚 = 穩

# 3. 群大小: 小於 30 顆的群先存疑
sort(table(gbm$RNA_snn_res.0.5))
```

三個檢查十秒鐘。ARI < 0.8、或某群在換 k 後消失 → 那一刀不穩，用 marker 決定要不要留 | 腳本: 02 §3

必要檢查三：分群後檢視每群的 QC 與 doublet

```
gbm @ meta.data |>
  group_by(cluster= RNA_snn_res.0.5) |>
  summarise(n = n(), m_t = median(percent_m_t), nF = median(nFeature_RNA),
            dbl = mean(dbl_class == "doublet"), cyc = mean(Phase != "G1")) |>
  arrange(desc(dbl))
```


```
cluster  n   m_t  nF  dbl cyc
12      131 5.1 6221 0.60 0.24 ← 六成是 doublet、nF 全場最高 → 整群移除
9       140 3.6 5370 0.31 0.20
7       276 4.4 5625 0.20 1.00 ← cyc = 1：增殖「狀態」，不是型別
0      1048 4.8 4922 0.02 0.37
...
```

整群 doublet 比例過半、又卡在兩大群之間 → 整群移除並記錄； percent.mt 明顯偏高的群 → 回 QC 調整閾值 | 腳本：02 §4

分群到此告一段落： 13 個編號，還不是 13 種細胞

示意／模擬資料

UMAP : resolution 0.5 , 13 個群 (編號 0-12)




紅圈的第 12 群：三項 doublet 診斷全中，整群移除

分群到這裡告一段落：必要檢查三做完——每一群的 nFeature、percent.mt 都看過，第 12 群三項診斷全中，整群移除。

但手上現在只有 13 個編號，不是 13 種細胞——編號會隨參數重排，名字才是能寫進論文的东西。下一段開始給它們名字。

每群多大：最小的 131 顆



這就是分群這一段交出來的東西：一張 res 0.5 的 UMAP、13 個群、每群的大小，還有一群已被標記為整群移除。編號會隨參數重排，所以它只是中繼站，不是結論 | 腳本：02 \$4

05

註釋：從群的編號到細胞的名字

先看四頁地圖，再走腳本 03：譜系標誌基因 → marker → SingleR → 狀態分數

在講方法之前：細胞標註為什麼難


細胞標註不是把 marker 對到標籤那麼簡單

示意／模擬資料

① Continuous biology


細胞狀態是連續的，沒有天然邊界

虛線是演算法切出來的，不是生物學的邊界



② Annotation resolution

要標到多細取決於研究問題；越細不等於越好



③ No universal definition

不同研究對同一群的定義與命名都不同

同一群




SPP1+ macrophage
TREM2+ macrophage
Lipid-associated Mφ
Tumor-associated Mφ

④ Non-specific markers

marker 往往不是某一型專屬——要看一組的整體樣式


點越大=表現越高



⑤ Identity vs. state

新的亞型，還是被 IFN 刺激過的同一群？

兩群分得開，但那是型別還是狀態？



⑥ Technical uncertainty

四種技術性來源都會被誤讀成新的細胞族群

- ! dropout：測不到 ≠ 沒表現
- ! 批次：一個群可能只是一批樣本
- ! doublet：T + B 會像新型別
- ! 參考集偏差：沒有的型別會被硬塞


結論不是「找出唯一正確答案」，而是根據轉錄體、marker、參考集、組織背景與研究問題，建立一個最合理、而且拿得出證據的生物學解釋。

這六件事沒有一件是換個工具就能解決的。知道難在哪裡，等一下看每一種方法時才知道它解掉了什麼、又留下了什麼


目前的細胞型別註釋做法：人工判讀，還是自動註釋？

Accurate cell annotations are essential in many fields. Currently, there are many tools developed for automated annotation using reference datasets or marker genes.

Check the classic marker gene then assign by user
subjective and labor-intensive




Automatic annotation Nearly 200 methods



Giovanni Pasquini, et al. Comput Struct Biotechnol J. 2021 Jan 19;19:961-969.


There are now more than 200 tools available for cell type annotation



https://www.scrna-tools.org/


差別只在「誰來指派」。自動註釋兩百多個工具只有三大類，而三類的共同點比差別重要：都得先有一份參考——一張 marker 表，或一份已註釋的資料集

穩健的註釋，需要好的參考集，也需要好的演算法



Abdelaal, et al. Genome biology 20.1 (2019): 194.

Better Reference, Better Annotation



Fu, Qiqing, et al. Briefings in Bioinformatics 25.5 (2024): bbae392.

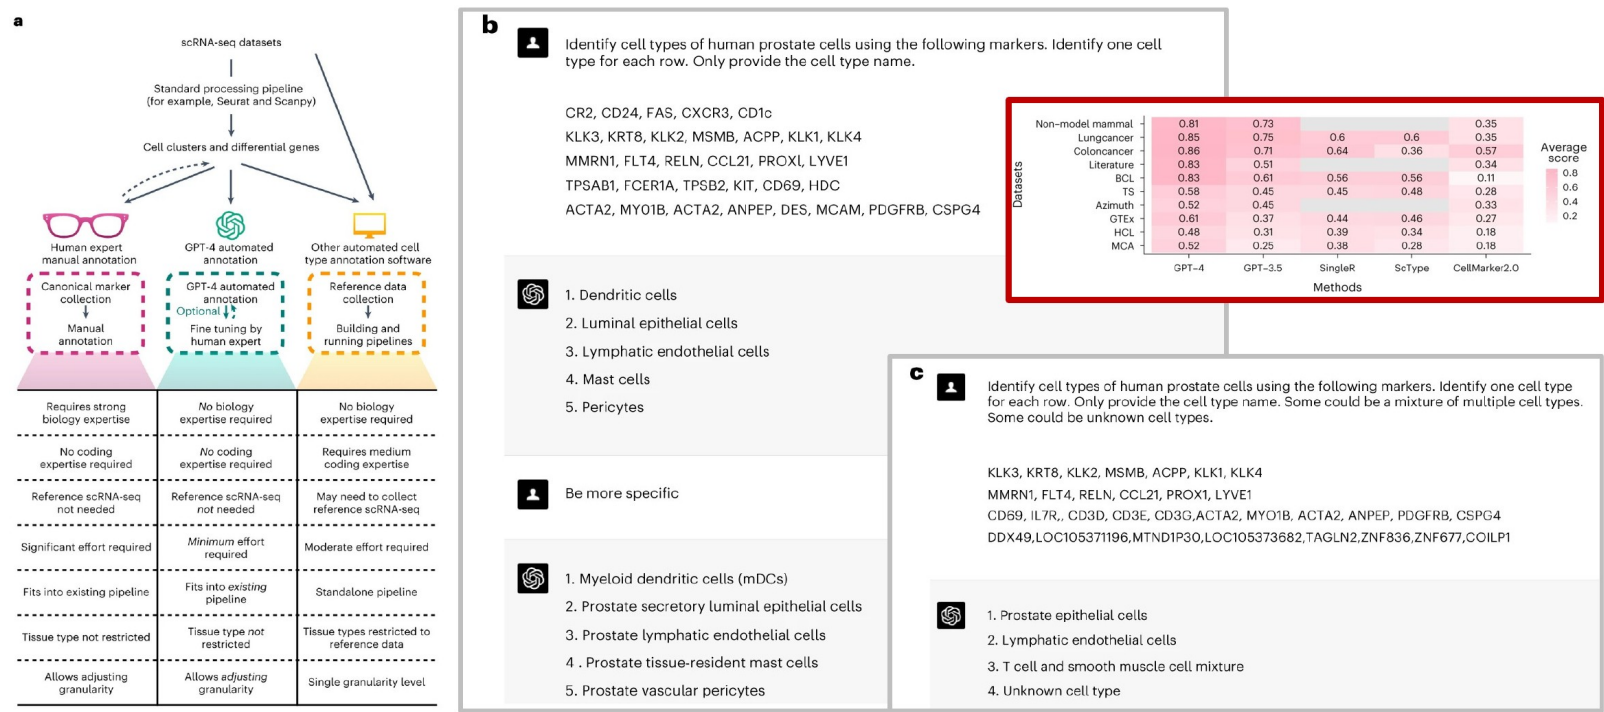
Across benchmarks and best-practice resources, the **coverage and quality of the reference atlas** often have a stronger impact on reference-based single-cell annotation than the specific classifier used.

Cheng, Jinming, et al. BMC bioinformatics 26.1 (2025): 22.

換演算法，前段班彼此差得有限；把某一型從參考集裡拿掉，同一批演算法整排一起崩。
演算法決定「好一點還是好很多」，參考集決定「有沒有可能對」

用 GPT-4 讀 marker 名單：它到底站在哪個位置？

GPT-4 can accurately annotate cell types in scRNA-seq analysis based on marker genes, achieving high consistency with expert annotations across diverse tissues.



Hou, Wenpin, and Zhicheng Ji. Nature Methods (2024): 1-4.


只給 marker 名單，它就贏過既有工具；但它從沒看過我們的資料。位置和 SingleR 一樣——第三份證據，不是唯一證據 | 腳本：03 §3

文獻： Hou W, Ji Z. Nat Methods. 2024;21(8):1462-1465. doi:10.1038/s41592-024-02235-4

先用四個譜系標誌基因劃分主要類群

示意／模擬資料

四個 gate 基因劃出來的主要類群



深藍 = 表現高

PTPRC

MBP

亮的是免疫

亮的是寡樹突

SOX2

PECAM1

亮的是膠質／惡性

亮的是血管

免疫（PTPRC）、膠質／惡性（SOX2）、寡樹突（MBP）、血管（PECAM1）。四塊劃清楚，再進亞群

譜系標誌基因與 marker 面板

```
FeaturePlot(gbm , features = c("PTPRC", "SOX2", "MBP", "PECAM 1"), ncol= 4)

panel<- c("PTPRC", "CD 68", "CD 163", "P2RY12", "TMEM 119", "CD 3E", # 免疫
          "SOX2", "OLIG2", "PTPRZ1", "EGFR", # 膠質／惡性
          "MBP", "PLP1", "PECAM 1", "VWF", "PDGFRB", "RGS5", # 寡樹突／血管／周細胞
          "MKI67", "TOP2A") # 週期
DotPlot(gbm , features = panel) + RotatedAxis()
```

沿對角線一塊塊亮起來就是好的分群； PTPRC 亮在三種免疫細胞是正常的 | 腳本： 03 §1 | 深入： B10

GBM 微環境的 marker 面板

族群	經典 marker	一句話
● 免疫類群	PTPRC (CD45)	所有免疫細胞的譜系標誌
● 巨噬細胞	CD68, CD163, C1QB, AIF1	腫瘤相關巨噬細胞 (TAM)，GBM 裡最多的免疫細胞
● 小膠質細胞	P2RY12, TMEM119, CX3CR1	腦內駐留的巨噬細胞；與血液來源的 TAM 區分
● T 細胞	CD3E, CD3D, CD2 (+CD8A / IL7R)	GBM 是「免疫冷」腫瘤，T 細胞通常很少
● 惡性 / 膠質	SOX2, OLIG2, PTPRZ1, EGFR	marker 只能說「膠質譜系」；惡性要靠 CNV 判定 (Q3)
● 寡樹突細胞	MBP, PLP1, MOG	被浸潤的正常白質；inferCNV 的好參考
● 血管內皮	PECAM1, VWF, CLDN5	GBM 血管增生明顯
● 周細胞	PDGFRB, RGS5, ACTA2	血管周圍的基質細胞
● 增殖中	MKI67, TOP2A	不是型別，是狀態；會疊在惡性細胞上

小膠質 vs 血液來源巨噬細胞、增殖狀態 vs 型別——這兩組是腫瘤註釋最常搞混的

證據一： FindAllMarkers 的 marker 表

```
m_markers <- FindAllMarkers(gbm, only.pos = TRUE,  
                             min.pct = 0.25, logfc.threshold = 0.5)  
m_markers |> group_by(cluster) |> slice_max(avg_log2FC, n = 5) |>  
  select(cluster, gene, avg_log2FC, pct.1, pct.2) |> print(n = 50)
```

cluster	gene	avg_log2FC	pct.1	pct.2	
4	OLR1	3.65	0.98	0.17	← 巨噬細胞 (TAM)
1	MAG	7.64	0.94	0.03	← 寡樹突: pct.2 = 0.03, 乾淨
0	PTPRZ1	1.92	0.99	0.38	← 膠質 (惡性待判定): pct.2 高 = 譜系共用

看表順序: avg_log2FC → pct.1 / pct.2 → p。pct.2 接近 0 才是乾淨的 marker | 腳本: 03 §2

marker 表怎麼篩：四個欄位、四個問題

p 值最後看——五千顆細胞幾乎什麼都顯著

欄位	它回答	好的 marker	陷阱
avg_log2FC	這群比其他群高多少	> 1 （兩倍以上）	低表現基因的 FC 會被 pseudocount 壓小
pct.1	這群裡多少比例表現	> 0.5	pct.1 = 0.3 的「marker」只描述群的一部分——可能藏著亞群或 doublet
pct.2	其他群裡多少比例表現	< 0.1	環境 RNA 會把 pct.2 抬高；MBP 的 pct.2 = 0.3 不代表寡樹突到處都是
p_val_adj	差異是不是偶然	< 0.05 （幾乎都是）	同群細胞不是獨立觀察值，p 值被高估幾個量級——只當篩子

證據二： SingleR 自動註釋

```
library(SingleR); library(cellidex)
ref <- cellidex:HumanPrimaryCellAtlasData()
pred <- SingleR(test = GetAssayData(gbm, layer = "data"), ref = ref,
               labels = ref$label.main, clusters = gbm$seurat_clusters)
data.frame(cluster = rownames(pred), SingleR = pred$labels,
           delta = round(pred$delta.next, 2))
```

cluster	SingleR	delta
0	Astrocyte	0.12 ← 參考集沒有 GBM 惡性細胞，被塞成最像的正常型別
1	Astrocyte	0.08 ← 其實是寡樹突（MAG/HAPLN2）；HPCA 也沒有寡樹突
4	Macrophage	0.18
9	Tissue_stem_cells	0.05 ← 其實是血管周／纖維母細胞
10	T_cells	0.06 ← 免疫型別才是它真正準的地方

免疫型別很準；參考集沒有的型別（惡性、寡樹突）一律被塞成最像的正常型別——那不是答案，是提醒 | 腳本：03 §3

文獻：Aran D, et al. Nat Immunol. 2019;20(2):163-172. doi:10.1038/s41590-018-0276-y

自動註釋的定位（以腫瘤資料為例）

自動註釋（SingleR / Azimuth）在腫瘤資料的定位

- ✓ 免疫細胞：很準。參考集（HPCA、Blueprint）涵蓋完整
- ✓ 寡樹突、內皮：準
- ✗ 惡性細胞：參考集裡沒有「GBM 惡性細胞」，會被硬塞成最像的正常型別（astrocyte、neural progenitor）
- 結論：自動註釋當第二獨立證據；惡性判定另外做

交叉驗證表（範例）

群	手動 marker	SingleR	裁決
2	巨噬細胞	Macrophage	✓
3	T 細胞	T_cells	✓
4	寡樹突	Oligodendrocyte	✓
0	惡性 AC 樣	Astrocyte	CNV 決定
1	惡性 OPC 樣	Neural progenitor	CNV 決定
5	內皮	Endothelial	✓

三欄交叉驗證：一致的群直接過；膠質群兩欄都只說到譜系，惡性與否這份資料判不了

註釋策略總覽：四條路，通常一起走

本課的順序是譜系標誌 → marker → 自動參考 → 分數；四條路都只走到譜系，惡性要的是另一類證據

策略	怎麼做	強項	弱項	工具
手動 marker	每群看 dotplot / FeaturePlot，對照文獻 marker	可解釋、能發現新型別	慢、主觀、依賴分群	Seurat
參考集分類	每群或每顆細胞與參考集比相關	快、可重現；正常型別準	參考集沒有的型別（腫瘤）會被塞成最像的	SingleR, scType, CellTypist
基因集打分數	一組基因的平均／AUC 當一個分數	連續、跨研究可比 適合「狀態」	分數高不等於型別；門檻很主觀	AddModuleScore, UCell, AUCell
圖譜投影	投到大型參考圖譜，繼承標籤	亞群最細、標籤一致	需要好的圖譜 惡性細胞投不上去	Azimuth, scArches

自動註釋工具怎麼選

同一份 GBM 資料跑三種，正常型別的一致率通常 > 90% ； 不一致的地方就是要人看的地方

工具	原理	參考	單位	適合／注意
SingleR	Spearman 相關 + 微調	celldex : HPCA、 Blueprint、 Monaco 免疫	細胞或群	正常型別的預設選擇； 換免疫專用參考可分 T 亞群
scType	marker 資料庫 + 群層級打分	內建人／鼠組織 marker 表	群	十秒出結果； 腦組織的表不含腫瘤
CellTypist	邏輯迴歸模型	免疫圖譜、人體多組織	細胞	免疫亞群最強（Python）
Azimuth	錨點投影到參考 UMAP	PBMC、人腦、肺 腎、骨髓...	細胞	附帶 UMAP 座標； 人腦參考對 GBM 的惡性細胞無效
scANVI / scArches	半監督深度模型	任何我們訓練的圖譜	細胞	跨技術、大型；要 GPU

文獻： Abdelaal T, et al. Genome Biol. 2019;20(1):194. doi:10.1186/s13059-019-1795-z | Hao Y, et al. Cell. 2021;184(13):3573-3587.e29. doi:10.1016/j.cell.2021.04.048


命名：證據到哪裡，標籤就寫到哪裡

```
new.ids <- c("0" = "G l i a l (undetermined)", "1" = "O ligodendrocyte",  
            "2" = "G l i a l (undetermined)", "3" = "G l i a l (undetermined)",  
            "4" = "M acrophage", "5" = "M acrophage", "6" = "M acrophage",  
            "7" = "Cycling (undetermined)", "8" = "M i c r o g l i a",  
            "9" = "Pericyte / fibroblast", "10" = "T cell",  
            "11" = "G l i a l (undetermined)", "12" = "G l i a l (undetermined)")  
# 要刪哪一群由 02 的 QC 表決定，不要寫死編號  
qc <- read.csv("output/tables/02_per_cluster_qc.csv")  
new.ids[as.character(qc$cluster[qc$dbl > 0.5])] <- "D O U B L E T"  
gbm <- RenameIds(gbm, new.ids); gbm$celltype <- Idents(gbm)  
gbm <- subset(gbm, subset = celltype != "D O U B L E T")
```

編號與名字的對應每份資料都不同，一定對照我們自己的 DotPlot 再掛；要刪的 doublet 群由 02 的 QC 表決定，不要寫死編號 | 腳本：03 \$4

層級式註釋：主要類群定了，再進亞群

示意／模擬資料



為什麼要重算

- 1 全體的 HVG 被「惡性 vs 免疫」佔滿，免疫內部的差異排不進前2,000
- 2 PCA 的前幾軸也一樣——亞群的訊號在第 20 軸之後
- 3 只留免疫細胞重跑，T 細胞的 CD4/CD8、TAM 的來源才分得開

免疫類群單獨拿出來重跑 HVG、PCA、分群，CD4 / CD8、小膠質 / 血液來源巨噬細胞才分得開。惡性類群的「亞群」用狀態分數，不用分群


亞群： subset 之後整條流程重跑一次

```
in m <- subset(gbm, celltype %in% c("Macrophage", "Microglia", "T cell"))
in m <- NormalizeData(in m) |> FindVariableFeatures(nfeatures = 2000) |>
  ScaleData() |> RunPCA(npcs = 30)
ElbowPlot(in m) # 亞群通常 15-20 個 PC 就夠
in m <- FindNeighbors(in m, dims = 1:20) |> FindClusters(resolution = 0.6) |>
  RunUMAP(dims = 1:20)
in m.panel <- c("P2RY12", "TMEM119", "CX3CR1", # 小膠質
  "CD163", "LYZ", "TGFB1", "S100A8", "VCAN", # 血液來源 TAM / 單核球
  "CD3E", "CD8A", "GZMK", "CD4", "IL7R", "FOXP3",
  "PDCD1", "HAVCR2", "NKG7", "GNLY", "CD1C", "MKI67")
DotPlot(in m, features = in m.panel) + RotatedAxis()
# 只想切某一群、不重跑: FindSubCluster(gbm, cluster = "2", graph.name = "RNA_snn")
```

subset 之後一定重算 HVG 與 PCA；直接在舊的 UMAP 上圈是常見錯誤。單細胞數 < 200 的亞群不要再切 | 腳本：03 §4b

免疫亞群面板：對角線就是證據

示意／模擬資料



怎麼讀

PTPRC 一整欄都亮：譜系標誌，不是亞群 marker

小膠質 vs 血液來源
TAM：P2RY12/TMEM119
對 CD163/TGFB1

耗竭 T 是 CD8+
PDCD1/HAVCR2，不是
新型別

增殖免疫只有 MKI67
亮：狀態，併回原型別

小膠質 vs 血液來源 TAM、CD8 vs 耗竭 CD8、Treg——每一刀都要有自己的 marker；
只有 MKI67 亮的群是狀態，併回去

膠質群的狀態分數（ Neftel 2019 ）


```
neftel<-list(                                # 每組取前 6 個示範
  MES = c("CHBL1", "ANXA2", "ANXA1", "CD44", "VIM", "MT2A"),
  AC  = c("CST3", "S100B", "SLC1A3", "HOPX", "MT3", "SPARCL1"),
  OPC = c("BCAN", "PLP1", "GPR17", "FBN", "LHFPL3", "OLIG1"),
  NPC = c("DLL3", "DLL1", "SOX4", "TUBB3", "HES6", "TAGLN3"))
glial<-subset(gbm, ids = "Glial(undetermined)")
glial<-AddModuleScore(glial, features = neftel, name = names(neftel))
FeaturePlot(glial, features = paste0(names(neftel), 1:4), ncol= 4)
```

各取前 6 個示範，完整基因集用論文附表（每組 50 個）；狀態定義在「已確認惡性」的細胞裡，分數不能反過來當惡性的證據 | 腳本：03 §5 | 深入：B13

文獻：Neftel C, et al. Cell. 2019;178(4):835-849.e21. doi:10.1016/j.cell.2019.06.024

為什麼是「打分數」而不是再分一次群

示意／模擬資料



- 惡性細胞的狀態是連續的，硬切成群會製造假邊界
- 用已發表的基因集打分數，結果可以跨研究比較
- 同一位病人的腫瘤同時含四種狀態——這是治療抗性的來源之一
- 週期分數 (G2M/S) 要一起算，否則增殖細胞會自成一群

惡性狀態是連續的；打分數保留連續性，也能跨研究比較。週期分數要一起看

文獻： Neftel C, et al. Cell. 2019;178(4):835–849.e21. doi:10.1016/j.cell.2019.06.024 | Tirosh I, et al. Science. 2016;352(6282):189–196. doi:10.1126/science.aad0501

打分數的三種算法： AddModuleScore、 UCell、 AUCell

```
# 1.AddModuleScore (Seurat)：基因集平均 - 表現量相近的對照基因平均。快，但受深度影響
glial<-AddModuleScore(glial, features = nefte1, name = names(nefte1))

# 2.UCell：以基因在每顆細胞內的「排名」算 Mann-Whitney U 分數，對深度與稀疏穩健
library(UCell)
glial<-AddModuleScore_UCell(glial, features = nefte1, name = "_UCell")

# 3.AUCell：每顆細胞的基因排名前 5% 裡有多少基因集成員（AUC）；SCENIC 也用它
library(AUCell)
rank<-AUCell_buildRankings(LayerData(glial, layer= "counts"))
auc<-AUCell_calcAUC(nefte1, rank)


FeaturePlot(glial, features = paste0(names(nefte1), "_UCell"), ncol= 4)
cor(glial$MES1, glial$MES_UCell) # AddModuleScore 加編號、UCell 不加；排序高度一致
```

狀態分數要報告算法與基因集來源；三種算法結論不一致時，相信 UCell（最不受深度影響） | 腳本：03 §5

文獻：Andreatta M, Carmona SJ. Comput Struct Biotechnol J. 2021;19:3796-3798. doi:10.1016/j.csbj.2021.06.043 | Aibar S, et al. Nat Methods. 2017;14(11):1083-1086. doi:10.1038/nmeth.4463

註釋的品質檢查：交叉表與 marker 熱圖

示意／模擬資料



左：對角線清楚、惡性被拆到星狀／神經前驅是預期（參考集沒有腫瘤）；右：對角線區塊一塊塊亮起來、沒有一群「什麼都亮」

左：手動 vs 自動的對角線清楚，偏離處都解釋得了；右：每群 top marker 一塊塊亮、沒有一群什麼都亮。這兩張放補充圖

品質檢查的程式碼：交叉表、熱圖、分群樹、輪廓係數

```
# 交叉表：手動標籤 vs SingleR (每列加總為 1)
round(prop.table(table(gbm$celltype, gbm$singleR), 1), 2)

# 每群 top 5 marker 熱圖 (每群最多抽 100 顆, 否則圖太重)
top5 <- markers |> group_by(cluster) |> slice_max(avg_log2FC, n = 5)
gbm <- ScaleData(gbm, features = unique(c(VariableFeatures(gbm), top5$gene))) # 熱圖基因要先 scale
DoHeatmap(subset(gbm, downsamples = 100), features = top5$gene, group.by = "celltype")

# 分群樹：型別之間的相似結構是否合理 (免疫一支、膠質一支)
gbm <- BuildClusterTree(gbm, dims = 1:20); PlotClusterTree(gbm)

# 輪廓係數：每群在 PC 空間裡有多「自成一格」 (< 0.1 的群要存疑)
library(cluster)
cl <- if(ncol(gbm) > 20000) sample(colnames(gbm), 20000) else colnames(gbm) # dist() 是 O(n²)
sil <- silhouette(as.integer(Ids(gbm)[cl]), dist(Embeddings(gbm, "pca")[cl, 1:20]))
tapply(sil, "sil_width", Ids(gbm)[cl, mean])
```

四個檢查各回答一個問題：自動同不同意、marker 乾不乾淨、結構合不合理、群分不分得開 | 腳本：03 \$5b

命名規範：三層標籤都存進 metadata

論文用第二層，補充表用第三層，統計檢定常常只用第一層

欄位	內容	例	規則
celltype_l1	主要類群	Immune / Malignant / Oligo / Vascular / Stromal	五到七個；組成分析用它
celltype_l2	型別	Microglia、Blood-derived TAM CD8 T、Glial (undetermined)	每個都有 ≥ 2 個 marker 支持；名字對齊 Cell Ontology
celltype_l3	狀態 / 亞群	Exhausted CD8 T、Cycling TAM、MES-like	狀態用「形容詞 + 型別」，不要發明新名詞
celltype_conf	信心	high / medium / unresolved	不確定的誠實寫 unresolved，不要硬塞

常見的誤註釋：五種「新型別」其實是什麼

看起來像	其實是	怎麼抓	怎麼處理
表現免疫基因的 腫瘤細胞	惡性 + 巨噬細胞 doublet	整群 dbl 比例高、nCount 偏高，卡在兩大群之間	整群移除並記錄
幹細胞樣亞群	增殖中的既有型別	marker 只有 MKI67 / TOP2A ； Phase 幾乎全是 S/G2M	併回原型別，加註 cycling
壓力反應亞群	解離假象	FOS / JUN / HSPA1A 高；散在每一型別裡各一撮	回歸或註明； 不當生物學
低分化 / 未知型別	低品質細胞	nFeature 最低、mt 最高，marker 什麼都不亮	回 QC 調整閾值
表現寡樹突基因的 免疫細胞	環境 RNA	MBP / PLP1 在所有群都有一點 pct.2 偏高	SoupX 後重跑

文獻： van den Brink SC, et al. Nat Methods. 2017;14(10):935-936. doi:10.1038/nmeth.4437 | McGinnis CS, Murrow LM, Gartner ZJ. Cell Syst. 2019;8(4):329-337.e4. doi:10.1016/j.cels.2019.03.003

交付：論文 Figure 1 的三張圖與一張表

```
p1 <- DimPlot(gbm, group.by = "celltype", label = TRUE,
              repel = TRUE) + NoLegend()
p2 <- DotPlot(gbm, features = panel, group.by = "celltype") + RotatedAxis()
p3 <- ViolinPlot(gbm, features = c("nFeature_RNA", "percent.mt"),
                 group.by = "celltype", pt.size = 0, ncol = 2)
fig1 <- (p1 | p2) / p3 # patchwork 排版
ggsave("output/figs/03_fig1_annotation.pdf", fig1, width = 14, height = 9, bg = "white")

comp <- gbm@meta.data %>% dplyr::count(celltype) %>%
  mutate(pct = round(100 * n / sum(n), 1))
write.csv(comp, "output/tables/03_composition.csv", row.names = FALSE)
```

celltype	n	pct
Glial (undetermined)	2379	46.4
Macrophage	1178	23.0
Oligodendrocyte	850	16.6
Cycling (undetermined)	276	5.4
Microglia	171	3.3
Pericyte / fibroblast	140	2.7
T cell	136	2.7

UMAP 給位置、dotplot 給證據、violin 給 QC 一致性、表給數字。四樣一起交，審稿人的第一輪問題少一半 | 腳本：03 §6

收尾：儲存物件與版本紀錄

```
saveRDS(gbm, "output/rds/03_gbm_annotated.rds")
write.csv(markers, "output/tables/03_markers.csv", row.names = FALSE)
sessionInfo() # 收進附錄；審稿人的好朋友
```

output/ 裡的每一個檔案都能從 R/ 的腳本重生——這就是可重現 | 腳本：03 §6

06

常見錯誤

六個腫瘤資料最常見的實作雷

錯誤一： percent.mt 照抄 5%



雷是什麼

用 PBMC 教學的 5% 直接套在 GBM 上。

為什麼會踩

每份教學都用 PBMC，5% 看起來像常識。

踩了會怎樣

砍掉一半活細胞，而且砍掉的多半是代謝旺盛的惡性細胞。
剩下的資料裡免疫細胞比例被灌大，之後的組成分析全歪。

錯誤二： doublet 群被當成「免疫樣腫瘤細胞」



雷是什麼

一群同時表現 SOX2 與 CD74 的細胞，寫成「具抗原呈現能力的惡性亞群」。

為什麼會踩

marker 看起來很有趣，也有文獻可以引。

踩了會怎樣

整群六成被 doublet 工具標記，又剛好卡在惡性與髓系之間。必要檢查三就是為了抓這個。

錯誤三：增殖細胞被當成新型別



雷是什麼

一群 MKI67、TOP2A 高的細胞自成一個群集，被命名為「幹細胞樣亞群」。

為什麼會踩

週期基因訊號很強，容易主導分群。

踩了會怎樣

那是狀態不是型別：裡面混著正在分裂的惡性細胞與巨噬細胞。先看 Phase 欄位，再決定要不要 regress。

錯誤四： resolution 越切越細，每一群都硬要命名



雷是什麼

把 resolution 開到 1.2，切出二十幾群，然後每一群都寫一個名字。

為什麼會踩

群多看起來比較細緻，clustree 也還畫得出來。

踩了會怎樣

多切的那幾刀沒有 marker 支持，換個 seed 就消失。分幾群不是目標，能不能用 marker 說清楚每一刀才是。先回到穩定層，再用 marker 決定要不要往下切。

錯誤五： marker 表只看 p 值



雷是什麼

FindAllMarkers 給了 $\text{padj} = 1\text{e-}40$ ，就把那個基因當成該群的 marker。

為什麼會踩

p 值小看起來就是證據強。

踩了會怎樣

cell-level 檢定把細胞當樣本，幾千顆細胞下 p 值天生極小，排序意義有限。要一起看 pct.1 與 pct.2 差多少、avg_log2FC 有多大——pct.1 = 0.22 對 pct.2 = 0.19 的基因，padj 再小也分不出群。

錯誤六：照抄別人的 marker 面板



雷是什麼

把 PBMC 教學的 marker 面板整份搬到腫瘤資料上。

為什麼會踩

面板現成、看起來通用。

踩了會怎樣

免疫那幾條照樣管用，但組織專屬的那一半整個缺席——沒有 PTPRZ1、MBP、PECAM1，膠質、寡樹突、血管就全部落進 unknown。marker 面板要照組織與癌別重配，不是照抄。

Q2 checklist



原始物件在過濾前存了一份



三條 QC 線各有數字與理由 (MAD)



doublet 分數在 metadata 裡



PC1 與 nCount 的相關 $|r| < 0.3$



dims 有依據 (拐點 + 量化 cutoff)



resolution 掃過，
穩定層有 marker 支持



四個主要類群用譜系標誌基因劃清楚



每群名字有兩個獨立證據 (marker+自動註釋)



惡性標籤暫時標「膠質 (待判定)」

九格全勾，物件才能進 Q3

一句話總結

**每個參數是一個假設：有數字、有理由、有紀錄。
註釋先確定譜系，惡性與否留待多重證據共同判定。**

做到這些，我們的流程就可重現、可辯護。惡性判定需要單一樣本給不了的證據，Q3 換一份資料示範。

自測 1

GBM 資料 percent.mt 中位數 7%、median + 3×MAD = 13%。閾值該怎麼定？

- A 照慣例 5%
- B 13%，並把數字與理由寫進方法段
- C 不過濾 percent.mt

答 B。閾值是資料的性質。5% 會砍掉大半活細胞；不過濾則會留下第二個峰的垂死細胞。

自測 2

某群同時高表現 SOX2 與 C1QB，doublet 工具標記其中 65% 為 doublet。該怎麼處理？

- A 這是有趣的新亞群，寫進結果
- B 整群移除並記錄理由
- C 只移除被標記的 65%

答 B。過半被標記、又卡在兩大群之間，整群就是 doublet 的產物；剩下的 35% 是工具沒抓到的，不是真細胞。

自測 3

SingleR 把 0 號群標成 Astrocyte，marker 是 SOX2 / PTPRZ1 / EGFR。最誠實的標籤？

A Astrocyte

B Malignant

C Glial（惡性待判定）

答 C。參考集裡沒有 GBM 惡性細胞，SingleR 只能塞最像的；marker 只說譜系。惡性要基因體層級的證據加上跨病人專屬性，單一病人湊不齊，誠實的標籤就是待判定。

自測 4

clustree 顯示 **res 0.4、0.5、0.6** 三層結構一致，**0.8** 以後細胞開始來回換群。該用哪一個？

- A 0.8，群比較多比較細
- B 0.5，穩定層裡的中間值，再用 marker 檢查每一刀
- C 都跑，最後挑結果最好看的

答 B。穩定層代表這幾刀換參數也不會變，取中間值最保險。挑「看起來最好看的」等於用結果決定方法，那條線畫在哪裡都能自圓其說。

自測 5

某個 marker 的 $\text{padj} = 1\text{e-}40$ ，但 $\text{pct.1} = 0.22$ 、 $\text{pct.2} = 0.19$ 。這個 marker 能用嗎？

- A 能， padj 這麼小一定是真的
- B 不能，群內外幾乎一樣多細胞在表現
- C 要看 avg_log2FC 是正是負

答 B。cell-level 檢定把細胞當樣本，幾千顆細胞下 padj 天生極小。 pct.1 跟 pct.2 只差 0.03，代表它在群內群外一樣常見——不具區辨力，就不是 marker。

自測 6

有一群細胞，四個譜系標誌基因都不亮。下一步最合理的做法？

A 標成 unknown 就好

B 刪掉，反正認不出來

C 先看它自己的 top marker 與 QC，必要時 subset 重跑

答 C。gate 基因只涵蓋四大類群，本來就會漏掉周細胞、纖維母這類細胞。先看它的 top marker——常常一眼就認得出來；QC 也要看，因為低品質細胞同樣會什麼都不亮。確定不是垃圾，再 subset 重跑一次。

下一集

Q3：多樣本整合與下游分析

換成 4 位病人、核心 vs 邊緣的 GBM 資料（GSE84465）——換資料就是為了拿到單一樣本給不了的證據。

以 inferCNV 為主的多重證據做惡性判定，pseudobulk 讓 DE 以病人為單位，最後是下游分析的選路指南。

