

Q 系列 Q3

實作篇 II：多樣本整合 與下游分析

以四位 GBM 病人（核心 vs 浸潤邊緣）為練習資料。做 Q2 那份單一病人資料做不到的惡性判定，讓 DE 以病人為單位，然後選擇下游路線。

約 70 分鐘 | 前置：Q2 | 腳本：R/04-10 | 深入：B11-B17





[https://github.com/
Charlene717/scRNA-seq-
tutorial-Qseries](https://github.com/Charlene717/scRNA-seq-tutorial-Qseries)

同一個問題，兩種答案

同一個問題（核心 vs 邊緣，同一種細胞），兩種答案

長條為本課實跑；右側散點為示意



核心 vs 邊緣，同一種細胞差了哪些基因？ cell-level 說 3,486 個，pseudobulk 說 608 個。65 分鐘後你知道該信哪個

這一集的起點

**多病人腫瘤資料只有三個關鍵決定：
整合到什麼程度、誰是惡性、DE 的單位是什麼。**

三個都做對，結果經得起審稿；錯一個，圖再漂亮也沒用。

本集目標

- 1 把 4 位病人的資料合在一起，用 Seurat 預設整合（必要時比較 Harmony），以正負對照檢查整合有沒有不足或過頭
- 2 用 inferCNV 以免疫與寡樹突細胞為參考判定惡性細胞，三角驗證後寫進 metadata，並和作者的標籤與作者標籤比對
- 3 做組成分析、pseudobulk + DESeq2（配對設計）、GSEA，並用一張表決定下一條下游路

01

四位病人、八個樣本

腳本 04：載入 Smart-seq2 counts 與 GEO 的 metadata

練習資料： Darmanis et al. 2017

練習資料： Darmanis et al. 2017 (GSE84465)

組織	4 位 GBM 病人，每位各取腫瘤核心（core）與浸潤邊緣（periphery）
細胞數	3,589 顆（通過作者 QC）
技術	Smart-seq2 全長定序（無 UMI，read counts）
已有標籤	7 種型別：惡性、OPC、星狀、寡樹突、神經元、血管、免疫
為什麼選它	多病人+有條件（core vs periphery）+有惡性標籤可對答案

實驗設計：4 × 2 配對



同一位病人的兩個部位可以配對比較：n = 4 對

這份資料有三樣 Q2 沒有的東西：多位病人、一個條件（核心 vs 邊緣）、作者的惡性標籤可以與作者標籤比對

Smart-seq2 和 10x 差在哪、哪裡一樣

10x 3' (Q2 的 GBM 5k)

Smart-seq2 (Q3 的 GSE84465)

計數單位	UMI 分子數	read counts (PCR 重複未去除)
每顆細胞的總量	5k-30k	50 萬-數百萬 reads
基因涵蓋	3' 端，1-3 千個基因	全長，4-8 千個基因
細胞數 / 成本	多、便宜	少、貴、每細胞資訊多
QC 差異	percent.mt 有效；doublet 要抓	percent.mt 仍有效；每孔一顆細胞，doublet 少
Seurat 流程	完全相同	完全相同 (NormalizeData 一樣適用)
pseudobulk	加總 UMI counts	加總 read counts (仍是整數，DESeq2 可用)

Seurat 流程完全相同；差別在計數單位、每顆細胞的資訊量，以及 doublet 幾乎不用擔心

載入 counts 與 metadata

```
# GEO 補充檔 (約 20 MB) : 注意它其實是「空白分隔」, read.csv 會讀成 0 欄
cnt <- read.table(gzfile("data/GSE84465_GBM_All_data.csv.gz"), header = TRUE,
                  sep = " ", row.names = 1, check.names = FALSE)
bad <- c("no_feature", "ambiguous", "alignment_not_unique",
        "too_low_aQual", "not_aligned") # HTSeq 統計列
cnt <- cnt[!row.names(cnt) %in% bad, ]

# metadata 在 series matrix。不要用 getGEO (GSEMatrix = TRUE): 暫存檔沒下載完整就會丟
# "parsing failed--expected only one 'series_data_table_begin'。自己讀標頭列最穩。
sm <- "data/geo/GSE84465_series_matrix.txt.gz" # 00_setup.R 已下載
hdr <- grep("^!Sample_characteristics_ch1",
            readLines(gzfile(sm), warn = FALSE), value = TRUE)
meta <- as.data.frame(do.call(cbind, lapply(hdr, function(x)
      scan(text = sub("^![^\t]+\t", "", x), what = "", sep = "\t",
        quote = "\"", quiet = TRUE))))
```

getGEO 的 parseGSEMatrix 對這個 GSE 很容易失敗; 自己下載+讀標頭列反而穩定 | 腳本: 04 §1

建物件、快速 QC

```
# 欄位順序不保證 → 用「內容」找欄，不要寫死 ch1.1 / ch1.2 這種索引
get.val <- function(df, key) {
  hit <- sapply(df, function(v) any(grepl(paste0("^", key, ":"), v)))
  sub(paste0("^", key, ":"), "", df[names(df)[which(hit)[1]]])
}
meta$patient <- get.val(meta, "patient id"); meta$tissue <- get.val(meta, "tissue")
meta$celltype_author <- get.val(meta, "cell type")
meta$cell <- paste(get.val(meta, "plate id"), get.val(meta, "well"), sep = ".") # 例: 1001000173.G8
meta <- meta[match(colnames(cnt), meta$cell), ] # 對齊 counts 的欄名
gbm4 <- CreateSeuratObject(as.matrix(cnt), meta.data = meta, min.cells = 3, min.features = 500)
gbm4[["percent.mt"]] <- PercentageFeatureSet(gbm4, pattern = "^MT-")
table(gbm4$patient, gbm4$tissue)
```

	Periphery	Tumor
BT_S1	55	433
BT_S2	445	712
BT_S4	554	957
BT_S6	179	204

← 八個樣本都在，但大小差 17 倍

Smart-seq2 的 nFeature 動輒 4-8 千，下限用 500 而不是 200；分布用 VlnPlot 按病人看。八個樣本從 55 顆到 957 顆，這個不平衡做 DE 時會回來找你 | 腳本: 04 §2

02

整合：校正強度的取捨

腫瘤資料的整合是兩難；先看未整合的圖

先跑一次不整合的流程，留基線


```
gbm 4 <- NormalizeData(gbm 4) |> FindVariableFeatures() |> ScaleData() |> RunPCA()
gbm 4 <- FindNeighbors(gbm 4, dims = 1:25) |> FindClusters(resolution = 0.5)
gbm 4 <- RunUMAP(gbm 4, dims = 1:25, reduction.name = "umap.raw")
DimPlot(gbm 4, reduction = "umap.raw",
         group.by = c("patient", "celltype_author"))
saveRDS(gbm 4, "output/rds/04_gbm 4_unintegrated.rds") # 之後惡性分析回來用這份
```

沒有基線就無法判斷整合改變了什麼。作者標籤這裡當「已知答案」用 | 腳本：04 §3 | 深入：B11

未整合基線透露的訊息

整合的兩難：修掉「病人效應」，也會修掉惡性細胞真實的病人差異

示意／模擬資料



做法：整合後的空間只用來註釋正常細胞型別與對齊免疫細胞；惡性細胞的分析回到未整合空間、按病人分開看

免疫與寡樹突細胞跨病人混合、惡性細胞按病人分島。整合會把後者也混掉——那是真的生物學

整合方法地圖：修多強、要什麼、對腫瘤的風險

沒有最好的方法，只有跟問題相稱的修正強度

方法	原理	修正強度	適合	腫瘤資料的風險
Seurat CCA / RPCA (本課預設)	找跨樣本的錨點細胞對； Seurat v5 內建，IntegrateLayers 一行	RPCA 弱 CCA 強	樣本間型別重疊高時	CCA 最容易過度修正；病人特有型別會被塞進別人
Harmony (比較用)	在 PC 空間迭代把批次質心拉近	中	多病人、多批次快、省記憶體	theta 調高會把惡性細胞硬混
scVI / scANVI	變分自編碼器，批次當條件	可調	大型圖譜、跨技術（10x + Smart-seq2）	需 GPU 與 Python 潛在空間難解釋
不整合 + 拆開分析	正常細胞用整合空間；惡性細胞每位病人各自分析	—	腫瘤研究的主流做法	跨病人比較惡性狀態要靠分數（Neftel），不靠分群

整合： Seurat 預設先跑， Harmony 當比較

```
gbm 4[["RNA"]] <- split(gbm 4[["RNA"]], f = gbm 4$patient) # 每位病人一個 layer
gbm 4 <- NormalizeData(gbm 4) |> FindVariableFeatures() |> ScaleData() |> RunPCA()
# (a) Seurat 預設：CCA 錨點（大資料可換 RPCAIntegration）
gbm 4 <- IntegrateLayers(gbm 4, method = CCAIntegration,
  orig.reduction = "pca", new.reduction = "integrated.cca")
# (b) 比較：Harmony（Seurat 整合不理想時的替代方案）
gbm 4 <- IntegrateLayers(gbm 4, method = HarmonyIntegration,
  orig.reduction = "pca", new.reduction = "harmony")
gbm 4 <- JoinLayers(gbm 4)
for (red in c("integrated.cca", "harmony")) { # 同 dims/resolution 才能比
  tag <- sub("integrated.", "", red, fixed = TRUE)
  gbm 4 <- FindNeighbors(gbm 4, reduction = red, dims = 1:25,
    graph.name = paste0(tag, "_snn")) |>
    FindClusters(graph.name = paste0(tag, "_snn"), resolution = 0.5,
    cluster.name = paste0(tag, "_clusters")) |>
    RunUMAP(reduction = red, dims = 1:25,
    reduction.name = paste0("umap.", tag))
}
DimPlot(gbm 4, reduction = "umap.cca", group.by = "patient") |
DimPlot(gbm 4, reduction = "umap.harmony", group.by = "patient")
```

整合只新增 reduction，表達值一個都沒動；DE 永遠回 RNA counts。兩個都跑、用同一套正負對照與 LISI 比——這份資料選 Seurat CCA | 腳本：04 §4 | 深入：B11

整合的正負對照： 哪些該混、 哪些該分

整合品質的正負對照： 哪些該混（正對照）、 哪些該分（負對照）

期望看到（通過）

警訊（失敗）

 正對照：免疫細胞（巨噬、T）  四位病人混合 → 整合成功

 按病人分島 → 批次效應未修

 正對照：寡樹突、血管  跨病人混合

 按病人分島

 負對照：惡性細胞  按病人分島（正確！）

 被混成一團→整合過頭，
病人特異 CNV 生物學被抹掉

正對照：免疫與寡樹突應跨病人混合；負對照：惡性應保留病人差異。這份資料的病人熵（上限 1.386）：免疫 0.79→1.01 過關，惡性 0.17→1.09 沒過——比免疫還高 | 腳本：04 §4

把「混得好不好」變成數字：每群病人組成、LISI

```
# 1. 每個整合群裡各病人佔多少：正常細胞的群應該四位都有
round(prop.table(table(gbm 4$cca_clusters, gbm 4$patient), 1), 2)

# 2. LISI: 一顆細胞的鄰居裡「有效病人數」 (1 = 全是同一位, 4 = 四位均勻)
library(lisi)
for (red in c("pca", "integrated.cca", "ham ony")) {
  em b <- Em beddings(gbm 4, red)[, 1:25]
  gbm 4[[paste0("lisi_", sub("integrated.", "", red, fixed = TRUE))]] <-
    com pute_lisi(em b, gbm 4@ m eta.data, "patient")$patient
}
gbm 4@ m eta.data >| group_by(celltype_author) >|
  sum m arise(across(starts_w ith("lisi_"), ~ m edian(x)))
```

celltype_author	lisi_pca	lisi_cca	lisi_ham ony	
Im m une cell	1.22	1.61	1.87	← 正對照：整合後混得比較開
O ligodendrocyte	1.26	2.00	1.91	
O PC	1.28	1.96	1.90	
Neoplastic	1.00	1.64	1.76	← 負對照：越接近 1 越保得住病人差異

正常細胞要往病人數（4）走、惡性細胞要留在 1 附近。這份資料兩個方法都把惡性混掉一些；CCA 混得比較少、正常細胞又沒輸——所以選 CCA | 腳本：04 \$5

腫瘤資料的整合原則

**整合後的空間只拿來註釋正常細胞、對齊免疫細胞；
惡性細胞的分析回到未整合空間，按病人分開看。**

這不是折衷，是兩種細胞本來就有不同的統計結構。多數腫瘤論文（Tirosh、Neftel、Puram）都這樣做。

另一條路：把細胞投到參考圖譜上

當你有一份好的參考時，註釋不必從頭來——正常細胞尤其適合

Azimuth



把你的細胞投到已註釋的參考（PBMC、人腦、肺……）上，直接繼承標籤與 UMAP 座標。免疫細胞亞群用它最省事

scArches



在參考模型（scVI / scANVI）上「續訓」你的資料，不用重跑整個圖譜；跨技術也行。Python 生態

惡性細胞投不上去



參考圖譜裡沒有這位病人的腫瘤。惡性細胞投上去只會得到「最像的正常型別」——跟 SingleR 一樣，是提醒不是答案

03

細胞身分判定：以 inferCNV 判惡性為例

腳本 05：惡性判定——換一份撐得住的資料才做得成

三件輸入： counts、註釋、基因座標


```
library(infercnv)      # BiocManager::install("infercnv")
refs <- c("Immune cell", "Oligodendrocyte")
ann <- data.frame(row.names = colnames(gbm4),
                  group = ifelse(gbm4$celltype_author % in% refs,
                                gbm4$celltype_author,
                                paste0("obs_", gbm4$patient)))
write.table(ann, "data/infercnv_annot.txt", sep = "\t",
            colnames = FALSE, quote = FALSE)
# 基因座標檔：官方提供 hg38 gencode 版本（見腳本 05 的下載連結）
cts <- LayerData(gbm4, layer = "counts")
obj <- CreateInfercnvObject(raw_counts_matrix = cts,
                           annotations_file = "data/infercnv_annot.txt",
                           gene_order_file = "data/hg38_gencode_v27.txt",
                           ref_group_names = refs)
obj <- infercnv::run(obj, cutoff = 1,      # Smart-seq 1 ; 10x 0.1
                    out_dir = "output/05_infercnv",
                    cluster_by_groups = TRUE, denoise = TRUE, HMM = FALSE)
```

參考組必須是「確定正常」的細胞：免疫與寡樹突最安全。星狀細胞不行——它可能就是惡性的 | 腳本：05 §1 | 深入：B16

inferCNV 熱圖怎麼讀

inferCNV 熱圖：每一列一顆細胞，每一欄一段基因體

示意／模擬資料



上半是參考細胞（平坦）；下半每位病人的惡性細胞各有自己的 CNV 組合——共同的 chr7+/chr10- 是 GBM 的教科書事件，其餘是各病人的私有事件

chr7 增加、chr10 缺失是 GBM 的教科書事件，四位病人共有；其餘每位病人各有私有事件——這就是 Q1 說的「按病人分島」的基因體原因

inferCNV 的關鍵參數：平台不同，數字不同

最常出錯的是 cutoff 抄錯平台；其次是參考組選錯（錯誤一）

參數	意思	Smart-seq2	10x	提醒
cutoff	基因平均表現低於此值就不用	1	0.1	10x 用 1 會把基因幾乎全丟掉，熱圖一片空白
ref_group_names	誰是「確定正常」	Immune + Oligodendrocyte	同	每組至少 50-100 顆 別用星狀細胞
window_length	沿基因體平滑的視窗（基因數）	101	101	越大越平滑 小片段事件看不到
HMM / denoise	把連續訊號切成離散 CNV 狀態	i6，可開	i6，可開	HMM 慢 本課用分數 + 相關代替
cluster_by_groups	觀察組按什麼分開畫	按病人	按樣本	按病人畫才看得到私有事件

從熱圖到兩項量化指標

```
d <- "output/05_infercnv/"
cnv <- read.table(paste0(d, "infercnv.observations.txt"), check.names = FALSE)
ref <- read.table(paste0(d, "infercnv.references.txt"), check.names = FALSE)
cnv.all <- cbind(cnv, ref) # 基因 × 細胞，已平滑、以參考為中心

cnv.score <- colMeans((cnv.all - 1)^2) # ① 偏離參考的程度
top <- names(sort(cnv.score, decreasing = TRUE))[1:200]
malprofile <- rowMeans(cnv.all[, top]) # 最像惡性的 200 顆平均 profile
cnv.cor <- apply(cnv.all, 2, cor, y = malprofile) # ② 與惡性 profile 相關


gbm4$cnv.score <- cnv.score[colnames(gbm4)]
gbm4$cnv.cor <- cnv.cor[colnames(gbm4)]
FeatureScatter(gbm4, "cnv.score", "cnv.cor", group.by = "celltype_author")
```

這是 Tirosh 2016 的做法：分數 + 相關兩個維度，畫出來看有沒有清楚的兩群 | 腳本：05 §2

每顆細胞兩個數字，四個象限

從熱圖到標籤：每顆細胞兩個數字

示意／模擬資料



三角驗證：三項獨立證據都到齊才定案

① CNV

分數高 + 與同病人惡性 profile 相關高

② 分群

按病人成島（正常細胞跨病人混合）

③ marker

膠質譜系（SOX2、OLIG2）而非免疫／血管

寫進 metadata

malignant/normal/unresolved
三種標籤，不確定的不要硬判

右上是惡性、左下是正常、中間標 unresolved。不確定的不要硬判——審稿人寧可看到誠實的灰色地帶

三角驗證：寫入 metadata，與作者標籤比對

```
gbm 4$malignant <- with(gbm 4@meta.data, ifelse(
  cnv.score > 0.02 & cnv.cor > 0.4, "malignant",      # 閾值看你的散點圖決定
  ifelse(cnv.score < 0.01 & cnv.cor < 0.2, "normal", "unresolved")))
# 第三項證據：譜系 marker。免疫／血管群若被標惡性，一律改 unresolved
gbm 4$malignant[gbm 4$malignant == "malignant" &
  gbm 4$celltype_author %in% c("Immune cell", "Vascular")] <-
  "unresolved"
table(gbm 4$malignant, gbm 4$celltype_author)
```

	Neoplastic	Astrocyte	OPC	Oligodendrocyte	Immune cell	Vascular	Neuron
malignant	高	少數	少數	0	0	0	0
normal	少數	多數	多數	全部	全部	全部	多數
unresolved	...						

和作者的 Neoplastic 標籤與作者標籤比對：一致率通常 > 90%。不一致的那幾顆值得看——常是浸潤邊緣的細胞 | 腳本：05 §3

CNV 以外的惡性證據

CNV 弱的腫瘤（兒童腦瘤、部分血液腫瘤、近二倍體的癌）要換獨立證據

突變與等位基因



Smart-seq2 讀得到編碼區的 SNV（IDH1 R132H、TP53）；10x 只在 3' 端偶爾抓到。HoneyBADGER、Numbat 用等位基因失衡補強 CNV

第二個 CNV 工具



copyKAT 不需要參考組、SCEVAN 全自動；跟 inferCNV 三者一致的細胞才寫 malignant。不一致的留在 unresolved

表現程式與病理



Neftel 狀態分數高、增殖高、跟任何正常型別都不像；加上病理的免疫染色（例如 IDH1 R132H 抗體）。這些是輔助，不是單獨的證據

04

組成：核心 vs 邊緣有什麼不同

腳本 06a §1：比例是組成資料，單位是病人

每位病人、每個部位的型別比例


```
gbm 4$type <- ifelse(gbm 4$malignant == "malignant",  
  "Malignant", gbm 4$celltype_author)  
prop <- gbm 4@meta.data |> dplyr::count(patient, tissue, type) |>  
  group_by(patient, tissue) |> mutate(frac = n / sum(n))  
ggplot(prop, aes(tissue, frac, fill = type)) + geom_col() +  
  facet_wrap(~ patient, nrow = 1) + theme_classic()  
  
# 檢定: propeller (speckle 套件), 以樣本為單位、配對設計  
library(speckle)  
propeller(clusters = gbm 4$type, sample = paste(gbm 4$patient, gbm 4$tissue),  
  group = gbm 4$tissue, transform = "logit")
```

「邊緣的惡性細胞比例較低」要用 propeller / scCODA 檢定, $n = 8$ 個樣本; 直接對比例做 t-test 是錯的 | 深入: B12

組成圖：每位病人一組

組成：每位病人核心 vs 邊緣的細胞型別比例

示意／模擬資料



比例是組成資料

邊緣的惡性細胞「變少」，
可能只是因為正常腦組織變多。
要檢定比例差異，用 propeller/scCODA，
且以病人為單位

四位病人方向一致才算數。比例是封閉的：一種細胞變少，其他的必然變多

組成分析的三件事：閉合、配對、單位

閉合



比例加總是 1：惡性細胞減少，免疫細胞「自動」增加。所以檢定要在 logit 或 CLR 尺度做（propeller、scCODA），不能對原始比例做 t-test

配對



核心與邊緣來自同一位病人，配對設計把病人間的差異扣掉，功效大增。propeller 用 $\sim$ patient + tissue 的設計矩陣即可

單位是樣本



$n = 8$ 個樣本（ 4×2 ），不是 3,589 顆細胞。卡方檢定在細胞層級做，p 值會小到荒謬——跟錯誤一同一個錯


05

差異表達：每種細胞各自比核心 vs 邊緣

腳本 06a（pseudobulk 主線）與 06b（樣本太少時的 cell-level 備案）


為什麼 cell-level 檢定會給你兩千個基因

cell-level 檢定看到的



n = 1,200 vs 1,200 「觀察值」

真正的設計



n = 4 對 (配對)

同一位病人的細胞共享基因體與 CNV，彼此不獨立。把細胞當觀察值 = pseudoreplication，p 值會小到不像話

同一位病人的惡性細胞共享同一套 CNV，彼此高度相關。真正的設計是 4 對，不是 2,400 個觀察值

pseudobulk 的五步

pseudobulk：把單細胞資料變回「每個樣本一行」，再用成熟的 Bulk 統計



一行抓雷：sum(mat != round(mat)) 必須是 0。不是 0 代表你加總到了 data / scale.data / integrated 層

只取一種細胞——否則你比的是組成（邊緣的正常腦細胞比較多），不是那種細胞的變化

每種細胞型別各自比：為什麼、門檻是什麼

混在一起 = 比組成



核心 vs 邊緣的差異，每一種細胞都不一樣。全部細胞一起做 DE，前十名會是 MBP、PLP1——那只是邊緣的寡樹突比較多

兩個門檻



MIN_CELLS = 20：每個「病人 × 部位」至少 20 顆才算一個 pseudobulk 樣本，太少的整格丟掉。MIN_PAIRS = 2：至少兩位病人兩個部位都有，配對設計才成立

這份資料只有一種型別過關



四位病人的邊緣加起來只有 31 顆惡性細胞（最多的一位 17 顆），沒有人到 MIN_CELLS = 20——惡性細胞的核心 vs 邊緣，這份資料做不了。真正跑得出來的是 Immune cell：4 對病人、608 個顯著基因

把 pseudobulk + 配對 DESeq2 包成函式，對每種型別呼叫

```
pb_de <- function(obj, type, m.in.cells = 20, m.in.pairs = 2) {  
  sub <- subset(obj, cells = colnames(obj)[obj$type == type])  
  n <- table(sub$patient, sub$tissue)  
  ok <- names(which(rowSums(n >= m.in.cells) == 2)) # 兩部位都夠的病人  
  if (length(ok) < m.in.pairs) return(NULL)  
  sub <- subset(sub, cells = colnames(sub)[sub$patient %in% ok])  
  pb <- as.matrix(AggregateExpression(sub, assays = "RNA",  
    group.by = c("patient", "tissue"))$RNA)  
  stopifnot(sum(pb != round(pb)) == 0) # 一行抓雷：必須是整數  
  coldata <- data.frame(patient = sub("_[^_]*$", "", colnames(pb)),  
    tissue = factor(sub(".*_", "", colnames(pb)),  
      levels = c("Periphery", "Tumor")))  
  dds <- DESeq(DESeqDataSetFromMatrix(pb[rowSums(pb) >= 10, ], coldata,  
    design = ~ patient + tissue))  
  raw <- results(dds, name = "tissue_Tumor_vs_Periphery") # stat → GSEA、火山圖  
  shr <- lfcShrink(dds, coef = "tissue_Tumor_vs_Periphery", type = "ashr")  
  list(res = data.frame(gene = rownames(raw), log2FC = raw$log2FoldChange,  
    log2FC_shrunk = shr$log2FoldChange, stat = raw$stat,  
    padj = raw$padj), pb = pb, coldata = coldata)  
}  
de <- lapply(types, function(ty) pb_de(gbm4, ty)); names(de) <- types
```

~ patient + tissue：配對設計先吸掉病人差異。病人 ID 含底線，拆欄名要從最後一段切 | 腳本：06a §2 | 深入：B12

一個 DE 結果、三種 log2FC：哪個用在哪裡



收縮（shrinkage）是把低表現、高變異基因的誇大 FC 往 0 拉；拉多用力，方法差很多

欄位	怎麼來	特性	用在
未收縮 log2FC	results(dds) 的 log2FoldChange	低 count 基因： FC 很大、SE 也很大	火山圖的 x 軸（形狀才正常）
stat（Wald）	$\log_2FC \div SE$	同時帶效應量與不確定性，很少同分	GSEA 的排序統計量
log2FC_shrunk (ashr)	lfcShrink(type = "ashr")	小 n 穩定；保留大效應、壓小雜訊	報告效應量、挑基因做驗證
apegglm (小 n 不建議)	lfcShrink(type = "apeglm")	n = 8 時先驗太強，幾乎所有基因被壓成同一值 → 火山圖變一根直柱、GSEA 全是同分	樣本多 (≥ 3 vs 3、count 充足) 時才用

報告時證明差異在病人層級一致

報告時證明差異在「病人層級」一致：每位病人一條線

示意／模擬資料



左邊這種圖比火山圖更有說服力；右邊這種在 cell-level 檢定裡照樣「極顯著」


每位病人一條線（示意圖； SLC2A1 是本課實跑的顯著基因， $\log_2FC$ 5.7、 p_{adj} 3.6e-12）。左邊這種圖比火山圖更有說服力；右邊這種在 cell-level 檢定裡照樣「極顯著」

火山圖怎麼讀：先看形狀，再看角落


火山圖怎麼讀：先看形狀，再看角落

示意／模擬資料

正常的火山圖：紅 = 核心高、藍 = 邊緣高、灰 = 不顯著；對稱、兩翼張開




異常 1：一根直柱



LFC 全被壓到同一值：
收縮太強（小 n 用 apeglm 常見）
。火山圖改用未收縮 LFC，
效應量改用 ashr

異常 2：只有一側



某個病人 × 部位細胞太少，
pseudobulk 是噪音，
全部往一邊倒。提高 MIN_CELLS、
看 `table(patient, tissue)`

x = 未收縮 $\log_2 \text{FC}$ 、y = $-\log_{10}(\text{padj})$ ；每種細胞型別各畫一張（腳本 06 § 3）。顯著卻落在中間的點，用每樣本點圖確認四位病人方向一致

x = 未收縮 $\log_2 \text{FC}$ 、y = $-\log_{10}(\text{padj})$ 。一根直柱 = 收縮太強；只有一側 = 某個樣本細胞太少；飛到 $|\log_2 \text{FC}| > 20$ 的點 = 一邊有、一邊幾乎沒有，是組成不是高低 | 腳本：06a § 3

同一份 DE 結果、兩種富集問法：ORA 數比例，GSEA 看排序

同一份 DE 結果、兩種富集問法：ORA 數比例，GSEA 看排序

示意／模擬資料

ORA (over-representation)：先切閾值，再數比例

顯著基因

背景 = 被檢定的所有基因 (universe)




藍 tick = 某個基因集 (例如 GO 「response to hypoxia」) 的成員

問：顯著基因裡藍 tick 的比例，是否高於背景裡的比例？
超幾何 / Fisher 檢定 → padj、GeneRatio、Count

需要：夠多的顯著基因 ($\geq 10-20$)、正確的背景。
小 n 的 DE 表很短時，ORA 幾乎沒東西可算

工具：clusterProfiler enrichGO/enrichKEGG；
圖：dotplot、cnetplot

GSEA：不切閾值，看整個排序清單



基因依 DESeq2 stat 排序 (左 = 核心較高)

問：這個基因集的成員是不是擠在清單的一端？
置換檢定 → NES (正 = 核心較高)、padj、leading edge

小 n 的首選：全部基因都貢獻證據。
工具：fgsea (Hallmark/GO/KEGG 都能跑)

兩種都跑：GSEA 當主結果，ORA 上調／下調分開做當交叉驗證。同一個 pathway 兩邊都出現，才寫進結論

GSEA 不切閾值、全部基因貢獻證據——小 n 的首選；ORA 要先有夠多顯著基因、背景要對。兩種都跑，同一條 pathway 兩邊都出現才寫進結論

三個基因集資料庫： Hallmark、 GO、 KEGG

都從 msigdb 拿，同一套 fgsea 跑；ORA 用 clusterProfiler 的 enrichGO / enrichKEGG

資料庫	內容與大小	優點	注意
Hallmark (H)	50 個精選、彼此少重疊的生物程式：缺氧、EMT、干擾素、G2M...	先看這個：一頁講得完、結果最好解讀、幾乎不會互相冗餘	只有 50 條，細節（哪條訊號、哪個代謝分支）問不到
GO BP (C5)	約 7,500 個 BP 詞條 階層式、高度重疊	最細；ORA 的預設語言；離線就能跑（org.Hs.eg.db）	同一件事會以十個詞條出現——先 simplify()；命中 3-5 個基因的詞條再顯著也別寫進結論
KEGG (C2 CP)	約 190 條代謝與訊號路徑，有路徑圖	代謝問題（糖解、OXPHOS）最直觀；pathview 能畫在路徑圖上	enrichKEGG 要連網；很多是疾病路徑（「阿茲海默症」）不代表機制；msigdb 的是 legacy 版

GSEA：三個資料庫、每種型別，一個迴圈


```
library(fgsea); library(m sigdbr)
m sig <- function(coll, sub = NULL) {
  m <- m sigdbr(species = "Homo sapiens", collection = coll, subcollection = sub)
  split(m $gene_symbol, m $gs_name)
  gene.sets <- list(Hallmark = m sig("H"), GO_BP = m sig("C5", "GO :BP"),
    KEGG = m sig("C2", "CP :KEGG_LEGACY"))
  rank_stat <- function(res) { # 排序用 Wald stat, 不用 shrunken LFC
    r <- setNames(res$stat, res$gene); r <- r[!is.na(r)]
    sort(r + mom(length(r), sd = 1e-6), decreasing = TRUE) } # 打散同分
  run_gsea <- function(d, sets) rbindlist(lapply(names(sets), function(nm) {
    g <- fgsea(sets[[nm]], rank_stat(d$res), minSize = 15, maxSize = 500) # eps 留預設
    g$collection <- nm; g$type <- d$type; g}))
  gsea.all <- rbindlist(lapply(de, run_gsea, sets = gene.sets))
  gsea.all[adj < 0.05][order(-abs(NES))][, .SD[1:5], by = .(type, collection)]
```

eps = 0 會要求 p 值算到無限精細，跑幾小時都跑不完；預設 1e-10 已經夠報告。背景自動是被檢定的基因 | 腳本：06a §4 | 深入：B13

GSEA：把一百多個基因變成一句話

GSEA (fgsea + Hallmark)：把 168 個基因變成一句生物學結論

示意／模擬資料



讀法

核心：缺氧、糖解、EMT 樣程式——符合壞死中心的微環境。邊緣：增殖與 OXPHOS 較高——浸潤中的細胞。

方向合理=已知答案驗證通過；
再去看 leading edge 裡是哪些基因

排序用 DESeq2 的 Wald stat (不用 shrunken log2FC：大量同分)，不切顯著閾值；背景基因集自動是「被檢定的基因」

核心缺氧、糖解；邊緣增殖、OXPHOS——方向合理是已知答案驗證。接著讀 leading edge 裡是哪些基因

ORA : clusterProfiler 的 GO 與 KEGG , 上調下調分開做



```
library(clusterProfiler); library(org.Hs.eg.db); library(enrichplot)
run_ora <- function(d, direction = "up", fc = 0.5, p = 0.05) {
  r <- d$res[!is.na(d$res$padj), ]
  sig <- r$gene[r$padj < p & (if(direction == "up") r$log2FC > fc else r$log2FC < -fc)]
  if(length(sig) < 10) return(NULL) # 顯著基因太少: 改看 GSEA
  go <- enrichGO(sig, orgDb = org.Hs.eg.db, keyType = "SYMBOL", ont = "BP",
    universe = d$res$gene, # ★ 背景 = 被檢定的基因, 不是全基因組
    minGSSize = 15, maxGSSize = 500) |>
    clusterProfiler::simplify(cutoff = 0.7) # igraph 也有 simplify, 寫全名
  ids <- bitr(sig, "SYMBOL", "ENTREZID", org.Hs.eg.db)
  uni <- bitr(d$res$gene, "SYMBOL", "ENTREZID", org.Hs.eg.db)
  kegg <- enrichKEGG(ids$ENTREZID, organism = "hsa", universe = uni$ENTREZID) |>
    setReadable(org.Hs.eg.db, keyType = "ENTREZID") # 要連網
  list(go = go, kegg = kegg) }
ora <- run_ora(de[["Malignant"]], "up")
dotplot(ora$go, showCategory = 12); dotplot(ora$kegg, showCategory = 12)
cnetplot(ora$go, showCategory = 5) # 詞條-基因網路: 哪些基因撐起哪個詞條
```

universe 留空, clusterProfiler 會拿全基因組當背景——顯著詞條會多一倍, 全是假的。上下調分開, 因為「缺氧上升」與「增殖下降」混在一起會互相抵銷 | 腳本: 06a \$4

富集結果怎麼讀： NES 熱圖與 dotplot

富集結果怎麼讀：NES 熱圖看「誰的 pathway」，dotplot 看「哪些詞條可信」

示意／模擬資料



整列都紅 = 微環境程式，每種細胞都感受得到；只有一欄 = 細胞內在的程式。dotplot 只讀前幾名、GeneRatio 高而且 padj 小的那幾條 | 腳本：06a §4 圖 A-C

富集分析最常見的五個錯

背景錯了



ORA 的 universe 必須是「被檢定的基因」（有表現、進了 DESeq2 的那些），不是全基因組。單細胞只測到一萬多個基因，用兩萬多當背景，每個詞條都會膨脹

方向弄反、混在一起



NES 正負取決於 tissue 的 levels 順序；ORA 上下調不分開，相反的程式會抵銷。先用已知答案（核心該缺氧）確認方向再往下讀

冗餘不是多重證據



GO 的「response to hypoxia」「response to decreased oxygen levels」「response to oxygen levels」是同一件事。simplify() 之後再數；報告時寫一條，不是三條

命中太少就下結論



命中 3-5 個基因的詞條，再顯著也不寫進結論；leading edge 至少要有十來個基因，而且你要能一個一個說出它們在做什麼

忘了這是誰的 pathway



缺氧在惡性細胞升、在巨噬細胞也升——那是微環境，不是惡性細胞的特性。每種型別各自做，把 NES 排成熱圖，才分得出「共同」與「專屬」

交付：每型別的 DE 表、火山圖、GSEA 與 ORA 總表

```
for (ty in names(de)) # 每種型別一份表
  write.csv(de[[ty]]$res, sprintf("output/tables/06_de_%s.csv", ty), row.names = FALSE)
write.csv(de.summary, "output/tables/06_de_summary_by_type.csv") # 幾對病人、幾個顯著基因


vol <- lapply(de, function(d) { # 紅 = 核心高、藍 = 邊緣高、灰 = NS
  kv <- with(d$res, ifelse(padj < 0.05 & log2FC > 1, "#D62728",
    ifelse(padj < 0.05 & log2FC < -1, "#1F77B4", "grey70")))
  names(kv) <- c("#D62728" = "Up in core", "#1F77B4" = "Up in periphery", grey70 = "NS")[kv]
  EnhancedVolcano(d$res, lab = d$res$gene, x = "log2FC", y = "padj", colCustom = kv,
    pCutoff = 0.05, FCcutoff = 1, title = paste0(d$type, ": core vs periphery")) })
ggsave("output/figs/06_volcano_all_types.png", wrap_plots(vol, ncol = 2), bg = "white")

gsea.all[, leadingEdge := sapply(leadingEdge, paste, collapse = ";")] # list 欄轉字串
write.csv(gsea.all, "output/tables/06_gsea_all_types.csv", row.names = FALSE)
# NES 熱圖 (列 = pathway、欄 = 型別) 與 ORA dotplot: 見腳本 06a §4 圖 A-C
plotEnrichment(gene.sets$Hallmark[["HALLMARK_HYPOXIA"]], rank_stat(de$Malignant$res))
```

表要有 raw 與 shrunken LFC、padj、baseMean；火山圖標的是 padj 不是 p；GSEA 表附 leading edge。全部由腳本重生，output 裡沒有手工檔 | 腳本：06a §5

多少位病人才夠？功效來自病人數

多少位病人才夠？功效來自病人數，不是細胞數



怎麼讀這張圖

- 1 $n=4$ 只抓得到「很大」的效應；中等效應的功效不到 20%
- 2 再加上幾千個基因的多重校正，真正能過 FDR 的更少——所以 $n=4$ 的 DE 表短是正常的，不是分析做錯
- 3 要看中等效應，配對設計大約需要 10 位以上病人；非配對還要更多
- 4 功效不夠時的正確做法：把 $n=4$ 當作「假說產生」，用公開資料或 Bulk 世代驗證

$n = 4$ 只看得到很大的效應，所以 DE 表短是正常的。把 $n = 4$ 當假說產生，用公開世代驗證——這就是錯誤三的正面版

不能 pseudobulk 的時候：三道防線

先承認落到哪裡



pseudobulk 要每個條件 $\geq$ 2-3 個生物重複。病人不夠（06a 的 de.summary 顯示被跳過，如本資料的 OPC）就退到 cell-level——但 p 值是被細胞數灌大的，結論定位只能是「假說產生」

防線一＋二：共變量與逐病人一致性



先跑 Seurat 預設的 Wilcoxon 當基準，再用 MAST 把病人放進 latent.vars（Wilcoxon 做不到）——只在 Wilcoxon 顯著的基因多半是病人效應。接著逐病人各算 logFC，方向全一致才留；一致性表裡的 NA = 該病人單邊 < 5 顆、無法評估

防線三：標籤置換



把 tissue 標籤在病人內隨機打散重跑：真實訊號應遠多於置換後撈到的「顯著」數。差不多多，就是假重複在說話。最後把方法與限制明寫在交付表上

cell-level DE 的正確作法（腳本 06b）

```
obj <- subset(gbm 4, cells = colnames(gbm 4)[gbm 4$type == "0 PC"])
table(obj$patient, obj$tissue)      # 先看樣本結構：兩部位都夠的病人只有 1 位
Idents(obj) <- "tissue"
de.wilcox <- FindMarkers(obj, ident.1 = "Tumor", ident.2 = "Periphery",
                        logfc.threshold = 0.25) # Seurat 預設 Wilcoxon：當基準
de <- FindMarkers(obj, ident.1 = "Tumor", ident.2 = "Periphery",
                  test.use = "MAST", latent.vars = "patient", # 防線一：病人當共變量
                  logfc.threshold = 0.25, min.pct = 0.1)
setdiff(head(de.wilcox$gene, 30), head(de$gene, 30)) # 只在預設法顯著 ≈ 病人效應
# 防線二：逐病人 logFC，方向一致才留（單邊 < 5 顆的病人不算）
# 防線三：tissue 在病人內置換 20 次，比較「顯著基因數」的真實值 vs 置換分布
perm.sig <- replicate(20, {
  o <- obj; o$tissue <- ave(as.character(o$tissue), o$patient, FUN = sample)
  Ident(o) <- o$tissue
  sum(FindMarkers(o, ident.1 = "Tumor", ident.2 = "Periphery",
                  logfc.threshold = 0.25)$p_val_adj < 0.05, na.rm = TRUE)})
de$method <- "cell-levelMAST; hypothesis-generating" # 交付表明寫限制
```

這支的重點不是 p 值——是三道防線與誠實的定位。能 pseudobulk 就永遠用 06a；06b 是樣本結構不允許時的備案 | 腳本：06b

06

差異表達之後：下游路線的選擇

腫瘤研究常走的六條路，每一條都要對的資料

六條路，各自要什麼

DE 之後：腫瘤研究常走的六條路，各自要什麼資料

細胞通訊

惡性↔TAM 的配體-受體
軸（如 SPP1、CSF1）

需要：可靠型別標籤、多型別共存

CellChat

惡性狀態與可塑性

MES / AC / OPC / NPC 樣分數、週期

需要：已判定的惡性細胞 + 發表的基因集

AddModuleScore

軌跡

惡性細胞內的狀態轉換（不是型別之間）

需要：連續過程被取樣；起點有依據

Slingshot

CNV 亞株

同一病人內的亞株結構

需要：inferCNV HMM 或 CopyKAT

inferCNV

反卷積 Bulk 隊列

用單細胞參考拆 TCGA-GBM
的比例，連結存活

需要：同組織單細胞參考 + Bulk

MuSiC / BayesPrism

空間

哪種惡性狀態靠近血管／壞死區

需要：Visium / Xenium 資料


Seurat spatial

先對照「需要」那一行，再決定走哪條。選錯資料，整條路作廢

最常見的下游誤用

示意／模擬資料

惡性 → 免疫 → 寡樹突的「分化路徑」？



軌跡工具永遠會給你一條線

- ✗ 惡性細胞不會分化成巨噬細胞。這條線不存在
- ✗ 分支點落在型別交界 = 人工產物的典型長相
- ✓ 腫瘤裡合理的軌跡：惡性細胞「內部」的狀態轉換（OPC 樣→AC 樣），而且要先判定惡性、先按病人分開
- ✓ 快照推不出方向；起點要有獨立依據（週期、幹性、RNA velocity）

腫瘤裡合理的軌跡只有一種：惡性細胞內部的狀態轉換，先判定惡性、先按病人分開

07

細胞通訊： CellChat 從跑到讀圖

腳本 07：六種圖，每一種回答一個問題

細胞通訊（CellChat / LIANA）：三個前提

腫瘤研究最愛的下游，也是最常做錯的

同一個樣本裡



配體與受體必須來自同一位病人的同一個部位——不同病人的巨噬細胞跟惡性細胞不可能對話。
按樣本分開跑，再比較

兩端都要夠多細胞



預設門檻常是 10% 細胞表現；
環境 RNA 會製造假的配體。
SoupX 之後再跑，並只用 CNV
判定後的惡性細胞

結果是假說



RNA 層級的配體—受體共表現
不等於結合、不等於訊號。要有
第二種證據（空間、蛋白、擾
動）才能寫成「X 驅動 Y」

CellChat 在算什麼

CellChatDB：配體—受體資料庫（人類約 3,300 對）



分泌型 (Secreted)

細胞激素、生長因子：SPP1-CD44、TGFB1-TGFBR



ECM—受體

細胞外基質：COL1A1-ITGA/ITGB、LAMININ



細胞—細胞接觸

需要相鄰：PD-L1-PD-1、NOTCH-JAG、MHC-TCR

多亞單位受體（ITGAV+ITGB1）與協同／拮抗因子都寫在資料庫裡——這是 CellChat 與單純「兩個基因相乘」的差別

一對細胞群之間的「通訊機率」怎麼算

- ① 每群取配體 L 與受體 R 的「trimean」表現（比平均更抗離群，要求 $\geq 25\%$ 細胞表現）
- ② 質量作用定律： $P = L \cdot R / (K + L \cdot R)$ ，多亞單位取幾何平均；協同因子乘上去、拮抗因子除下來
- ③ 置換檢定：把細胞標籤隨機打亂 100 次，重算 P；真實 P 高於 95% 的隨機值才算顯著 ($p < 0.05$)
- ④ 把同一路徑（例如 SPP1 路徑的 3 對 L-R）的機率加總→路徑層級；再把所有路徑加總→群對群的總網路

輸出是三層：L-R 對→路徑→群對群。
後面每一種圖都是其中一層的某個切面

資料庫決定「哪些對可能」，表現量決定「哪些對成立」，置換檢定決定「哪些對不是巧合」。輸出三層：L-R 對、路徑、群對群

跑一次 CellChat：從 Seurat 物件到總網路（每個樣本各跑一次）

```
library(CellChat)
run_cc <- function(obj, label = "cc_label") {
  obj$samples <- factor(paste(obj$patient, obj$tissue)) # v2 要求 samples 欄
  cc <- createCellChat(obj, group.by = label, assay = "RNA") # 用 data 層
  cc@DB <- subsetDB(CellChatDB.human, search = "Secreted Signaling")
  cc <- subsetData(cc) |> identifyOverExpressedGenes() |>
    identifyOverExpressedInteractions()
  cc <- computeCommunProb(cc, type = "trMean", # 注意大小寫
    population.size = TRUE) # 群大小校正
  cc <- filterCommunication(cc, min.cells = 20) # < 20 顆的群不參與
  cc <- computeCommunProbPathway(cc) |> aggregateNet()
  netAnalysis_computeCentrality(cc)
}
core <- run_cc(subset(gbm4, tissue == "Tumor" & patient == "BT_S2"))
peri <- run_cc(subset(gbm4, tissue == "Periphery" & patient == "BT_S2"))
# 4 位病人 × 2 部位 = 8 個物件；lapply 跑完存成 list
```

三個關鍵：用 log-normalized 的 data 層、每個樣本分開跑、只用 CNV 判定後的標籤。約 5-15 分鐘一個樣本 | 腳本：07 §1



圖 1： netVisual_circle—— 鳥瞰整個網路

圖 1：netVisual_circle——整個網路的鳥瞰

示意／模擬資料

互動數 (Number of interactions)

互動強度 (Interaction weights)



怎麼看

每個節點一種細胞群；
節點大小=該群送出的總量

邊的顏色=來源 (sender)
；箭頭指向接收者

邊的粗細=顯著 L-R 對的
數目 (左) 或機率總和 (右)

左右不一致很常見：
對數多不代表強；
先看右圖找主軸，再回左圖


自環=同群之間 (惡
性→惡性的自分泌)

`groupSize <- table(cc@idents); netVisual_circle(cc@net$count, vertex.weight = groupSize)` 與 `cc@net$weight` 各畫一張。先看右圖找主軸

圖 2： netVisual_heatmap—— 誰送給誰

圖 2：netVisual_heatmap——誰送給誰

示意／模擬資料



怎麼看

列=送出的群、
欄=接收的群；顏色深=通訊強

右側長條=每列加總（誰最會送）
；上方長條=每欄加總（誰最會收）

GBM 的典型：惡性↔巨噬細胞是最亮的一對；惡性→內皮（VEGF）也常亮

比 circle 圖適合讀數字；
circle 圖適合看方向

netVisual_heatmap(cc, measure = "weight", color.heatmap = "Reds")。行是來源、欄是目標；兩側長條是加總。要引用數字用這張，看方向用 circle

路徑層級：先排序，再挑一條路徑拆開看

```
cc@ netP$pathways          # 顯著的路徑清單
netAnalysis_signalingRole_heatmap(cc, pattern = "outgoing", height = 8) # 圖 4 左
netAnalysis_signalingRole_heatmap(cc, pattern = "incoming", height = 8) # 圖 4 右
netAnalysis_signalingRole_scatter(cc)                                # 圖 4 散點

pw <- "SPP1"
netVisual_aggregate(cc, signaling = pw, layout = "circle") # 圖 3 左 (也可 "chord"、"hierarchy")
netAnalysis_contribution(cc, signaling = pw)                # 圖 3 右：哪對 L-R 撐起路徑
netVisual_heatmap(cc, signaling = pw, color.heatmap = "Reds") # 單一路徑的來源 × 目標
plotGeneExpression(cc, signaling = pw)                      # 該路徑所有基因的 violin：驗證表現
netAnalysis_signalingRole_network(cc, signaling = pw)       # sender / receiver / mediator / influencer
```


讀圖順序：signalingRole 找主角 → aggregate 看方向 → contribution 找具體 L-R → plotGeneExpression 驗證。路徑名稱以 cc@netP\$pathways 為準 | 腳本：07 §2

圖 3：一條路徑的方向與組成

圖 3：路徑層級——一條路徑的方向與組成

示意／模擬資料

SPP1 路徑：netVisual_aggregate (circle)




SPP1 是 GBM 教科書級的 TAM → 惡性訊號。看到這樣的圖，下一步不是寫進論文，是去畫 SPP1 與 CD44 的 violin 確認表現與比例

圖 4： signalingRole—— 每種細胞在每條路徑的角色

圖 4：netAnalysis_signalingRole_heatmap——每種細胞在每條路徑上扮演什麼角色

示意／模擬資料



讀法：一列一條路徑、一欄一種細胞；左圖找「誰在送」、右圖找「誰在收」。散點圖右上角是既送又收的樞紐（GBM 通常是惡性細胞與巨噬細胞）

這是通訊分析最有資訊量的一張：一眼看到惡性細胞送 VEGF / MIF / PTN、巨噬細胞送 SPP1 / TGFb / MHC-II。散點右上角是樞紐

落到具體配體—受體，然後比較兩個條件

```
# 圖 5：指定來源與目標群，列出顯著的 L-R 對
netVisual_bubble(cc, sources.use = c("MacroMG", "Malignant"),
  targets.use = c("Malignant", "MacroMG", "Vascular"),
  remove.isolate = TRUE)
sig3 <- head(intersect(c("SPP1", "MIF", "VEGF"),
  cc@netP$pathways), 3) # 名稱以 cc@netP$pathways 為準
netVisual_bubble(cc, signaling = sig3) # 只看幾條路徑


# 圖 6：兩條件比較——先合併
cc.m <- mergeCellChat(list(Core = core, Periphery = peri),
  add.names = c("Core", "Periphery"))
compareInteractions(cc.m, group = c(1, 2)) # 互動數
compareInteractions(cc.m, group = c(1, 2), measure = "weight")
netVisual_diffInteraction(cc.m, weight.scale = TRUE) # 差異 circle：紅增藍減
netVisual_heatmap(cc.m, measure = "weight") # 差異熱圖
rankNet(cc.m, mode = "comparison", stacked = TRUE, do.stat = TRUE) # Wilcoxon
netVisual_bubble(cc.m, sources.use = "MacroMG", targets.use = "Malignant",
  comparison = c(1, 2), angle.x = 45) # 同一對 L-R 在兩條件
```

四位病人各有一對物件；比較時要看「四位方向一致」的路徑，不是單一病人的。統計單位仍然是病人 | 腳本：07 §3-4

圖 5： netVisual_bubble—— 論文主圖層級的呈現

圖 5：netVisual_bubble——落到具體的配體與受體

示意／模擬資料




又大又黃才追；同一配體對多種受體會佔好幾列。追到具體的對之後，回到 Seurat 畫 FeaturePlot 與 VlnPlot 驗證

圖 6：核心 vs 邊緣——mergeCellChat 之後

圖 6：兩條件比較——mergeCellChat 之後的三張圖

示意／模擬資料



讀法

每位病人分開跑、再合併比較；粗體=兩條件差異顯著 (Wilcoxon)。
核心：SPP1、VEGF (缺氧、巨噬細胞)；邊緣：PTN、MHC-II (浸潤、與正常腦互動)

核心的互動更多更強（缺氧、巨噬細胞浸潤）；rankNet 粗體的路徑才是兩條件有差的。每位病人各跑一組，四位一致才寫

CellChat 之外： LIANA 共識與其他工具

方法之間結果差異很大；審稿人常要求至少兩種方法一致

工具	特色	輸出	何時用
CellChat（本課）	多亞單位、協同因子、路徑層級圖最完整	L-R、路徑、網路	預設選擇；要畫圖
LIANA+	一次跑 CellPhoneDB、NATMI、Connectome 等多種方法，取共識排名	L-R 的共識排名	要交叉驗證 CellChat 的結果
CellPhoneDB	最早、資料庫嚴謹（人類）	L-R + p 值	Python 流程；人類資料
NicheNet	問「哪個配體最能解釋目標細胞的表現變化」——用下游基因反推	配體活性 + 目標基因	有明確的「接收者變了什麼」（DE）時
空間驗證	Visium / Xenium 看配體與受體是否真的相鄰	共定位	寫「X 驅動 Y」之前

08

軌跡分析：狀態怎麼轉換


腳本 08：Slingshot + tradeSeq 主線；Monocle3 / Monocle2 比較與手動選起點

軌跡： pseudotime 與基因動態怎麼讀


軌跡分析：pseudotime 圖與基因動態圖怎麼讀

示意／模擬資料

Slingshot：主曲線 + pseudotime（一位病人的惡性細胞）



沿 pseudotime 變化的基因 (tradeSeq)



軌跡能相信的四個條件

- 1 只在「同一位病人的惡性細胞」內做
- 2 起點有生物學理由（例如 OPC 樣、或 RNA velocity 指向）
- 3 週期分數不主導軌跡（否則先回歸）
- 4 換 seed、換病人，主軸方向一致

只在同一位病人的惡性細胞內做；起點要有理由；週期不能主導；換 seed 與換病人方向一致。四條件不滿足，那條曲線就只是裝飾

Slingshot + tradeSeq：一位病人的惡性細胞

```
library(slingshot); library(tradeSeq)
m.all <- subset(gbm4, malignant == "malignant" & patient == "BT_S2")
m.all <- NormalizeData(m.all) |> FindVariableFeatures() |> ScaleData() |> RunPCA() |>
  FindNeighbors(dim.s = 1:15) |> FindClusters(resolution = 0.4) |> RunUMAP(dim.s = 1:15)
sce <- as.SingleCellExperiment(m.all)
sce <- slingshot(sce, clusterLabels = "seurat_clusters", reducedDim = "UMAP",
  start.clus = "2") # 起點：OPC 樣分數最高的群
pt <- slingPseudotime(sce)[,1]
FeaturePlot(m.all, features = "pt") # 先把 pt 存進 m.all$pt

# 沿 pseudotime 變化的基因 (負二項 GAM)
counts <- LayerData(m.all, layer = "counts")[VariableFeatures(m.all), ]
gam <- fitGAM(counts = counts, pseudotime = pt, cellweights = rep(1, ncol(counts)), nknots = 6)
assoc <- associationTest(gam); head(assoc[order(assoc$pvalue), ])
plotSmoothers(gam, counts, gene = "CD44")

# RNA velocity (可選)：需要loom (velocyto) → scVelo (Python)；用它決定方向與起點
```

Monocle3 是另一個常見選擇 (graph-based，允許分支)。無論哪個，起點與方向都要有獨立證據 | 腳本：08 §1

Monocle3 / Monocle2 : 起點選擇的兩種作法

```
# Monocle3 (最多人用; graph-based)
library(monocle3)
cds <- SeuratWrappers::as.cell_data_set(ma1) # 沿用 Seurat 的 UMAP 與分群
cds <- cluster_cells(cds) |> learn_graph(use_partition = FALSE)
# (a) 手動互動式: 跳出視窗讓你「點」起點——直觀, 但不可重現
cds <- order_cells(cds)
# (b) 腳本化: 把理由寫成程式碼——OPC 樣分數前 10 顆當 root, 可重現
root_cells <- colnames(ma1)[order(ma1$OPC1, decreasing = TRUE)[1:10]]
cds <- order_cells(cds, root_cells = root_cells)
plot_cells(cds, color_cells_by = "pseudotime", label_branch_points = TRUE)

# Monocle2 (經典 DDRTree; root_state 一樣是自己選)
cds2 <- reduce_dimension(cds2, method = "DDRTree") |> orderCells()
plot_cell_trajectory(cds2, color_by = "State") # 看圖決定哪個 State 當起點
cds2 <- orderCells(cds2, root_state = 3) # ← 手動填; 腳本版用分數選

cor(ma1$pt, ma1$pt_m3, method = "spearman") # 跨工具檢查: > 0.8 才可信
```

探索用手動點選、定稿用腳本化——手動每次點的不一樣, 不可重現。三套工具 (Slingshot / Monocle3 / Monocle2) 方向一致的結論才寫進論文 | 腳本: 08 §2-3

09



路徑與轉錄因子活性：誰在驅動

腳本 09：decoupleR / PROGENy（R、快）與 SCENIC（Python、慢，選配）

調控與活性：誰在驅動這群細胞

調控與活性：從「哪些基因變了」到「誰在驅動」

示意／模擬資料



兩者的差別

SCENIC 問「哪個轉錄因子在驅動這群」：
從共表現+motif 推 regulon，再算每顆細胞的活性

PROGENy/decoupleR 問「哪條訊號路徑活著」：
用擾動實驗學到的 footprint 基因，不是路徑成員基因

兩者都可以做 pseudobulk 後再比較條件——單位仍是病人

SCENIC 回答「哪個轉錄因子」，PROGENy / decoupleR 回答「哪條路徑活著」。兩者都可以 pseudobulk 後以病人為單位比較條件

decoupleR (R) 與 SCENIC (pySCENIC)

```
# 1. decoupleR + PROGENY: 每顆細胞的 14 條路徑活性
library(decoupleR)
net <- get_progeny(organism = "human", top = 500)
mat <- as.matrix(LayerData(gbm4, layer = "data"))
act <- run_mlm(mat, net, .source = "source", .target = "target", .mor = "weight")
act.w <- tidyr::pivot_wider(act, id_cols = source, names_from = condition,
                             values_from = score) |>
  tibble::column_to_rownames("source") |> as.matrix()
gbm4[["progeny"]] <- CreateAssayObject(act.w)
DefaultAssay(gbm4) <- "progeny"
FeaturePlot(gbm4, features = c("Hypoxia", "JAK-STAT"))
# 條件比較: 活性先平均到 病人 × 部位, 再做配對檢定 (單位 = 病人)

# 2. SCENIC: R 匯出loom → pySCENIC 三步 → 讀回 AUCell 矩陣
# pyscenic gm counts.loom tfs.txt -o adj.csv # 共表現 (GRNBoost2)
# pyscenic ctx adj.csv *.feather --annotations_fname motifs.tbl -o reg.csv
# pyscenic aucell counts.loom reg.csv -o auc.loom # regulon 活性
auc <- read.csv("output/tables/09_scenic_auc.csv", row.names = 1) # regulon × cell
gbm4[["scenic"]] <- CreateAssayObject(as.matrix(auc))
DoHeatmap(gbm4, features = c("SOX2(+)", "OLIG2(+)", "SPI1(+)", "CEBPB(+)",
                             assay = "scenic")
```

SCENIC 跑一次數小時; GBM 的經典結果是惡性 SOX2 / OLIG2、TAM 的 SPI1 / CEBPB。regulon 名稱後的 (+) 表示活化型 | 腳本: 09

10



反卷積與存活：以大型世代驗證

腳本 10：MuSiC + TCGA-GBM + KM / Cox——單細胞假說的出口

反卷積：把 $n = 4$ 帶到 $n = 500$

反卷積：把單細胞學到的「型別特徵」帶回幾百份 Bulk，換取統計功效

示意／模擬資料



這是 $n = 4$ 的正確出路：用單細胞產生假說（例如「巨噬細胞比例與預後有關」），用 TCGA 的 $n = 500$ 驗證。數字為示意，請以實跑為準

用你註釋好的單細胞當參考，估 TCGA 每份 Bulk 的型別比例，再做存活分析。這是單細胞研究最常見、也最有力的驗證路線

MuSiC 反卷積 + TCGA 存活

```
library(MuSiC); library(TCGAAbiolinks); library(survival); library(survminer)
# 1. 參考：本課的單細胞 (counts + celltype_l1 + patient)
ref <- as.SingleCellExperiment(BinLayers(gbm4))
# 2. Bulk: TCGA-GBM 的 counts 與臨床
q <- GDCquery("TCGA-GBM", data.category = "Transcriptome Profiling",
              data.type = "Gene Expression Quantification",
              workflow.type = "STAR - Counts")
GDCdownload(q, directory = "C:/GDCdata") # Windows: 路徑上限 260 字元
Bulk <- GDCprepare(q, directory = "C:/GDCdata") # → 用短路徑，否則整批解壓失敗
est <- music_prop(Bulk.mtx = assay(Bulk, "unstranded"), sc.sce = ref,
                  clusters = "celltype_l1", samples = "patient")
prop <- as.data.frame(est$Est.prop.weighted) # 樣本 × 型別
# 3. 存活：巨噬比例上下半
clin <- as.data.frame(cbindData(Bulk))[rownames(prop), ]
clin$mac_hi <- prop$Immunune > median(prop$Immunune)
fit <- survfit(Surv(time, event) ~ mac_hi, data = clin)
ggsurvplot(fit, pval = TRUE, risk.table = TRUE)
coxph(Surv(time, event) ~ mac_hi + age_at_index, data = clin)
```

BayesPrism、CIBERSORTx 是替代方案。Cox 模型要調整年齡、MGMT 等已知因子；比例是估計值，不要當真值 | 腳本：10

下游工具總表：問題 → 工具 → 輸入 → 最小證據

問題	工具	輸入	寫進論文前的最小證據
誰跟誰對話	CellChat、LIANA	同一樣本、CNV 後標籤、log-normalized	兩種方法一致、四位病人一致表現圖驗證
狀態怎麼轉換	Slingshot、Monocle3 scVelo	一位病人的惡性細胞	起點有理由 + 換 seed/ 病人一致
誰在驅動	SCENIC、decoupleR	counts (SCENIC) / data (decoupleR)	regulon 的目標基因在 DE 裡也動
在大世代成不成立	MuSiC、BayesPrism	單細胞參考 + Bulk counts	調整已知因子後仍顯著
空間上在哪	RCTD、cell2location	單細胞參考 + Visium	配體受體在空間上真的相鄰

常見錯誤總表

集	雷	一句話解法
Q1	把細胞數當樣本數	n 是病人；DE 用 pseudobulk
Q1	用 marker 判定惡性	marker 只定譜系；惡性判定需要 CNV 等多重證據
Q1	惡性四島當四種亞型	那是四位病人；狀態分數在病人內看
Q2	percent.mt 照抄 5%	median + 3×MAD，數字寫進方法段
Q2	doublet 群當免疫樣腫瘤細胞	分群後看每群 doublet 比例，整群移除
Q3	整合把惡性細胞的病人差異修掉	整合空間只註釋正常細胞；惡性回未整合空間
Q3	inferCNV 參考選到惡性細胞	參考 = 免疫 + 寡樹突；星狀細胞不行
Q3	把多位病人合併跑 CellChat	每個樣本分開跑；四位一致才寫
Q3	跨病人的惡性細胞畫軌跡	一位病人、CNV 之後、起點有理由

09

常見錯誤

三個會被審稿人直接退回的雷

錯誤一： inferCNV 的參考組選錯

雷是什麼

拿「Astrocyte」群當正常參考，因為它 marker 很像正常星狀細胞。



為什麼會踩

星狀細胞在教科書裡是正常腦細胞。

踩了會怎樣

GBM 的惡性細胞大半是 AC 樣狀態；參考組裡混了惡性細胞，chr7/chr10 的訊號被扣掉，全圖 CNV 歸零、惡性判定全滅。

錯誤二：用整合後的值做 DE 或 CNV

雷是什麼

整合完直接 FindMarkers 比核心 vs 邊緣，或把 integrated 值餵給 inferCNV。



為什麼會踩

整合後的物件看起來就是「乾淨的資料」。

踩了會怎樣

corrected 值不是表現量。DE 回 RNA counts 並 pseudobulk；inferCNV 要原始 counts。一行檢查：矩陣是整數嗎。

錯誤三：以 $n = 4$ 逕下臨床結論

雷是什麼

「邊緣的惡性細胞高表現基因 X，可作為浸潤的治療標靶。」



為什麼會踩

配對設計、pseudobulk、GSEA 都做對了，p 值也漂亮。

踩了會怎樣

方法對、功效與外推性不夠。四位病人能給你「候選」與「一致的方向」；要下結論，要更多病人與獨立驗證（如 TCGA 反卷積、空間資料）。

Q3 checklist

Q3 checklist：九格全勾，結果才能寫進論文



整合前先存未整合的圖與物件



整合空間只用來註釋正常型別



inferCNV 參考 = 免疫 + 寡樹突



惡性標籤三角驗證，
不確定者標 unresolved



pseudobulk 矩陣是
整數、每欄一個樣本



DESeq2 設計含 patient（配對）



每樣本點圖確認方向一致



GSEA 通過已知答案驗證



下一條路的資料前提已對照

九格全勾，結果才能寫進論文

一句話總結

**整合的目的是對齊各樣本的共同細胞型別；惡性細胞
帶病人特異的基因體變異，宜逐病人分析；
差異表達以病人為統計單位；下游分析各有其適用的
資料條件。**

加上 Q1、Q2 的六句，這就是腫瘤單細胞分析的骨架。

自測 1

跑 inferCNV 時，哪一組最適合當參考（正常）細胞？

- A 表現 GFAP 的星狀細胞群
- B 免疫細胞與寡樹突細胞
- C UMAP 上離惡性細胞最遠的群

答 B。參考組必須「確定沒有 CNV」。免疫與寡樹突細胞在 GBM 裡幾乎不可能是惡性的；星狀細胞可能就是 AC 樣的惡性細胞；UMAP 距離不是證據。

自測 2

四位病人的資料，整合之後惡性細胞混成一團。這代表？

- A 整合成功，可以直接做下游
- B 整合把病人特異的 CNV 生物學修掉了；惡性分析要回未整合空間
- C 這四位病人是同一種亞型

答 B。惡性細胞按病人分島是基因體差異，不是批次。整合空間只拿來註釋正常細胞。

自測 3

核心 vs 邊緣的惡性細胞 DE，DESeq2 的 design 該怎麼寫？

A ~ tissue

B ~ patient + tissue

C ~ tissue + n_cells

答 B。同一位病人同時有兩個部位，是配對設計；先吸掉病人差異再比部位，功效高很多。細胞數不是共變量，pseudobulk 已經處理了。

延伸課程

三個系列，依需求深入

A 系列 · 入門篇

觀念與判讀：實驗設計、圖表解讀、從結果到研究敘事。不需撰寫程式，適合建立整體框架與跨領域溝通。

B 系列 · 實作篇

以 PBMC 公開資料完整實作：從 FASTQ 與 Cell Ranger 到 Seurat 標準流程與各項下游分析，隨集附練習腳本。本課程各頁的「深入：Bx」即為對應索引。

C 系列 · 數學篇

方法背後的數學與統計：PCA 與降維、變異數穩定化、統計推論（pseudobulk 的理論基礎）、整合演算法的原理。

各系列皆為中英雙語；完整索引與連結見影片說明欄。

Q 系列到此結束

課程總結：一套完整的 scRNA-seq 分析骨架

練習腳本 R/00-10 與自測題庫隨課程提供。

接下來，將這套流程應用到你自己的資料——不限於腫瘤。

scRNA-seq 教學影片系列 · Q 系列 · 快速上手篇



[https://github.com/
Charlene717/scRNA-seq-
tutorial-Qseries](https://github.com/Charlene717/scRNA-seq-tutorial-Qseries)