

Q 系列 Q3

實作篇 II：多樣本整合 與下游分析


以四位 GBM 病人（核心 vs 浸潤邊緣）為練習資料。做 Q2 那份單一病人資料做不到的惡性判定，讓 DE 以病人為單位，然後選擇下游路線。

約 70 分鐘 | 前置：Q2 | 腳本：R/04-10 | 深入：B11-B17




[https://github.com/
Charlene717/scRNA-seq-
tutorial-Qseries](https://github.com/Charlene717/scRNA-seq-tutorial-Qseries)

同一個問題，兩種答案



長條為本課實跑；右側散點為示意



核心 vs 邊緣，同一種細胞差了哪些基因？ cell-level 說 3,486 個，pseudobulk 說 608 個。65 分鐘後我們就知道該信哪個

這一集的起點

多病人腫瘤資料要顧的環節不少。這一集聚焦其中三個：整合到什麼程度、誰是惡性、DE 的單位是什麼。

挑這三個，是因為它們最常在一開始就把後面的分析帶偏；顧好了，其他問題才有討論的基礎。

本集目標

- 1 把 4 位病人的資料合在一起，用 Seurat 預設整合（必要時比較 Harmony），以正負對照檢查整合有沒有不足或過頭
- 2 用 inferCNV 以免疫與寡樹突細胞為參考判定惡性細胞，三角驗證後寫進 metadata，並和作者的標籤與作者標籤比對
- 3 做組成分析、pseudobulk + DESeq2（配對設計）、GSEA，並用一張表決定下一條下游路

01

四位病人、八個樣本

腳本 04：載入 Smart-seq2 counts 與 GEO 的 metadata

練習資料： Darmanis et al. 2017

組織	4 位 GBM 病人，每位各取腫瘤核心（core）與浸潤邊緣（periphery）
細胞數	3,589 顆（通過作者 QC）
技術	Smart-seq2 全長定序（無 UMI，read counts）
已有標籤	7 種型別：惡性、OPC、星狀、寡樹突、神經元、血管、免疫
為什麼選它	多病人+有條件（core vs periphery）+有惡性標籤可對答案

實驗設計：4 × 2 配對



同一位病人的兩個部位可以配對比較：n = 4 對

這份資料有三樣 Q2 沒有的東西：多位病人、一個條件（核心 vs 邊緣）、作者的惡性標籤可以與作者標籤比對

Smart-seq2 和 10x 差在哪、哪裡一樣

10x 3' (Q2 的 GBM 5k)

Smart-seq2 (Q3 的 GSE84465)

計數單位	UMI 分子數	read counts (PCR 重複未去除)
每顆細胞的總量	5k-30k	50 萬-數百萬 reads
基因涵蓋	3' 端，1-3 千個基因	全長，4-8 千個基因
細胞數 / 成本	多、便宜	少、貴、每細胞資訊多
QC 差異	percent.mt 有效；doublet 要抓	percent.mt 仍有效；每孔一顆細胞，doublet 少
Seurat 流程	完全相同	完全相同 (NormalizeData 一樣適用)
pseudobulk	加總 UMI counts	加總 read counts (仍是整數，DESeq2 可用)

Seurat 流程完全相同；差別在計數單位、每顆細胞的資訊量，以及 doublet 幾乎不用擔心

文獻：Picelli S, et al. Nat Protoc. 2014;9(1):171-181. doi:10.1038/nprot.2014.006 | Zheng GXY, et al. Nat Commun. 2017;8:14049. doi:10.1038/ncomms14049

載入 counts 與 metadata

```
# GEO 補充檔 (約 20 MB) : 注意它其實是「空白分隔」, read.csv 會讀成 0 欄
cnt <- read.table(gzfile("data/GSE84465_GBM_All_data.csv.gz"), header = TRUE,
                  sep = " ", row.names = 1, check.names = FALSE)
bad <- c("no_feature", "ambiguous", "alignment_not_unique",
        "too_low_aQual", "not_aligned") # HTSeq 統計列
cnt <- cnt[!row.names(cnt) % in% bad, ]

# metadata 在 series matrix。不要用 getGEO (GSEMatrix = TRUE) : 暫存檔沒下載完整就會丟
# "parsing failed--expected only one 'series_data_table_begin'". 自己讀標頭列最穩。
sm <- "data/geo/GSE84465_series_matrix.txt.gz" # 00_setup.R 已下載
hdr <- grep("^!Sample_characteristics_ch1",
            readLines(gzfile(sm), warn = FALSE), value = TRUE)
meta <- as.data.frame(do.call(cbind, lapply(hdr, function(x)
      scan(text = sub("^![^\t]+\t", "", x), what = "", sep = "\t",
        quote = "\"", quiet = TRUE))))
```

getGEO 的 parseGSEMatrix 對這個 GSE 很容易失敗; 自己下載+讀標頭列反而穩定 | 腳本: 04 §1

建物件、快速 QC

```
# 欄位順序不保證 → 用「內容」找欄，不要寫死 ch1.1 / ch1.2 這種索引
get.val <- function(df, key) {
  hit <- sapply(df, function(v) any(grepl(paste0("^ ", key, ":"), v)))
  sub(paste0("^ ", key, ":"), "", df[names(df)[which(hit)[1]]])
}
meta$patient <- get.val(meta, "patient id"); meta$tissue <- get.val(meta, "tissue")
meta$celltype_author <- get.val(meta, "cell type")
meta$cell <- paste(get.val(meta, "plate id"), get.val(meta, "well"), sep = ".") # 例: 1001000173.G8
meta <- meta[match(colnames(cnt), meta$cell), ] # 對齊 counts 的欄名
gbm4 <- CreateSeuratObject(as.matrix(cnt), meta.data = meta, min.cells = 3, min.features = 500)
gbm4[["percent.mt"]] <- PercentageFeatureSet(gbm4, pattern = "^MT-")
table(gbm4$patient, gbm4$tissue)
```

	Periphery Tumor	
BT_S1	55	433
BT_S2	445	712
BT_S4	554	957
BT_S6	179	204

← 八個樣本都在，但大小差 17 倍

Smart-seq2 的 nFeature 動輒 4-8 千，下限用 500 而不是 200；分布用 VlnPlot 按病人看。八個樣本從 55 顆到 957 顆，這個不平衡做 DE 時會回來找我們 | 腳本：04 \$2

02


整合：校正強度的取捨

腫瘤資料的整合是兩難；先看未整合的圖

先跑一次不整合的流程，留基線

```
gbm 4 <- NormalizeData(gbm 4) |> FindVariableFeatures() |> ScaleData() |> RunPCA()
gbm 4 <- FindNeighbors(gbm 4, dims = 1:25) |>
  FindClusters(resolution = 0.5, cluster.name = "raw_clusters")
gbm 4 <- RunUMAP(gbm 4, dims = 1:25, reduction.name = "umap.raw")
DimPlot(gbm 4, reduction = "umap.raw",
  group.by = c("patient", "celltype_author"))
saveRDS(gbm 4, "output/rds/04_gbm 4_unintegrated.rds") # 之後惡性分析回來用這份
```


輸出示意



沒有基線就無法判斷整合改變了什麼。作者標籤這裡當「已知答案」用 | 腳本：04 §3 | 深入：B11

未整合基線透露的訊息

整合的兩難：修掉「病人效應」，也會修掉惡性細胞真實的病人差異



做法：整合後的空間只用來註釋正常細胞型別與對齊免疫細胞；惡性細胞的分析回到未整合空間、按病人分開看

示意／模擬資料

② 是理想：正常細胞混開、惡性細胞的病人結構還在，綠圈那一塊（跨病人共享的狀態）本來就該混。③ 是校正強度給太多時會落到的地方：連病人私有的那一部分都被抹平

整合方法地圖：修多強、要什麼、對腫瘤的風險

沒有最好的方法，只有跟問題相稱的修正強度

方法	原理	修正強度	適合	腫瘤資料的風險
Seurat CCA / RPCA (本課預設)	找跨樣本的錨點細胞對； Seurat v5 內建， IntegrateLayers 一行	RPCA 弱 CCA 強	樣本間型別重疊高時	CCA 最容易過度修正； 病人特有型別會被 塞進別人
Harmony (比較用)	在 PC 空間迭代把批 次質心拉近	中	多病人、多批次 快、省記憶體	theta 調高會把惡 性細胞硬混
scVI / scANVI	變分自編碼器，批次當條件	可調	大型圖譜、 跨技術（10x + Smart-seq2）	需 GPU 與 Python 潛在空間難解釋
不整合 + 拆開分析	正常細胞用整合空間； 惡性細胞每位病人各自分析	—	腫瘤研究的主流做法	跨病人比較惡性狀態要靠 分數（Neftel）， 不靠分群

文獻：Stuart T, et al. Cell. 2019;177(7):1888–1902.e21. doi:10.1016/j.cell.2019.05.031 | Korsunsky I, et al. Nat Methods. 2019;16(12):1289–1296. doi:10.1038/s41592-019-0619-0

整合： Seurat 預設先跑， Harmony 當比較

```
gbm 4[["RNA"]] <- split(gbm 4[["RNA"]], f = gbm 4$patient) # 每位病人一個 layer
gbm 4 <- NormalizeData(gbm 4) |> FindVariableFeatures() |> ScaleData() |> RunPCA()
# (a) Seurat 預設：CCA 錨點 (大資料可換 RPCA Integration)
gbm 4 <- IntegrateLayers(gbm 4, method = CCAIntegration,
  orig.reduction = "pca", new.reduction = "integrated.cca")
# (b) 比較： Harmony (Seurat 整合不理想時的替代方案)
gbm 4 <- IntegrateLayers(gbm 4, method = HarmonyIntegration,
  orig.reduction = "pca", new.reduction = "harmony")
gbm 4 <- JoinLayers(gbm 4)
for (red in c("integrated.cca", "harmony")) { # 同 dims / resolution 才能比
  tag <- sub("integrated.", "", red, fixed = TRUE)
  gbm 4 <- FindNeighbors(gbm 4, reduction = red, dims = 1:25,
    graph.name = paste0(tag, "_snn")) |>
    FindClusters(graph.name = paste0(tag, "_snn"), resolution = 0.5,
    cluster.name = paste0(tag, "_clusters")) |>
    RunUMAP(reduction = red, dims = 1:25,
    reduction.name = paste0("umap.", tag))
}
DimPlot(gbm 4, reduction = "umap.cca", group.by = "patient") |
DimPlot(gbm 4, reduction = "umap.harmony", group.by = "patient")
```

整合只新增 reduction，表達值一個都沒動；DE 永遠回 RNA counts。兩個都跑、用同一套正負對照與 LISI 比——這份資料選 Seurat CCA | 腳本：04 §4 | 深入：B11

文獻：Stuart T, et al. Cell. 2019;177(7):1888-1902.e21. doi:10.1016/j.cell.2019.05.031 | Korsunsky I, et al. Nat Methods. 2019;16(12):1289-1296. doi:10.1038/s41592-019-0619-0

整合品質的三道檢查：哪些該混、哪些該留、表現量有沒有被動到

期望看到（通過）

警訊（失敗）

● 正對照：免疫細胞（巨噬、T）	✓ 四位病人混合 → 批次效應修掉了	⚠ 仍按病人各自成群 → 整合不足
● 正對照：寡樹突、血管	✓ 跨病人混合	⚠ 仍按病人各自成群
● 負對照：惡性細胞	✓ 病人特異的那一部分還在 （共享狀態混在一起是正常的）	⚠ 連私有的部分都被抹平，四位病人變成同質的一團 → 整合過頭
● 第三道：已知 marker 檢查	✓ PTPRC/SOX2/MBP/PECAM1 整合前後標到同一群細胞	⚠ marker 的高低被拉平或換了位置 → 整合動到的不只是座標


負對照的標準不是「病人有沒有完全分開」——共享狀態本來就會混；要問的是「私有的那一塊還在不在」。

這份資料的病人熵（上限 1.386）：免疫 0.79→1.01 過關；惡性 0.17→1.09
沒過——比免疫還高，等於連私有事件都被抹平 | 腳本：04 §4

LISI：把「混得好不好」變成一個數字

示意／模擬資料

① 先看一顆細胞的鄰居



鄰居全是同一位病人

iLISI ≈ 1.0



四位病人均勻混合

iLISI ≈ 4.0

② 用什麼公式算

$$LISI = \frac{1}{\sum_i p_i^2}$$

p_i = 鄰居裡第 i 位病人所佔的比例（以距離加權，perplexity 預設 30）。這就是 inverse Simpson 指數——生態學拿它算「有效物種數」，這裡算「有效病人數」。

範圍：1（全是同一位）到 N （ N 位病人均勻混合）。這份資料 $N=4$ 。

③ 兩種用法，方向相反

iLISI

拿「病人」當標籤。整合後應該變高——批次混開了。

cLISI

拿「細胞型別」當標籤。應該維持接近 1——型別沒有被融掉。

讀的時候要小心：

- 1 只出現在一位病人身上的稀有型別，iLISI 天生就低——那不是整合不足。
- 2 惡性細胞的 iLISI 衝高不是好消息：那代表病人特異的部分被抹掉了。

Korsunsky et al. Nat Methods 2019;16:1289–1296 (Harmony 與 LISI) ；比較見 Tran et al. Genome Biol 2020;21:12

iLISI 高＝批次混得比較開，cLISI 接近 1＝型別沒被融掉。兩個都只是「混合程度」的指標，不能單獨證明整合在生物學上是對的：稀有型別的 iLISI 天生低，惡性細胞的 iLISI 衝高反而是壞消息

文獻：Korsunsky I, et al. Nat Methods. 2019;16(12):1289–1296. doi:10.1038/s41592-019-0619-0

把「混得好不好」變成數字：每群病人組成、LISI

```
# 1. 每個整合群裡各病人佔多少：正常細胞的群應該四位都有
round(prop.table(table(gbm_4$cca_clusters, gbm_4$patient), 1), 2)

# 2. LISI: 一顆細胞的鄰居裡「有效病人數」 (1 = 全是同一位, 4 = 四位均勻)
library(lisi)
for (red in c("pca", "integrated.cca", "hamony")) {
  emb <- Embeddings(gbm_4, red)[1:25]
  gbm_4[[paste0("lisi_", sub("integrated.", "", red, fixed = TRUE))]] <-
    compute_lisi(emb, gbm_4@meta.data, "patient")$patient
}
gbm_4@meta.data > group_by(celltype_author) >
  summarise(across(starts_with("lisi_"), ~ median(x)))
```

celltype_author	lisi_pca	lisi_cca	lisi_hamony	
Immune cell	1.22	1.61	1.87	← 正對照：整合後混得比較開
Oligodendrocyte	1.26	2.00	1.91	
OPC	1.28	1.96	1.90	
Neoplastic	1.00	1.64	1.76	← 負對照：越接近 1 越保得住病人差異

正常細胞要往病人數（4）走、惡性細胞要留在 1 附近。這份資料兩個方法都把惡性混掉一些；CCA 混得比較少、正常細胞又沒輸——所以選 CCA | 腳本：04_s5

整合與分群的評估指標：各自量什麼、什麼時候會騙人

沒有一個指標單獨可信；整合要同時看「批次混得夠」與「型別沒被融掉」兩件事

指標	量什麼	要什麼輸入	好的方向	什麼時候會騙人
iLISI / cLISI	一顆細胞的鄰居裡有幾個有效批次 (i) / 幾個有效型別 (c)	嵌入 + 批次 (c 還要型別)	iLISI 高 cLISI 接近 1	稀有型別本來就只出現在一位病人身上，iLISI 天生低——不是沒整合好
kBET	局部鄰域的批次組成，和整體比例不一致 (拒絕率)	嵌入 + 批次	拒絕率低	各樣本的型別組成本來就不同 (腫瘤幾乎都是)，一定會被拒絕
ASW (輪廓係數)	批次 ASW：批次分得開不開；型別 ASW：型別分得開不開	嵌入 + 標籤	批次 ASW 低 型別 ASW 高	只看幾何形狀；細長或彎曲的群 (分化中的細胞) 分數天生就差
ARI / NMI	分群結果與一組參考標籤的一致程度	兩組標籤	越高越好	要有「正確答案」才能算；腫瘤資料通常沒有，只能拿作者標籤當近似
Purity	每一群裡最大宗的型別佔多少比例	分群 + 型別	越高越好	群切得越碎越高—— resolution 調到 3.0 每群都很純，但沒有意義
正負對照 (本課)	該混的 (免疫) 有沒有混、該分的 (惡性) 有沒有保住	嵌入 + 型別 + 病人	兩邊都成立	要自己指定對照組；但這是腫瘤資料唯一真正可信的一項

文獻：Luecken MD, et al. Nat Methods. 2022;19(1):41-50. doi:10.1038/s41592-021-01336-8 | Büttner M, et al. Nat Methods. 2019;16(1):43-49. doi:10.1038/s41592-018-0254-1 | Tran HTN, et al. Genome Biol. 2020;21(1):12. doi:10.1186/s13059-019-1850-9

腫瘤資料的整合原則

**整合後的空間只拿來註釋正常細胞、對齊免疫細胞；
惡性細胞的分析回到未整合空間，按病人分開看。**

這不是折衷，是兩種細胞本來就有不同的統計結構。多數腫瘤論文（Tirosh、Neftel、Puram）都這樣做。

另一條路：把細胞投到參考圖譜上

當我們有一份好的參考時，註釋不必從頭來——正常細胞尤其適合

Azimuth



把我們的細胞投到已註釋的參考（PBMC、人腦、肺……）上，直接繼承標籤與 UMAP 座標。免疫細胞亞群用它最省事

scArches



在參考模型（scVI / scANVI）上「續訓」我們的資料，不用重跑整個圖譜；跨技術也行。Python 生態

惡性細胞投不上去



參考圖譜裡沒有這位病人的腫瘤。惡性細胞投上去只會得到「最像的正常型別」——跟 SingleR 一樣，是提醒不是答案

03

細胞身分判定：以 inferCNV 判惡性為例

腳本 05：惡性判定——換一份撐得住的資料才做得成

三件輸入： counts、註釋、基因座標


```
library(infercnv)      # BiocManager::install("infercnv")
refs <- c("Immune cell", "Oligodendrocyte")
ann <- data.frame(row.names = colnames(gbm4),
                  group = ifelse(gbm4$celltype_author %in% refs,
                                gbm4$celltype_author,
                                paste0("obs_", gbm4$patient)))
write.table(ann, "data/infercnv_annot.txt", sep = "\t",
            colnames = FALSE, quote = FALSE)
# 基因座標檔：官方提供 hg38 gencode 版本（見腳本 05 的下載連結）
cts <- LayerData(gbm4, layer = "counts")
obj <- CreateInfercnvObject(raw_counts_matrix = cts,
                           annotations_file = "data/infercnv_annot.txt",
                           gene_order_file = "data/hg38_gencode_v27.txt",
                           ref_group_names = refs)
obj <- infercnv::run(obj, cutoff = 1,      # Smart-seq1 ; 10x 0.1
                    out_dir = "output/rds/05_infercnv",
                    cluster_by_groups = TRUE, denoise = TRUE, HMM = FALSE)
```

參考組必須是「確定正常」的細胞：免疫與寡樹突最安全。星狀細胞不行——它可能就是惡性的 | 腳本：05 §1 | 深入：B16

文獻：inferCNV of the Trinity CTAT Project. github.com/broadinstitute/inferCNV | Patel AP, et al. Science. 2014;344(6190):1396-1401. doi:10.1126/science.1254257

inferCNV 熱圖怎麼讀

示意／模擬資料



chr7 增加、chr10 缺失是 GBM 的教科書事件，四位病人共有；其餘每位病人各有私有事件——這就是 Q1 說的「惡性細胞多半按病人分群」的基因體原因

inferCNV 的關鍵參數：平台不同，數字不同

最常出錯的是 cutoff 抄錯平台；其次是參考組選錯（錯誤一）

參數	意思	Smart-seq2	10x	提醒
cutoff	基因平均表現低於此值就不用	1	0.1	10x 用 1 會把基因幾乎全丟掉，熱圖一片空白
ref_group_names	誰是「確定正常」	Immune + Oligodendrocyte	同	每組至少 50-100 顆 別用星狀細胞
window_length	沿基因體平滑的視窗（基因數）	101	101	越大越平滑 小片段事件看不到
HMM / denoise	把連續訊號切成離散 CNV 狀態	i6 ，可開	i6 ，可開	HMM 慢 本課用分數 + 相關代替
cluster_by_groups	觀察組按什麼分開畫	按病人	按樣本	按病人畫才看得到私有事件

文獻：inferCNV of the Trinity CTAT Project. github.com/broadinstitute/inferCNV


從熱圖到兩項量化指標

```
# CNV 矩陣直接從 run() 回傳的物件拿。不要去讀 infercnv.observations.txt --  
# 那兩個文字檔只有 plot_cnv(write_expr_matrix = TRUE) 才會寫，run() 預設不寫。  
obj <- readRDS("output/rds/05_infercnv/run.final.infercnv_obj") # R 重開過才需要  
cnv.all <- obj@expr.data # 基因 × 細胞，已平滑、已 denoise、以參考為中心  
  
cnv.score <- colMeans((cnv.all - 1)^2) # ① 偏離參考的程度  
top <- names(sort(cnv.score, decreasing = TRUE))[1:200]  
malprofile <- rowMeans(cnv.all[, top]) # 最像惡性的 200 顆平均 profile  
cnv.cor <- apply(cnv.all, 2, cor, y = malprofile) # ② 與惡性 profile 相關  
  
gbm4$cnv.score <- cnv.score[colnames(gbm4)]  
gbm4$cnv.cor <- cnv.cor[colnames(gbm4)]  
FeatureScatter(gbm4, "cnv.score", "cnv.cor", group.by = "celltype_author")
```

兩個維度的想法來自 Tirosh 2016 / Neftel 2019；本課的參考 profile 是自建的簡化版，不是原文分類器 | 腳本：05 \$2

每顆細胞兩個數字，四個象限

示意／模擬資料



三角驗證：三項獨立證據都到齊才定案

① CNV

分數高 + 與同病人惡性 profile 相關高

② 分群

多半按病人各自成群；正常細胞則跨病人混合

③ marker

膠質譜系 (SOX2、OLIG2) 而非免疫／血管

寫進 metadata

malignant/normal/unresolved 三種標籤，
不確定的不要硬判

雙軸判定出自 Tirosh et al. Science 2016;352:189–196；三角驗證見 Neftel et al. Cell 2019;178:835–849

右上是惡性、左下是正常、中間標 unresolved。不確定的不要硬判——審稿人寧可看到誠實的灰色地帶

文獻：Tirosh I, et al. Science. 2016;352(6282):189–196. doi:10.1126/science.aad0501

三角驗證：寫入 metadata，與作者標籤比對

```
ref.cell <- gbm 4$celltype_author%in% refs # 閾值由「確定正常」的參考組長出來
s.hi <- quantile(gbm 4$cnv.score[ref.cell], 0.99) # 正常的 CNV 分數上限
c.hi <- quantile(gbm 4$cnv.cor[ref.cell], 0.99) # 正常的相關上限，超過才談惡性
c.lo <- quantile(gbm 4$cnv.cor[ref.cell], 0.90) # 低於這條才算「明確正常」
gbm 4$malignant <- with(gbm 4@meta.data, ifelse(
  cnv.score > s.hi & cnv.cor > c.hi, "malignant",
  ifelse(cnv.score <= s.hi & cnv.cor < c.lo, "normal", "unresolved")))
# 第三項證據：譜系。免疫／血管／寡樹突／神經元被標惡性，一律改 unresolved
gbm 4$malignant[gbm 4$malignant == "malignant" & gbm 4$celltype_author%in%
  c("Immune cell", "Vascular", "Oligodendrocyte", "Neuron")] <- "unresolved"
table(gbm 4$malignant, gbm 4$celltype_author)
```

	Neoplastic	Astrocyte	OPC	Oligodendrocyte	Immune cell	Vascular	Neuron
malignant	高	少數	少數	0	0	0	0
normal	少數	多數	多數	全部	全部	全部	多數
unresolved	...						

和作者的 Neoplastic 標籤比對：本課實跑一致率 87.6%、精確率 99.4%、召回率 59.1%。不一致的那幾顆值得看——常是浸潤邊緣的細胞 | 腳本：05 §3

CNV 以外的惡性證據

CNV 弱的腫瘤（兒童腦瘤、部分血液腫瘤、近二倍體的癌）要換獨立證據

突變與等位基因



Smart-seq2 讀得到編碼區的 SNV（IDH1 R132H、TP53）；10x 只在 3' 端偶爾抓到。

HoneyBADGER、Numbat 用等位基因失衡補強 CNV

第二個 CNV 工具



copyKAT 不需要參考組、SCEVAN 全自動；跟 inferCNV 三者一致的細胞才寫 malignant。不一致的留在 unresolved

表現程式與病理



Neftel 狀態分數高、增殖高、跟任何正常型別都不像；加上病理的免疫染色（例如 IDH1 R132H 抗體）。這些是輔助，不是單獨的證據

04


組成：核心 vs 邊緣有什麼不同

腳本 06a §1：比例是組成資料，單位是病人

每位病人、每個部位的型別比例

```
gbm 4$type <- ifelse(gbm 4$malignant == "malignant", "Malignant", gbm 4$celltype_author)
prop <- gbm 4@meta.data %>% dplyr::count(patient, tissue, type) %>%
  group_by(patient, tissue) %>% mutate(frac = n / sum(n))
ggplot(prop, aes(tissue, frac, fill = type)) + geom_col() +
  facet_wrap(~ patient, nrow = 1) + theme_classic()
library(speckle); library(linma) # 檢定：單位是樣本（8 個）、配對設計
p8 <- getTransformedProps(gbm 4$type, paste(gbm 4$patient, gbm 4$tissue, sep = "_"),
  transform = "logit")$TransformedProps
pat <- sub("_[^_]*$", "", colnames(p8)) # 病人 ID 含底線，從最後一段切
tis <- factor(sub(".*_", "", colnames(p8)), c("Periphery", "Tumor"))
topTable(eBayes(lmFit(p8, model.matrix(~ pat + tis))), coef = "tisTumor", n = Inf)
```


輸出示意



「邊緣的惡性細胞比例較低」要用 propeller / scCODA 檢定， $n = 8$ 個樣本；直接對比例做 t-test 是錯的 | 腳本：06a §1 | 深入：B12

組成圖：每位病人一組

示意／模擬資料



比例是組成資料

邊緣的惡性細胞「變少」，可能只是因為正常腦組織變多。要檢定比例差異，用 propeller/scCODA，且以病人為單位

四位病人方向一致才算數。比例是封閉的：一種細胞變少，其他的必然變多

組成分析的三件事：閉合、配對、單位

閉合



比例加總是 1：惡性細胞減少，免疫細胞「自動」增加。所以檢定要在 logit 或 CLR 尺度做（propeller、scCODA），不能對原始比例做 t-test

配對



核心與邊緣來自同一位病人，配對設計把病人間的差異扣掉，功效大增。propeller 用 $\sim$ patient + tissue 的設計矩陣即可

單位是樣本



$n = 8$ 個樣本（ 4×2 ），不是 3,589 顆細胞。卡方檢定在細胞層級做，p 值會小到荒謬——跟錯誤一同一個錯


05

差異表達： 每種細胞各自比核心 vs 邊緣

腳本 06a (pseudobulk 主線) 與 06b (樣本太少時的 cell-level 備案)


為什麼 cell-level 檢定會給出兩千個基因

cell-level 檢定看到的



n = 1,200 vs 1,200 「觀察值」

真正的設計




n = 4 對 (配對)

同一位病人的細胞共享基因體與 CNV，彼此不獨立。把細胞當觀察值 = pseudoreplication，p 值會小到不像話

同一位病人的惡性細胞共享同一套 CNV，彼此高度相關。真正的設計是 4 對，不是 2,400 個觀察值

pseudobulk 的五步

pseudobulk：把單細胞資料變回「每個樣本一列」，再用成熟的 Bulk 統計



一行抓雷：sum(mat != round(mat)) 必須是 0。不是 0 代表我們加總到了 data / scale.data / integrated 層

只取一種細胞——否則我們比的是組成（邊緣的正常腦細胞比較多），不是那種細胞的變化

每種細胞型別各自比：為什麼、門檻是什麼

混在一起 = 比組成

核心 vs 邊緣的差異，
每一種細胞都不一樣。
全部細胞一起做 DE，
前十名會是
MBP、PLP1——那只是邊緣
的寡樹突比較多

兩個門檻

MIN_CELLS = 20：
每個「病人 × 部位」至少 20
顆才算一個 pseudobulk
樣本，太少的整格丟掉。
MIN_PAIRS = 2：
至少兩位病人兩個部位都有，
配對設計才成立

這份資料只有一種型別過關

四位病人的邊緣加起來只有 31
顆惡性細胞（最多的一位 17
顆），沒有人到 MIN_CELLS
= 20——惡性細胞的核心 vs
邊緣，這份資料做不了。
真正跑得出來的是 Immune
cell：4 對病人、608
個顯著基因

把 pseudobulk + 配對 DESeq2 包成函式，對每種型別呼叫

```
pb_de <- function(obj, type, m.in.cells = 20, m.in.pairs = 2) {  
  sub <- subset(obj, cells = colnames(obj)[obj$type == type])  
  n <- table(sub$patient, sub$tissue)  
  ok <- names(which(rowSums(n >= m.in.cells) == 2)) # 兩部位都夠的病人  
  if (length(ok) < m.in.pairs) return(NULL)  
  sub <- subset(sub, cells = colnames(sub)[sub$patient %in% ok])  
  pb <- as.matrix(AggregateExpression(sub, assays = "RNA",  
    group.by = c("patient", "tissue"))$RNA)  
  stopifnot(sum(pb != round(pb)) == 0) # 一行抓雷：必須是整數  
  coldata <- data.frame(patient = sub("_[^_]*$", "", colnames(pb)),  
    tissue = factor(sub(".*_", "", colnames(pb)),  
      levels = c("Periphery", "Tumor")))  
  dds <- DESeqDataSetFromMatrix(pb[rowSums(pb) >= 10, ], coldata,  
    design = ~ patient + tissue)  
  raw <- results(dds, name = "tissue_Tumor_vs_Periphery") # stat → GSEA、火山圖  
  shr <- lfcShrink(dds, coef = "tissue_Tumor_vs_Periphery", type = "ashr")  
  list(res = data.frame(gene = rownames(raw), log2FC = raw$log2FoldChange,  
    log2FC_shrunk = shr$log2FoldChange, stat = raw$stat,  
    padj = raw$padj), pb = pb, coldata = coldata)  
}  
de <- lapply(types, function(ty) pb_de(gbm4, ty)); names(de) <- types
```

~ patient + tissue：配對設計先吸掉病人差異。病人 ID 含底線，拆欄名要從最後一段切 | 腳本：06a §2 | 深入：B12

文獻：Love MI, Huber W, Anders S. Genome Biol. 2014;15(12):550. doi:10.1186/s13059-014-0550-8

一個 DE 結果、三種 log2FC：哪個用在哪裡



收縮（shrinkage）是把低表現、高變異基因的誇大 FC 往 0 拉；拉多用力，方法差很多

欄位	怎麼來	特性	用在
未收縮 log2FC	results(dds) 的 log2FoldChange	低 count 基因：FC 很大、SE 也很大	火山圖的 x 軸：形狀才正常
stat (Wald)	$\log_2FC \div SE$	同時帶效應量與不確定性，很少同分	GSEA 的排序統計量
log2FC_shrunk (ashr)	lfcShrink(type = "ashr")	小 n 穩定；保留大效應、壓小雜訊	報告效應量、挑基因做驗證
apecglm (本例不適用)	lfcShrink(type = "apecglm")	本例 n = 8 時收縮特別強，幾乎所有基因被壓成同一值 → 火山圖變一根直柱、GSEA 全是同分（收縮強度看資料，不是通則）	樣本多 (≥ 3 vs 3、count 充足) 時才用

文獻：Love MI, Huber W, Anders S. Genome Biol. 2014;15(12):550. doi:10.1186/s13059-014-0544-2

報告時證明差異在病人層級一致

示意／模擬資料





左邊這種圖比火山圖更有說服力；右邊這種在 cell-level 檢定裡照樣「極顯著」

每位病人一條線（示意圖；SLC2A1 是本課實跑的顯著基因，log2FC 5.7、padj 3.6e-12）。左邊這種圖比火山圖更有說服力；右邊這種在 cell-level 檢定裡照樣「極顯著」

火山圖怎麼讀：先看形狀，再找原因


三種形狀線索，以及該回頭查什麼

示意／模擬資料




線索 1 | 大量點擠成一根直柱

先問畫的是哪一種 LFC。若是收縮後的 LFC：可能是大量 effect size 被 shrink toward 0 (小 n 用 `apeglm` 常見) → 拿未收縮的 LFC 對照著看。若畫的本來就是未收縮 LFC (本課的作法)，那就不是 shrinkage → 回查 LFC 的計算方式、rounding 與繪圖流程。



線索 2 | 幾乎全部落在單側

不一定是錯誤。可能是真實的方向性變化，也可能來自樣本不平衡、library size 差異、低 counts／大量零值、outlier 樣本，或細胞組成差異。→ 回查 sample-level counts、每個樣本的細胞數與個別樣本表現。



線索 3 | 少數點飛到 $|\log_2 \text{FC}| > 10-20$



通常代表其中一組的表現量接近零。不要把它讀成「表現量增加幾百萬倍」。→ 回查原始／pseudobulk counts、樣本數與細胞組成，確認不是少數幾顆細胞或一個樣本撐起來的。

火山圖是 QC 線索，不是診斷結果：左右不對稱本身不是錯，生物效應本來就可能偏向單一方向；真正要停下來的是極端或不合理的分布型態。x=未收縮 $\log_2 \text{FC}$ 、y= $-\log_{10}(\text{padj})$ ，每種細胞型別各畫一張 (腳本 06 § 3)。

形狀是線索，不是診斷：直柱 → 先確認畫的是收縮還是未收縮 LFC；單側 → 可能是真實方向，也可能是樣本不平衡或 outlier；極端 $|\log_2 \text{FC}|$ → 通常是一組接近零，回查 counts | 腳本：06a § 3

跑兩萬次檢定：多重比較與 FDR

示意／模擬資料



同一份 p 值，三種處理

不校正

約 1,006 個是假陽性

1,196

Bonferroni

幾乎不會錯，但 200 個真訊號只抓到這些

78

BH (padj)

約 5 個是假的，接近說好的 5%

138


padj = 0.05 是什麼意思

「在我宣告顯著的這一批基因裡，大約 5% 是假的」——這是整批的錯誤率，不是「這一個基因有 5% 的機率是假的」。

所以 DE 表要報 padj、富集結果要報 p.adjust，而且校正的範圍就是「這一次跑的所有檢定」
——每種細胞型別各自跑一次 DESeq2，就各自校正各自的；不要把六個型別的 p 值倒在一起再校正一次。

BH 不是「讓 p 值變好看」，是換一個問題：不再控制「有沒有任何一個假陽性」，改成控制「這一批裡假陽性佔幾成」——這才是基因體資料要的 | 腳本：06a §2

同一份 DE 結果、兩種富集問法：ORA 數比例，GSEA 看排序



兩種都跑：GSEA 當主結果，ORA 上調／下調分開做當交叉驗證。同一個 pathway 兩邊都出現，才寫進結論

GSEA 不切閾值、全部基因貢獻證據——小 n 的首選；ORA 要先有夠多顯著基因、背景要對。
兩種都跑，同一條 pathway 兩邊都出現才寫進結論

文獻：Subramanian A, et al. Proc Natl Acad Sci USA. 2005;102(43):15545-15550. doi:10.1073/pnas.0506580102 | Wu T, et al. Innovation (Camb). 2021;2(3):100141. doi:10.1016/j.xinn.2021.100141

三個基因集資料庫： Hallmark、GO、KEGG


都從 msigdb 拿，同一套 fgsea 跑；ORA 用 clusterProfiler 的 enrichGO / enrichKEGG

資料庫	內容與大小	優點	注意
Hallmark (H)	50 個精選、彼此少重疊的生物程式：缺氧、EMT、干擾素、G2M...	先看這個：一頁講得完、結果最好解讀、幾乎不會互相冗餘	只有 50 條，細節（哪條訊號、哪個代謝分支）問不到
GO BP (C5)	約 7,500 個 BP 詞條 階層式、高度重疊	最細；ORA 的預設語言；離線就能跑（org.Hs.eg.db）	同一件事會以十個詞條出現——先 simplify()；命中 3-5 個基因的詞條再顯著也別寫進結論
KEGG (C2 CP)	約 190 條代謝與訊號路徑，有路徑圖	代謝問題（糖解、OXPHOS）最直觀； pathview 能畫在路徑圖上	enrichKEGG 要連網；很多是疾病路徑（「阿茲海默症」）不代表機制；msigdb 的是 legacy 版

文獻：Liberzon A, et al. Cell Syst. 2015;1(6):417-425. doi:10.1016/j.cels.2015.12.004

GO 為什麼會吐出二十條都在講同一件事的詞條

GO 是有向無環圖，不是清單



一個 CD3E，會同時被算進上面每一層

箭頭是 is_a/part_of。ORA 對每一個詞條各做一次 Fisher 檢定，父項與子項共用同一批基因——所以顯著的詞條會一串一串地出現。

沒去冗餘的 GO 結果長這樣

- T cell activation
- lymphocyte activation
- leukocyte activation
- cell activation
- T cell differentiation
- cytokine production
- regulation of cytokine production
- response to hypoxia

綠色這五條在講同一件事
(同一族的父子項)

八條詞條、三組顏色：
免疫活化、細胞激素生成、缺氧


三個處理方式

- 1 clusterProfiler 的 simplify(cutoff=0.7)：用語意相似度把同族詞條併成一條代表
- 2 Metascape：先把詞條聚類再報告，一族只留最顯著的那一條當標題
- 3 報告時 BP/CC/MF 分開列；同一族只寫最具體的那一條，其餘放補充資料

GO 是階層圖不是清單：父項與子項共用同一批基因，ORA 又對每個詞條各檢定一次，同一族就整串顯著。報告前一定要去冗餘 | 腳本：06a §4

GSEA 內部：ES 曲線、峰值與 leading edge

示意／模擬資料



紅色區間裡的成員基因=leading edge：
撐起這條路徑的核心基因，寫進論文的就是這一串

讀 GSEA 前要知道的四件事

- 1 排序指標決定一切。本課用 $\text{sign}(\log_2\text{FC}) \times -\log_{10}(p)$ ；bulk GSEA 常用 signal-to-noise。換指標，排序就換，結論可能跟著換——所以要寫進 methods。
- 2 p 值來自置換檢定。樣本數少（pseudobulk 只有 4 位病人）時要用 gene_set 置換，不能用 phenotype 置換——後者需要夠多樣本才有意義。
- 3 NES 是把 ES 除以隨機分布的平均，讓不同大小的基因集可以互相比較。正負只代表方向。
- 4 leading edge 才是可查證的東西。只寫「缺氧路徑上調」沒有資訊量；寫「缺氧路徑上調，leading edge 是 VEGFA、CA9、SLC2A1」才有。

GSEA 不切閾值，改看「這組基因是不是集中在排序的一端」。要寫進論文的不是 pathway 名字，是 leading edge 那一串基因 | 腳本：06a §4

GSEA：三個資料庫、每種型別，一個迴圈


```
library(fgsea); library(msigdb)
m_sig <- function(coll, sub = NULL) {
  m <- msigdb(species = "Homo sapiens", collection = coll, subcollection = sub)
  split(m$gene_symbol, m$gs_name)
}
gene_sets <- list(Hallmark = m_sig("H"), GO_BP = m_sig("C5", "GO:BP"),
  KEGG = m_sig("C2", "CP:KEGG_LEGACY"))
rank_stat <- function(res) { # 排序用 Wald stat, 不用 shrunken LFC
  r <- setNames(res$stat, res$gene); r <- r[!is.na(r)]
  sort(r + mom(length(r), sd = 1e-6), decreasing = TRUE) # 打散同分
}
run_gsea <- function(d, sets) rbindlist(lapply(names(sets), function(nm) {
  g <- fgsea(sets[[nm]], rank_stat(d$res), minSize = 15, maxSize = 500, nproc = 1)
  g$collection <- nm; g$type <- d$type; g}))
gsea_all <- rbindlist(lapply(de, run_gsea, sets = gene_sets))
gsea_all[padj < 0.05][order(-abs(NES))][, .SD[1:min(5, N)], by = .(type, collection)]
```

eps = 0 會要求 p 值算到無限精細，跑幾小時都跑不完；預設 1e-10 已經夠報告。背景自動是被檢定的基因 | 腳本：06a §4 | 深入：B13

文獻：Korotkevich G, Sukhov V, Sergushichev A. bioRxiv. doi:10.1101/060012

GSEA：把一百多個基因變成一句話

示意／模擬資料



讀法

這份資料七條都指向核心：缺氧、糖解、EMT 符合壞死中心；增殖（E2F、G2M）與 OXPHOS 也在核心較高。MYC 不顯著。

七條同向要先問一句：是不是整體深度或細胞數的差異？確認過再讀 leading edge 裡是哪些基因

排序用 DESeq2 的 Wald stat（不用 shrunken log2FC：大量同分），不切顯著閾值；背景基因集自動是「被檢定的基因」

這份資料七條 Hallmark 都是核心較高（缺氧、糖解、EMT、增殖、OXPHOS），MYC 不顯著。同向這麼一致要先排除深度差異，再讀 leading edge 裡是哪些基因

ORA：clusterProfiler 的 GO 與 KEGG，上調下調分開做



```
library(clusterProfiler); library(org.Hs.eg.db); library(enrichplot)
run_ora <- function(d, direction = "up", fc = 0.5, p = 0.05) {
  r <- d$res[!is.na(d$res$padj), ]
  sig <- r$gene[r$padj < p & (if (direction == "up") r$log2FC > fc else r$log2FC < -fc)]
  if (length(sig) < 10) return(NULL) # 顯著基因太少：改看 GSEA
  go <- enrichGO(sig, orgDb = org.Hs.eg.db, keyType = "SYMBOL", ont = "BP",
    universe = d$res$gene, # ★ 背景 = 被檢定的基因，不是全基因組
    minGSSize = 15, maxGSSize = 500) |>
    clusterProfiler::simplify(cutoff = 0.7) # igraph 也有 simplify，寫全名
  ids <- bitr(sig, "SYMBOL", "ENTREZID", org.Hs.eg.db)
  uni <- bitr(d$res$gene, "SYMBOL", "ENTREZID", org.Hs.eg.db)
  kegg <- enrichKEGG(ids$ENTREZID, "hsa", universe = uni$ENTREZID, minGSSize = 15) |>
    setReadable(org.Hs.eg.db, keyType = "ENTREZID") # 要連網
  list(go = go, kegg = kegg) }
ora <- run_ora(de[["Immune cell"]], "down") # 這份資料唯一過門檻的型別
dotplot(ora$go, showCategory = 12); dotplot(ora$kegg, showCategory = 12)
cnetplot(ora$go, showCategory = 5) # 詞條-基因網路：哪些基因撐起哪個詞條
```

universe 留空，clusterProfiler 會拿全基因組當背景——顯著詞條會多一倍，全是假的。上下調分開，因為「缺氧上升」與「增殖下降」混在一起會互相抵銷。
本課示範走 down：這份資料 up 那側沒有顯著詞條 | 腳本：06a \$4

文獻：Wu T, et al. Innovation (Camb). 2021;2(3):100141. doi:10.1016/j.xinn.2021.100141

富集結果怎麼讀： NES 熱圖與 dotplot

示意／模擬資料



整列都紅 = 微環境程式，每種細胞都感受得到；只有一欄 = 細胞內在的程式。dotplot 只讀前幾名、GeneRatio 高而且 padj 小的那幾條 | 腳本：06a §4 圖 A-C

富集分析最常見的五個錯

背景錯了



ORA 的 universe 必須是「被檢定的基因」（有表現、進了 DESeq2 的那些），不是全基因組。單細胞只測到一萬多個基因，用兩萬多當背景，每個詞條都會膨脹

方向弄反、混在一起



NES 正負取決於 tissue 的 levels 順序；ORA 上下調不分開，相反的程式會抵銷。先用已知答案（核心該缺氧）確認方向再往下讀

冗餘不是多重證據



GO 的「response to hypoxia」「response to decreased oxygen levels」「response to oxygen levels」是同一件事。simplify() 之後再數；報告時寫一條，不是三條

命中太少就下結論



命中 3-5 個基因的詞條，再顯著也不寫進結論；leading edge 至少要有十來個基因，而且我們要能一個一個說出它們在做什麼

忘了這是誰的 pathway



缺氧在惡性細胞升、在巨噬細胞也升——
那是微環境，不是惡性細胞的特性。每種型別各自做，把 NES 排成熱圖，才分得出「共同」與「專屬」

交付：每型別的 DE 表、火山圖、GSEA 與 ORA 總表


```
for (ty in names(de)) # 每種型別一份表
  write.csv(de[[ty]]$res, sprintf("output/tables/06_de_%s.csv", ty), row.names = FALSE)
write.csv(de.summary, "output/tables/06_de_summary_by_type.csv", row.names = FALSE)

vol<-lapply(de, function(d) { # 紅 = 核心高、藍 = 邊緣高、灰 = NS
  kv<-with(d$res, ifelse(padj< 0.05 & log2FC > 1, "#D62728",
    ifelse(padj< 0.05 & log2FC < -1, "#1F77B4", "grey70")))
  names(kv)<-c("#D62728"= "Up in core", "#1F77B4"= "Up in periphery", grey70= "NS")[kv]
  EnhancedVolcano(d$res, lab = d$res$gene, x = "log2FC", y = "padj", colCustom = kv,
    pCutoff= 0.05, FCcutoff= 1, title = paste0(d$type, ": core vs periphery")) })
ggsave("output/figs/06_volcano_all_types.png", wrap_plots(vol, ncol= 2), bg = "white")

gsea.all[, leadingEdge := sapply(leadingEdge, paste, collapse = ";")] # list 欄轉字串
write.csv(gsea.all, "output/tables/06_gsea_all_types.csv", row.names = FALSE)
# NES 熱圖 (列 = pathway、欄 = 型別) 與 ORA dotplot: 見腳本 06a §4 圖 A-C
foc<-de[["In mune cell"]] # 這份資料唯一過門檻的型別
plotEnrichment(gene.sets$Hallmark[["HALLMARK_HYPOXIA"]], rank_stat(foc$res))
```

表要有 raw 與 shrunken LFC、padj、baseMean；火山圖標的是 padj 不是 p；GSEA 表附 leading edge。
全部由腳本重生，output 裡沒有手工檔 | 腳本：06a §5

多少位病人才夠？ 功效來自病人數



怎麼讀這張圖

- 1 $n=4$ 只抓得到「很大」的效應；中等效應的功效不到 20%
- 2 再加上幾千個基因的多重校正，真正能過 FDR 的更少——所以 $n=4$ 的 DE 表短是正常的，不是分析做錯
- 3 要看中等效應，配對設計大約需要 10 位以上病人；非配對還要更多
- 4 功效不夠時的正確做法：
把 $n=4$ 當作「假說產生」，
用公開資料或 Bulk 世代驗證

$n = 4$ 只看得到很大的效應，所以 DE 表短是正常的。把 $n = 4$ 當假說產生，
用公開世代驗證——這就是錯誤三的正面版

不能 pseudobulk 的時候：三道防線

先承認落到哪裡



pseudobulk 要每個條件 $\geq$ 2-3 個生物重複。病人不夠（06a 的 de.summary 顯示被跳過，如本資料的 OPC）就退到 cell-level——但 p 值是被細胞數灌大的，結論定位只能是「假說產生」

防線一十二： 共變量與逐病人一致性



先跑 Seurat 預設的 Wilcoxon 當基準，再用 MAST 把病人放進 latent.vars（Wilcoxon 做不到）——只在 Wilcoxon 顯著的基因多半是病人效應。接著逐病人各算 logFC，方向全一致才留；一致性表裡的 NA = 該病人單邊 < 5 顆、無法評估

防線三：標籤置換



把 tissue 標籤在病人內隨機打散重跑：真實訊號應遠多於置換後撈到的「顯著」數。差不多多，就是假重複在說話。最後把方法與限制明寫在交付表上

cell-level DE 的正確作法（腳本 06b）

```
obj <- subset(gbm 4, cells = colnames(gbm 4)[gbm 4$type == "OPC"])
table(obj$patient, obj$tissue)      # 先看樣本結構：兩部位都夠的病人只有 1 位
Idents(obj) <- "tissue"
fm <- function(...) FindMarkers(obj, ident.1 = "Tumor", ident.2 = "Periphery",
                                logfc.threshold = 0.25, min.pct = 0.1, ...) {
  tibble::rownames_to_column("gene")      # 基因在 rownames，先拉成欄
  de.wilcox <- fm()                       # Seurat 預設 Wilcoxon：當基準
  de <- fm(test.use = "MAST", latent.vars = "patient") # 防線一：病人當共變量
  setdiff(head(de.wilcox$gene, 30), head(de$gene, 30)) # 只在預設法顯著 ≈ 病人效應
  # 防線二：逐病人 logFC，方向一致才留（單邊 < 5 顆的病人不算）
  # 防線三：tissue 在病人內置換 20 次，比較「顯著基因數」的真實值 vs 置換分布
  perm.sig <- replicate(20, {
    o <- obj; o$tissue <- ave(as.character(o$tissue), o$patient, FUN = sample)
    Ident(o) <- factor(o$tissue, levels = c("Periphery", "Tumor"))
    sum(FindMarkers(o, ident.1 = "Tumor", ident.2 = "Periphery",
                    logfc.threshold = 0.25)$p_val_adj < 0.05, na.rm = TRUE)})
  de$method <- "cell-levelMAST;hypothesis-generating" # 交付表明寫限制
```

這支的重點不是 p 值——是三道防線與誠實的定位。能 pseudobulk 就永遠用 06a；06b 是樣本結構不允許時的備案 | 腳本：06b

文獻：Squair JW, et al. Nat Commun. 2021;12(1):5692. doi:10.1038/s41467-021-25960-2

06

差異表達之後：下游路線的選擇

腫瘤研究常走的六條路，每一條都要對的資料

六條路，各自要什麼

細胞通訊

惡性↔TAM 的配體-受體軸（如 SPP1、CSF1）

需要：可靠型別標籤、多型別共存

CellChat

惡性狀態與可塑性

MES/AC/OPC/NPC 樣分數、週期

需要：已判定的惡性細胞 + 發表的基因集

AddModuleScore

軌跡

惡性細胞內的狀態轉換（不是型別之間）

需要：連續過程被取樣；起點有依據

Slingshot

CNV 亞株

同一病人內的亞株結構

需要：inferCNV HMM 或 CopyKAT

inferCNV

反卷積 Bulk 隊列

用單細胞參考拆 TCGA-GBM 的比例，連結存活

需要：同組織單細胞參考 + Bulk

MuSiC / BayesPrism

空間

哪種惡性狀態靠近血管／壞死區

需要：Visium / Xenium 資料

Seurat spatial

先對照「需要」那一行，再決定走哪條。選錯資料，整條路作廢

07

細胞通訊： CellChat 從跑到讀圖

腳本 07：六種圖，每一種回答一個問題

細胞通訊（CellChat / LIANA）：三個前提

腫瘤研究最愛的下游，也是最常做錯的

同一個樣本裡



配體與受體必須來自同一位病人的同一個部位——不同病人的巨噬細胞跟惡性細胞不可能對話。
按樣本分開跑，再比較

兩端都要夠多細胞



預設門檻常是 10% 細胞表現；環境 RNA 會製造假的配體。SoupX 之後再跑，並只用 CNV 判定後的惡性細胞

結果是假說



RNA 層級的配體—受體共表現不等於結合、不等於訊號。要有第二種證據（空間、蛋白、擾動）才能寫成「X 驅動 Y」

CellChat 在算什麼

CellChatDB：配體—受體資料庫（人類約 3,300 對）



分泌型 (Secreted)

細胞激素、生長因子：SPP1-CD44、TGFB1-TGFR



ECM—受體

細胞外基質：COL1A1-ITGA/ITGB、LAMININ



細胞—細胞接觸

需要相鄰：PD-L1-PD-1、NOTCH-JAG、MHC-TCR

多亞單位受體（ITGAV+ITGB1）與協同／拮抗因子都寫在資料庫裡——這是 CellChat 與單純「兩個基因相乘」的差別

一對細胞群之間的「通訊機率」怎麼算

①

$$L_i = \text{tri}(x_{L,i}), \quad R_j = \text{tri}(x_{R,j})$$

每一群各取配體 L 與受體 R 的 trimean。
trimean 比平均抗離群，而且要求該群至少 25% 的細胞表現，少數幾顆高表現的細胞撐不起一條訊號。

②

$$P_{i \rightarrow j} = \frac{L_i R_j}{K_h + L_i R_j} \cdot \frac{1 + AG}{1 + AN}$$

質量作用定律：配體乘受體，用 Hill 函數壓成 0-1。多亞單位受體取幾何平均，協同因子 AG 乘上去、拮抗因子 AN 除下來。

③

$$p = \frac{\#\{P^* \geq P\}}{100}$$

置換檢定：群標籤隨機打散 100 次重算 P^* 。真實的 P 要贏過 95% 的隨機結果才算顯著——它給的是「比隨機強多少」。

④

$$P_{i \rightarrow j}^{\text{path}} = \sum_{(L, R) \in \text{path}} P_{i \rightarrow j}$$

把同一條路徑底下的所有 L-R 對加起來，就是路徑層級；再把所有路徑加起來，就是群對群的總網路。

輸出是三層：L-R 對 → 路徑 → 群對群。後面每一種圖，都是其中一層的某個切面

資料庫決定「哪些對可能」，表現量決定「哪些對成立」，置換檢定決定「哪些對不是巧合」。

輸出三層：L-R 對、路徑、群對群

跑一次 CellChat：從 Seurat 物件到總網路（每個樣本各跑一次）

```
library(CellChat)
run_cc <- function(obj, label= "cc_label") {
  obj$samples <- factor(paste(obj$patient, obj$tissue, sep = "_")) # v2 要求 samples 欄
  cc <- createCellChat(obj, group.by = label, assay = "RNA") # 用 data 層
  cc@DB <- subsetDB(CellChatDB.human, search = "Secreted Signaling")
  cc <- subsetData(cc) |> identifyOverExpressedGenes() |>
    identifyOverExpressedInteractions()
  cc <- computeCommunProb(cc, type = "tMean", # 注意大小寫
    population.size = TRUE) # 把族群豐度納入機率
  cc <- filterCommunication(cc, min.cells = 20) # < 20 顆的群不參與
  cc <- computeCommunProbPathway(cc) |> aggregateNet()
  netAnalysis_computeCentrality(cc)
}
core <- run_cc(subset(gbm4, tissue == "Tumor" & patient == "BT_S2"))
peri <- run_cc(subset(gbm4, tissue == "Periphery" & patient == "BT_S2"))
# 4 位病人 × 2 部位 = 8 個物件；apply 跑完存成 list
```


三個關鍵：用 log-normalized 的 data 層、每個樣本分開跑、只用 CNV 判定後的標籤。約 5-15 分鐘一個樣本 | 腳本：07 §1

文獻：Jin S, et al. Nat Commun. 2021;12(1):1088. doi:10.1038/s41467-021-21246-9


圖 1： netVisual_circle——鳥瞰整個網路

示意／模擬資料

互動數 (Number of interactions)



互動強度 (Interaction weights)



怎麼看

每個節點一種細胞群；
節點大小=該群送出的總量

邊的顏色=來源 (sender)；
箭頭指向接收者

邊的粗細=顯著 L-R 對的
數目 (左) 或機率總和 (右)


左右不一致很常見：對數多不代表
強；先看右圖找主軸，再回左圖

自環=同群之間 (惡
性→惡性的自分泌)

```
groupSize <- table(cc@idents); netVisual_circle(cc@net$count,  
vertex.weight = groupSize) 與 cc@net$weight 各畫一張。先看右圖找主軸
```

圖 2： netVisual_heatmap—— 誰送給誰

示意／模擬資料



怎麼看

列=送出的群、欄=接收的群；顏色深=通訊強

右側長條=每列加總（誰最會送）；
上方長條=每欄加總（誰最會收）

GBM 的典型：惡性↔巨噬細胞是最亮的一對；惡性→內皮（VEGF）也常亮

比 circle 圖適合讀數字；
circle 圖適合看方向

`netVisual_heatmap(cc, measure = "weight", color.heatmap = "Reds")`。

行是來源、欄是目標；兩側長條是加總。要引用數字用這張，看方向用 circle

路徑層級：先排序，再挑一條路徑拆開看

```
cc@ netP$ pathways # 顯著的路徑清單
netAnalysis_signalingRole_heatmap(cc, pattern = "outgoing", height = 8) # 圖 4 左
netAnalysis_signalingRole_heatmap(cc, pattern = "incoming", height = 8) # 圖 4 右
netAnalysis_signalingRole_scatter(cc) # 圖 4 散點


pw <- "SPP1"
netVisual_aggregate(cc, signaling = pw, layout = "circle") # 圖 3 左 (也可 "chord"、"hierarchy")
netAnalysis_contribution(cc, signaling = pw) # 圖 3 右：哪對 L-R 撐起路徑
netVisual_heatmap(cc, signaling = pw, colorheatmap = "Reds") # 單一路徑的來源 × 目標
plotGeneExpression(cc, signaling = pw) # 該路徑所有基因的 violin：驗證表現
netAnalysis_signalingRole_network(cc, signaling = pw) # sender/receiver/mediator/influencer
```

讀圖順序：signalingRole 找主角 → aggregate 看方向 → contribution 找具體 L-R → plotGeneExpression 驗證。路徑名稱以 cc@netP\$pathways 為準 | 腳本：07 §2

圖 3：一條路徑的方向與組成

SPP1 路徑：netVisual_aggregate (circle)


示意／模擬資料



SPP1 是 GBM 教科書級的 TAM → 惡性訊號。看到這樣的圖，下一步不是寫進論文，是去畫 SPP1 與 CD44 的 violin 確認表現與比例

圖 4： signalingRole—— 每種細胞在每條路徑的角色

示意／模擬資料



讀法：一列一條路徑、一欄一種細胞；左圖找「誰在送」、右圖找「誰在收」。散點圖右上角是既送又收的樞紐（GBM 通常是惡性細胞與巨噬細胞）


這是通訊分析最有資訊量的一張：一眼看到惡性細胞送 VEGF / MIF / PTN、巨噬細胞送 SPP1 / TGFb / MHC-II。散點右上角是樞紐

三十條路徑講不完：通訊模式與路徑分群

示意／模擬資料

① 通訊模式：把「誰在送什麼」壓成幾個模式（NMF）

② 路徑分群：功能相似 vs 結構相似



模式 P1


惡性 + TAM 一起送出 SPP1、MIF

模式 P2


血管 + 基質送 COLLAGEN、VEGF

為什麼要它：三十條顯著路徑一條一條講沒有人看得完；
壓成兩三個模式，才講得出「這個腫瘤的通訊長什麼樣」。

功能相似度



結構相似度



功能相似：送出與接收的細胞群幾乎一樣——這幾條路徑角色重疊，可能互相取代，論文可以合成一句話講。

結構相似：網路拓撲的位置像（都是「一對多」或都是「多對一」），但參與的細胞可以完全不同。兩張圖要分開讀，不要當成同一件事。

identifyCommunicationPatterns() 用 NMF 把「群 × 路徑」壓成兩三個模式；netEmbedding + netClustering 再依功能或結構把路徑分群。兩者都是為了讓結論講得完 | 腳本：07 §5（進階，腳本未附）

落到具體配體—受體，然後比較兩個條件


```
# 圖 5：指定來源與目標群，列出顯著的 L-R 對
netVisual_bubble(cc, sources.use = c("MacromG", "Malignant"),
  targets.use = c("Malignant", "MacromG", "Vascular"),
  remove.isolate = TRUE)
sig3 <- head(intersect(c("SPP1", "MF", "VEGF"),
  cc@net$pathways), 3) # 名稱以 cc@net$pathways 為準
netVisual_bubble(cc, signaling = sig3) # 只看幾條路徑

# 圖 6：兩條件比較——先合併
cc.m <- mergeCellChat(list(Core = core, Periphery = peri),
  add.names = c("Core", "Periphery"))
compareInteractions(cc.m, group = c(1, 2)) # 互動數
compareInteractions(cc.m, group = c(1, 2), measure = "weight")
netVisual_diffInteraction(cc.m, weight.scale = TRUE) # 差異 circle：紅增藍減
netVisual_heatmap(cc.m, measure = "weight") # 差異熱圖
rankNet(cc.m, mode = "comparison", stacked = TRUE, do.stat = TRUE) # Wilcoxon
netVisual_bubble(cc.m, sources.use = "MacromG", targets.use = "Malignant",
  comparison = c(1, 2), angle.x = 45) # 同一對 L-R 在兩條件
```

四位病人各有一對物件；比較時要看「四位方向一致」的路徑，不是單一病人的。統計單位仍然是病人 | 腳本：07 §3-4

圖 5： netVisual_bubble—— 論文主圖層級的呈現

示意／模擬資料



怎麼看

縱軸—列一對 L-R；
橫軸—欄一組「來源→目標」

顏色=通訊機率、
大小=p 值：又大又黃才值得追


同一個配體對多種受體
(SPP1→CD44/整合素)
會佔好幾列——它們共用
同一個配體表現

這是寫進論文與
方法段的那張圖

又大又黃才追；同一配體對多種受體會佔好幾列。追到具體的對之後，回到 Seurat 畫 FeaturePlot 與 VlnPlot 驗證

圖 6：核心 vs 邊緣——mergeCellChat 之後

示意／模擬資料



讀法

每位病人分開跑、再合併比較；粗體=兩條件差異顯著 (Wilcoxon)。核心：SPP1、VEGF (缺氧、巨噬細胞)；邊緣：PTN、MHC-II (浸潤、與正常腦互動)

核心的互動更多更強（缺氧、巨噬細胞浸潤）；rankNet 粗體的路徑才是兩條件有差的。
每位病人各跑一組，四位一致才寫

文獻：Jin S, et al. Nat Commun. 2021;12(1):1088. doi:10.1038/s41467-021-21246-9

CellChat 之外： LIANA 共識與其他工具

方法之間結果差異很大；審稿人常要求至少兩種方法一致

工具	特色	輸出	何時用
CellChat	多亞單位、協同因子、路徑層級圖最完整	L-R、路徑、網路	預設選擇；要畫圖
LIANA+	一次跑 CellPhoneDB、NATMI、Connectome 等多種方法，取共識排名	L-R 的共識排名	要交叉驗證 CellChat 的結果
CellPhoneDB	最早、資料庫嚴謹（人類）	L-R + p 值	Python 流程；人類資料
NicheNet	問「哪個配體最能解釋目標細胞的表現變化」——用下游基因反推	配體活性 + 目標基因	有明確的「接收者變了什麼」（DE）時
空間驗證	Visium / Xenium 看配體與受體是否真的相鄰	共定位	寫「X 驅動 Y」之前

文獻：Efremova M, Vento-Tormo M, Teichmann SA, Vento-Tormo R. Nat Protoc. 2020;15(4):1484–1506. doi:10.1038/s41596-020-0292-x | Browaeys R, Saelens W, Saeyns Y. Nat Methods. 2020;17(2):159–162. doi:10.1038/s41592-019-0667-5

08


軌跡分析：狀態怎麼轉換

腳本 08：Slingshot + tradeSeq 主線；Monocle3 / Monocle2 比較與手動選起點


軌跡： pseudotime 與基因動態怎麼讀

示意／模擬資料

Slingshot：主曲線 + pseudotime



沿 pseudotime 變化的基因



軌跡能相信的五個條件

- 1 只在「同一位病人的惡性細胞」內做
- 2 起點有生物學理由 (OPC 樣，或 RNA velocity 指向)
- 3 週期分數不主導軌跡 (否則先回歸)
- 4 換 seed、換病人，主軸方向一致
- 5 終點的狀態要另外驗，不能從起點推


只在同一位病人的惡性細胞內做；起點要有理由；週期不能主導；換 seed 與換病人方向一致；終點要另外驗。五條缺一，那條曲線就只是裝飾

文獻：Street K, et al. BMC Genomics. 2018;19(1):477. doi:10.1186/s12864-018-4772-0 | Van den Berge K, et al. Nat Commun. 2020;11(1):1201. doi:10.1038/s41467-020-14766-3 | Cao J, et al. Nature. 2019;566(7745):496-502. doi:10.1038/s41586-019-0969-x

最常見的下游誤用

示意／模擬資料

惡性 → 免疫 → 寡樹突的「分化路徑」？



軌跡工具永遠會給出一條線

- ✗ 惡性細胞不會分化成巨噬細胞。這條線不存在
- ✗ 分支點落在型別交界 = 人工產物的典型長相
- ✓ 腫瘤裡合理的軌跡：惡性細胞「內部」的狀態轉換（OPC 樣→AC 樣），而且要先判定惡性、先按病人分開
- ✓ 快照推不出方向；起點要有獨立依據（週期、幹性、RNA velocity）

腫瘤裡真正說得通的軌跡，通常是惡性細胞內部的狀態轉換——先判定惡性、先按病人分開，再談 pseudotime

Slingshot + tradeSeq：一位病人的惡性細胞

```
library(slingshot); library(tradeSeq)
m.all <- subset(gbm4, malignant == "malignant" & patient == "BT_S2") # 388 顆
m.all <- NormalizeData(m.all) |> FindVariableFeatures() |> ScaleData() |> RunPCA() |>
  FindNeighbors(dims = 1:15) |> FindClusters(resolution = 0.4) |> RunUMAP(dims = 1:15)
# 起點不要寫死群號：用 0 PC 樣分數選出來，理由才寫得進論文
m.all <- AddModuleScore(m.all, features = neftel["0 PC"], name = "0 PC")
root <- names(which.max(apply(m.all$0 PC1, Idents(m.all), mean)))
sce <- slingshot(as.SingleCellExperiment(m.all), clusterLabels = "seurat_clusters",
  reducedDim = "UMAP", start.clus = root)
m.all$pt <- slingPseudotime(sce)[,1]
# 條件 ③ 當場驗：週期有沒有主導軌跡？ |r| > 0.5 就先回歸掉再做
m.all <- CellCycleScoring(m.all, s.features = cc.genes.updated.2019$s.genes,
  g2m.features = cc.genes.updated.2019$g2m.genes)
cor(m.all$pt, m.all$Score, use = "complete.obs") # 本例 -0.25
cor(m.all$pt, m.all$G2M.Score, use = "complete.obs") # 本例 -0.14，過關
# 沿 pseudotime 變化的基因（負二項 GAM，這一集最慢的一步）
keep <- !is.na(m.all$pt)
counts <- LayerData(m.all, layer = "counts")[VariableFeatures(m.all), keep]
gam <- fitGAM(as.matrix(counts), pseudotime = m.all$pt[keep],
  cellWeights = rep(1, sum(keep)), nknots = 6)
assoc <- associationTest(gam) # 本例 38 個基因的 p 直接下溢成 0，
head(assoc[order(-assoc$waldStat), ], 20) # 所以排序一定要用 waldStat
```

起點由分數選出、不是點出來的，所以可重現；週期相關性 -0.25 / -0.14 就是條件 ③ 的證據。fitGAM 是這一集最慢的一步 | 腳本：08 \$1

Monocle3 / Monocle2 : 起點選擇的兩種作法

```
# Monocle3 (最多人用; graph-based)
library(monocle3)
cds <- SeuratWrappers::as.cell_data_set(m all) # 沿用 Seurat 的 UMAP 與分群
cds <- cluster_cells(cds) |> learn_graph(use_partition = FALSE)
# (a) 手動互動式: 跳出視窗讓我們「點」起點——直觀，但不可重現
cds <- order_cells(cds)
# (b) 腳本化: 把理由寫成程式碼——OPC 樣分數前 10 顆當 root, 可重現
root.cells <- colnames(m all)[order(m all$OPC1, decreasing = TRUE)[1:10]]
cds <- order_cells(cds, root_cells = root.cells)
plot_cells(cds, color_cells_by = "pseudotime", label_branch_points = TRUE)

# Monocle2 (經典 DDRTree; root_state 一樣是自己選)
cds2 <- reduce_dimension(cds2, method = "DDRTree") |> orderCells()
plot_cell_trajectory(cds2, color_by = "State") # 看圖決定哪個 State 當起點
cds2 <- orderCells(cds2, root_state = 3) # ← 手動填; 腳本版用分數選

cor(m all$pt, m all$pt_m2, method = "spearman") # 跨工具一致性: 用分級判讀, 不用單一門檻
# > 0.8 強一致 | 0.6-0.8 要第三個獨立佐證 | < 0.6 先回頭查起點
# 本例 r = 0.757 — 中間帶, 佐證是終點的 Netel 分數與四個基因的方向
```

探索用手動點選、定稿用腳本化——手動每次點的不一樣，不可重現。跨工具一致性用分級讀：本例 Slingshot vs Monocle2 $r = 0.757$ 落在中間帶，靠終點狀態分數補足 | 腳本：08 \$2-3

文獻：Cao J, et al. Nature. 2019;566(7745):496-502. doi:10.1038/s41586-019-0969-x | Qiu X, et al. Nat Methods. 2017;14(10):979-982. doi:10.1038/nmeth.4402



09

路徑與轉錄因子活性：誰在驅動

腳本 09：decoupleR / PROGENy（R、快）與 SCENIC（Python、慢，選配）

調控與活性：誰在驅動這群細胞

示意／模擬資料



兩者的差別

SCENIC 問「哪個轉錄因子在驅動這群」：從共表現+motif 推 regulon，再算每顆細胞的活性

PROGENy/decoupleR 問「哪條訊號路徑活著」：用擾動實驗學到的 footprint 基因，不是路徑成員基因

兩者都可以做 pseudobulk 後再比較條件——單位仍是病人

兩張都是示意圖。本例邊緣側的惡性細胞只有 1 / 13 / 17 / 0 顆——配對只剩 3 位，其中一位的值來自一顆細胞。方法示範完整，結論僅到假設生成 | 腳本：09

文獻： Aibar S, et al. Nat Methods. 2017;14(11):1083-1086. doi:10.1038/nmeth.4463 | Badia-i-Mompel P, et al. Bioinform Adv. 2022;2(1):vbac016. doi:10.1093/bioadv/vbac016 | Schubert M, et al. Nat Commun. 2018;9(1):20. doi:10.1038/s41467-017-02391-6 | Van de Sande B, et al. Nat Protoc. 2020;15(7):2247-2276. doi:10.1038/s41596-020-0336-2

decoupleR (R) 與 SCENIC (pySCENIC)

```
# 1. decoupleR + PROGENY: 每顆細胞的 14 條路徑活性
library(decoupleR)
net <- get_progeny(organism = "human", top = 500)
mat <- as.matrix(LayerData(gbm4, layer = "data"))
act <- run_mlm(mat, net, source = "source", target = "target", mode = "weight")
act.w <- tidyr::pivot_wider(act, id_cols = source, names_from = condition,
                           values_from = score) |>
  tibble::column_to_rownames("source") |> as.matrix()
gbm4[["progeny"]] <- CreateAssayObject(act.w)
DefaultAssay(gbm4) <- "progeny"
FeaturePlot(gbm4, features = c("Hypoxia", "AK-STAT"))
# 條件比較: 活性先平均到 病人 × 部位, 再做配對檢定 (單位 = 病人)

# 2. SCENIC: R 匯出 loom → pySCENIC 三步 → 讀回 AUCell 矩陣
# pyscenic gm counts.loom tfs.txt -o adj.csv # 共表現 (GRNBoost2)
# pyscenic ctx adj.csv *.feather --annotations_fname motifs.tbl -o reg.csv
# pyscenic aucell counts.loom reg.csv -o auc.loom # regulon 活性
auc <- read.csv("output/tables/09_scenic_auc.csv", row.names = 1) # regulon × cell
gbm4[["scenic"]] <- CreateAssayObject(as.matrix(auc))
DoHeatmap(gbm4, features = c("SOX2(+)", "OLIG2(+)", "SPI1(+)", "CEBPB(+)",
                             assay = "scenic")
```

SCENIC 跑一次數小時; GBM 的經典結果是惡性 SOX2 / OLIG2、TAM 的 SPI1 / CEBPB。regulon 名稱後的 (+) 表示活化型 | 腳本: 09


10

反卷積與存活：以大型世代驗證

腳本 10：MuSiC + TCGA-GBM + KM / Cox——單細胞假說的出口

反卷積在解什麼： bulk 是加權混合，我們解那組權重

示意／模擬資料





$b = S \cdot w$ ：bulk 的表現量已知、單細胞做出來的特徵矩陣 S 已知，未知的只有比例 w。
加上「非負、加總為 1」就解得出來 | 腳本：10

文獻：Wang X, Park J, Susztak K, Zhang NR, Li M. Nat Commun. 2019;10(1):380. doi:10.1038/s41467-018-08023-x | Newman AM, et al. Nat Biotechnol. 2019;37(7):773-782. doi:10.1038/s41587-019-0114-2

反卷積：把 $n = 4$ 帶到 $n = 284$

反卷積：把單細胞學到的「型別特徵」帶回幾百份 Bulk，換取統計功效

示意／模擬資料



這是 $n=4$ 的正確出路：單細胞產生假說，公開世代驗證。兩張都是示意——本例實跑 TCGA-GBM（去重後 284 位、229 位可分析）：巨噬比例 HR 1.10 (0.85–1.44)、log-rank $p=0.5$ ；年齡 HR 1.03 (1.02–1.04)、 $p=1.8e-06$

圖為示意。實跑 TCGA-GBM：391 個檔案 → 372 份原發 → 去重後 284 位病人。巨噬比例 HR 1.10 (0.85–1.44)、 $p = 0.46$ 看不出關聯；年齡 HR 1.03、 $p = 1.8e-06$ 這個陽性對照有出來 | 腳本：10

MuSiC 反卷積 + TCGA 存活

```
library(MuSiC); library(TCGAAbiolinks); library(survival); library(survminer)
ref<-as.SingleCellExperiment(binLayers(gbm4)); ct<-gbm4$celltype_author
ref$celltype_l1<-ifelse(gbm4$malignant=="malignant","Malignant", # 反卷積用主要類群
  ifelse(ct=="Immune cell","Immune",ifelse(ct=="Oligodendrocyte","Oligo",
  ifelse(ct=="Vascular","Vascular","Other"))))
q<-GDCquery("TCGA-GBM",data.category="Transcriptome Profiling",
  data.type="Gene Expression Quantification",workflow.type="STAR-Counts")
GDCdownload(q,directory="C:/GDCdata"); bulk<-GDCprepare(q,directory="C:/GDCdata")
mtx<-assay(bulk,"unstranded"); rownames(mtx)<-rowData(bulk)$gene_name
# ★ barcode 第 4 段 01 = 原發；一位病人常有多份 aliquot，不去重=同一個死亡算兩次
sel<-which(substr(colnames(mtx),14,15)=="01")
sel<-sel[!duplicated(substr(colnames(mtx)[sel],1,12))] # 391 → 372 → 284 位
est<-music_prop(bulk[mtx=mtx[,sel],sc.sce=ref,
  clusters="celltype_l1",samples="patient")
prop<-as.data.frame(est$Est.prop.weighted); cl<-as.data.frame(colData(bulk)[rownames(prop),])
cl$time<-ifelse(cl$vital_status=="Dead",cl$days_to_death,cl$days_to_last_follow_up)/30.4
cl$event<-as.integer(cl$vital_status=="Dead") # 存活時間軸要自己接
cl$mac_hi<-prop$Immune>median(prop$Immune)
ggsurvplot(survfit(Surv(time,event)~mac_hi,data=cl),pval=TRUE)
coxph(Surv(time,event)~mac_hi+age_at_index,data=cl) # 年齡 = 陽性對照
```

BayesPrism、CIBERSORTx 是替代方案。Cox 模型要調整年齡、MGMT 等已知因子；比例是估計值，不要當真值 | 腳本：10

文獻：Wang X, Park J, Susztak K, Zhang NR, Li M. Nat Commun. 2019;10(1):380. doi:10.1038/s41467-018-08023-x | Brennan CW, et al. Cell. 2013;155(2):462-477. doi:10.1016/j.cell.2013.09.034

下游工具總表：問題 → 工具 → 輸入 → 最小證據

問題	工具	輸入	寫進論文前的最小證據
誰跟誰對話	CellChat、LIANA	同一樣本、CNV 後標籤、 log-normalized	兩種方法一致、四位病人一致 表現圖驗證
狀態怎麼轉換	Slingshot、 Monocle3 scVelo	一位病人的惡性細胞	起點有理由 + 換 seed/ 病人一致
誰在驅動	SCENIC、 decoupleR	counts（SCENIC） ／ data （decoupleR）	regulon 的目標基因 在 DE 裡也動
在大世代成不成立	MuSiC、 BayesPrism	單細胞參考 + Bulk counts	調整已知因子後仍顯著
空間上在哪	RCTD、 cell2location	單細胞參考 + Visium	配體受體在空間上真的相鄰

常見錯誤總表

集	雷	一句話解法
Q1	把細胞數當樣本數	n 是病人；DE 用 pseudobulk
Q1	用 marker 判定惡性	marker 只定譜系；惡性判定需要 CNV 等多重證據
Q1	惡性的四個群集當四種亞型	那是四位病人；狀態分數在病人內看
Q2	percent.mt 照抄 5%	median + 3×MAD，數字寫進方法段
Q2	doublet 群當免疫樣腫瘤細胞	分群後看每群 doublet 比例，整群移除
Q3	整合把惡性細胞的病人差異修掉	整合空間只註釋正常細胞；惡性回未整合空間
Q3	inferCNV 參考選到惡性細胞	參考 = 免疫 + 寡樹突；星狀細胞不行
Q3	把多位病人合併跑 CellChat	每個樣本分開跑；四位一致才寫
Q3	跨病人的惡性細胞畫軌跡	一位病人、CNV 之後、起點有理由

09

常見錯誤

六個會被審稿人直接退回的雷

錯誤一： inferCNV 的參考組選錯



雷是什麼

拿「Astrocyte」群當正常參考，因為它 marker 很像正常星狀細胞。

為什麼會踩

星狀細胞在教科書裡是正常腦細胞。

踩了會怎樣

GBM 的惡性細胞大半是 AC 樣狀態；參考組裡混了惡性細胞，chr7/chr10 的訊號被扣掉，全圖 CNV 歸零、惡性判定全滅。

錯誤二：用整合後的值做 DE 或 CNV



雷是什麼

整合完直接 FindMarkers 比核心 vs 邊緣，或把 integrated 值餵給 inferCNV。

為什麼會踩

整合後的物件看起來就是「乾淨的資料」。

踩了會怎樣

corrected 值不是表現量。DE 回 RNA counts 並 pseudobulk；inferCNV 要原始 counts。
一行檢查：矩陣是整數嗎。

錯誤三：以 $n = 4$ 逕下臨床結論



雷是什麼

「邊緣的惡性細胞高表現基因 X，可作為浸潤的治療標靶。」

為什麼會踩

配對設計、pseudobulk、GSEA 都做對了，p 值也漂亮。

踩了會怎樣

方法對、功效與外推性不夠。四位病人能給我們「候選」與「一致的方向」；要下結論，要更多病人與獨立驗證（如TCGA 反卷積、空間資料）。

錯誤四：沒有留不整合的基線



雷是什麼

拿到多病人資料就直接 IntegrateLayers，從頭到尾只看整合後的 UMAP。

為什麼會踩

整合後的圖比較漂亮，四個病人混在一起看起來就是「成功了」。

踩了會怎樣

沒有基線就沒有比較對象：分不出「原本就該混的正常細胞」和「被硬混掉的惡性細胞」。腳本 04 先跑一次不整合，就是為了留下這張對照圖——正負對照全部建立在它上面。

錯誤五：ORA 的背景用「全基因體」



雷是什麼

enrichGO 不給 universe，讓它預設拿整個 org.Hs.eg.db 當背景。

為什麼會踩

不寫 universe 也跑得動，而且詞條看起來更多更顯著。

踩了會怎樣

背景應該是「這次真的被檢定的基因」。用全基因體當背景，等於把根本沒表現、也沒被檢定的基因算進分母，比例被灌大，padj 一片顯著。universe 要給 DE 表裡的基因清單。

錯誤六：兩個條件合成一個 CellChat 物件



雷是什麼

把核心與邊緣的細胞放進同一個物件跑一次 CellChat，再按條件拆圖。

為什麼會踩

跑一次比較快，圖也畫得出來。

踩了會怎樣

CellChat 的機率是在「這個物件裡的細胞組成」下算出來的，兩個條件混在一起，算出來的既不是核心也不是邊緣。正確作法是每個樣本各跑一次，再用 mergeCellChat 比較——這也是為什麼比較圖要看 rankNet，而不是兩張 circle 圖用眼睛比。

Q3 checklist



整合前先存未整合的圖與物件



整合空間只用來註釋正常型別



inferCNV 參考 = 免疫 + 寡樹突



惡性標籤三角驗證，
不確定者標 unresolved



pseudobulk 矩陣是
整數、每欄一個樣本



DESeq2 設計含 patient (配對)



每樣本點圖確認方向一致



GSEA 通過已知答案驗證



下一條路的資料前提已對照

九格全勾，結果才能寫進論文

一句話總結

整合的目的是對齊各樣本的共同細胞型別；惡性細胞帶病人特異的基因體變異，宜逐病人分析；差異表達以病人為統計單位；下游分析各有其適用的資料條件。

加上 Q1、Q2 的六句，這就是腫瘤單細胞分析的骨架。

自測 1

跑 inferCNV 時，哪一組最適合當參考（正常）細胞？

- A 表現 GFAP 的星狀細胞群
- B 免疫細胞與寡樹突細胞
- C UMAP 上離惡性細胞最遠的群

答 B。參考組必須「確定沒有 CNV」。免疫與寡樹突細胞在 GBM 裡幾乎不可能是惡性的；星狀細胞可能就是 AC 樣的惡性細胞；UMAP 距離不是證據。

自測 2

四位病人的資料，整合之後惡性細胞混成一團。這代表？

A 整合成功，可以直接做下游

B 整合把病人特異的 CNV 生物學也修掉了；惡性分析要回未整合空間

C 這四位病人是同一種亞型

答 B。惡性細胞會按病人分群，多半是 CNV 這類基因體差異，不是批次；同一種狀態的細胞本來就會跨病人混，混一部分是正常的，全混成一團才是修過頭。整合空間只拿來註釋正常細胞。

自測 3

核心 vs 邊緣的惡性細胞 DE，DESeq2 的 design 該怎麼寫？

A ~ tissue

B ~ patient + tissue

C ~ tissue + n_cells

答 B。同一位病人同時有兩個部位，是配對設計；先吸掉病人差異再比部位，功效高很多。細胞數不是共變量，pseudobulk 已經處理了。

自測 4

整合後正常細胞四位病人混得很好，惡性細胞也混在一起了。最合理的判斷？

- A 整合成功，可以往下走
- B 很可能校正過頭，要用負對照與已知 marker 回頭檢查
- C 惡性細胞本來就該混，因為它們都是 GBM

答 B。惡性細胞帶著各自的 CNV，跨病人本來就會有相當一部分分開；四位完全混在一起，通常是校正把病人差異連同真訊號一起壓掉了。負對照就是為了抓這件事，再用幾個已知 marker 確認表現量沒有被動到。

自測 5

某種細胞型別只有 2 位病人配得成對，DESeq2 給出 300 個 $\text{padj} < 0.05$ 的基因。可以報嗎？

- A 可以， padj 已經校正過了
- B 不行，先報 n ，再說這批基因只能當候選
- C 把門檻改嚴一點就可以報

答 B。 $n = 2$ 的配對設計幾乎沒有功效，跑得出三百個顯著基因通常代表離散度估不準，而不是真的有三百個差異。門檻改嚴不會讓功效變高。誠實的寫法是先講幾位病人配得成對，再把清單標成候選。

自測 6

同一份 DE 結果，ORA 沒有任何顯著詞條，GSEA 卻有五條 $\text{padj} < 0.05$ 。怎麼看？

A 矛盾，兩個都不能信

B ORA 對，GSEA 太寬鬆

C 正常，小 n 時 DE 表短，ORA 幾乎沒東西可算；先看 GSEA 的 leading edge 合不合理

答 C。這兩種問法本來就不同：ORA 先切閾值，清單短的時候交集自然湊不出顯著；GSEA 不切閾值，整份排序都在貢獻證據，所以在小 n 更靈敏。不是誰對誰錯，而是先看 GSEA 的 leading edge 是不是一批說得通的基因，再決定要不要寫進結論。

三個系列，依需求深入

A 系列 · 入門篇

觀念與判讀：實驗設計、圖表解讀、從結果到研究敘事。不需撰寫程式，適合建立整體框架與跨領域溝通。

B 系列 · 實作篇

以公開資料完整實作：從 FASTQ 與 Cell Ranger 到 Seurat 標準流程與各項下游分析，隨集附練習腳本。本課程各頁的「深入：Bx」即為對應索引。

C 系列 · 數學篇

方法背後的數學與統計：PCA 與降維、變異數穩定化、統計推論（pseudobulk 的理論基礎）、整合演算法的原理。

各系列皆為中英雙語；完整索引與連結見影片說明欄。

Q 系列到此結束

課程總結：一套完整的 scRNA-seq 分析骨架

練習腳本 R/00-10 與自測題庫隨課程提供。
接下來，把這套流程用到我們自己的資料——不限於腫瘤。

scRNA-seq 教學影片系列 · Q 系列 · 快速上手篇



[https://github.com/
Charlene717/scRNA-seq-
tutorial-Qseries](https://github.com/Charlene717/scRNA-seq-tutorial-Qseries)